



**NOUVEAUX CAS D'UTILISATIONS DES WEARABLE DEVICES ET LEUR
INTEROPÉRABILITÉ AVEC L'INTELLIGENCE AMBIANTE DANS UNE
ARCHITECTURE D'HABITATS INTELLIGENTS MODERNISÉE**

PAR FLORENTIN THULLIER

**THÈSE PRÉSENTÉE À L'UNIVERSITÉ DU QUÉBEC À CHICOUTIMI
COMME EXIGENCE PARTIELLE EN VUE DE L'OBTENTION DU GRADE
DE PHILOSOPHIÆ DOCTOR (PH.D.) EN INFORMATIQUE**

QUÉBEC, CANADA

© FLORENTIN THULLIER, 2019

RÉSUMÉ

TABLE DES MATIÈRES

RÉSUMÉ	ii
LISTE DES TABLEAUX	vii
LISTE DES FIGURES	x
LISTE DES ABRÉVIATIONS	xiii
DÉDICACE	xv
REMERCIEMENTS	xvi
CHAPITRE I – INTRODUCTION	1
1.1 CONTEXTE DE LA RECHERCHE	1
1.2 L'ACTIVITÉ HUMAINE	4
1.3 LA RECONNAISSANCE D'ACTIVITÉS	6
1.4 LA RECONNAISSANCE D'ACTIVITÉS DANS LES ENVIRONNEMENTS INTELLIGENTS	7
1.5 LES HABITATS INTELLIGENTS ET LES <i>WEARABLE DEVICES</i>	10
1.6 DÉFINITION DU PROJET DE RECHERCHE	12
1.7 ORGANISATION DU DOCUMENT	13
CHAPITRE II – L'INTELLIGENCE AMBIANTE AU SEIN DES HABITATS INTELLIGENTS	14
2.1 INTRODUCTION	14
2.2 LES HABITATS INTELLIGENTS EXISTANTS	14
2.2.1 LE LIARA ET LE LABORATOIRE DOMUS	15
2.2.2 MAVHOME, GATOR-TECH ET AMIQUAL4HOME	17
2.2.3 CASAS	21
2.3 LE PROCESSUS D'APPRENTISSAGE POUR RECONNAÎTRE DES ACTIVITÉS	23
2.3.1 LES ÉTAPES PRÉLIMINAIRES	25
2.3.2 LES ALGORITHMES D'APPRENTISSAGE	32
2.3.3 LA MESURE DE LA PERFORMANCE	46
2.4 CONCLUSION	49

CHAPITRE III – LES WEARABLE DEVICES AU SEIN DES HABITATS INTELLIGENTS	51
3.1 INTRODUCTION	51
3.2 DÉFINITIONS	51
3.3 LES CAPTEURS	52
3.3.1 LES CAPTEURS DE MOUVEMENTS	53
3.3.2 LES CAPTEURS PHYSIOLOGIQUES	53
3.3.3 LES CAPTEURS DE COURBURE ET DE FORCE	54
3.3.4 LES CAPTEURS ENVIRONNEMENTAUX	55
3.4 LES TECHNOLOGIES DE COMMUNICATION SANS-FIL	56
3.4.1 LES TOPOLOGIES DES RÉSEAUX	56
3.4.2 WI-FI	58
3.4.3 BLUETOOTH LOW ENERGY (BLE)	59
3.4.4 ZIGBEE	61
3.4.5 LA COMMUNICATION EN CHAMP PROCHE	61
3.4.6 BILAN DES TECHNOLOGIES DE COMMUNICATION SANS-FIL	62
3.5 LES ÉCHANGES DE DONNÉES	64
3.5.1 LE MODÈLE <i>PUBLISH/SUBSCRIBE</i>	64
3.5.2 LE CAS SPÉCIFIQUE DU BLE	66
3.5.3 LES SERVICES WEB	69
3.6 CONCLUSION	77
CHAPITRE IV – UN WEARABLE DEVICE POUR LA RECONNAISSANCE DES SOLS	80
4.1 INTRODUCTION	80
4.2 ÉTAT DE L’ART	81
4.3 SOLUTION PROPOSÉE	84
4.3.1 LE <i>WEARABLE DEVICE</i>	84
4.3.2 LE <i>FIRMWARE</i>	86
4.3.3 LE PROCESSUS D’APPRENTISSAGE POUR LA RECONNAISSANCE DES TYPES DE SOLS	87
4.4 EXPÉRIMENTATIONS	93

4.4.1	MISE EN ŒUVRE	94
4.4.2	PROCÉDURE	98
4.5	RÉSULTATS ET DISCUSSION	99
4.5.1	ENSEMBLES DE DONNÉES	99
4.5.2	RÉSULTATS OBTENUS	100
4.5.3	DISCUSSION DES RÉSULTATS OBTENUS	104
4.6	CONCLUSION	104
CHAPITRE V – UN <i>WEARABLE DEVICE</i> POUR LA SÉCURITÉ & LA CONFIGURATION AUTOMATIQUE DES HABITATS INTELLIGENTS		105
5.1	INTRODUCTION	105
5.2	ÉTAT DE L’ART	105
5.3	SOLUTION PROPOSÉE	105
5.4	EXPÉRIMENTATION PRÉLIMINAIRES	105
5.5	RÉSULTATS PRÉLIMINAIRES	105
5.6	DISCUSSION	105
5.7	CONCLUSION	105
CHAPITRE VI – UNE ARCHITECTURE D’HABITATS INTELLIGENTS MODERNISÉE		106
6.1	INTRODUCTION	106
6.2	ÉTAT DE L’ART	106
6.3	UNE ARCHITECTURE D’HABITATS INTELLIGENTS MODERNISÉE	106
6.3.1	GESTION DU CLUSTER	106
6.3.2	APPLICATIONS RELATIVES À LA RECONNAISSANCE D’ACTIVITÉS	106
6.4	LIMITATIONS	106
6.5	TESTS D’INTÉGRATION	106
6.6	CONCLUSION	106
CHAPITRE VII – CONCLUSION GÉNÉRALE		107
7.1	RÉALISATION DES OBJECTIFS	107
7.2	RÉPONSE À LA PROBLÉMATIQUE	107
7.3	LIMITATIONS ET PERSPECTIVES D’AMÉLIORATION	107

7.4	APPORTS PERSONNELS	107
	BIBLIOGRAPHIE	108
	ANNEXE A – RÉSULTATS DÉTAILLÉS DE L'EXPÉRIMENTATION	
	POUR LA RECONNAISSANCE DES SOLS	127
A.1	<i>WEARABLE DEVICE</i> : VERSION 1	127
A.2	<i>WEARABLE DEVICE</i> : VERSION 2	128
A.3	TÉLÉPHONE INTELLIGENT	131

LISTE DES TABLEAUX

TABEAU 2.1 :	MATRICE DE CONFUSION D'UN SYSTÈME DE RECONNAISSANCE BINAIRE.	47
TABEAU 3.1 :	CARACTÉRISTIQUES DES DIFFÉRENTES TECHNOLOGIES DE COMMUNICATION SANS-FIL EMPLOYÉES PAR LES <i>WEARABLE DEVICES</i>	63
TABEAU 4.1 :	RÉCAPITULATIF DE TOUTES LES CARACTÉRISTIQUES UTILISÉES PAR LA SOLUTION PROPOSÉE EN FONCTION DU NOMBRE D'AXES OFFERTS PAR LA CENTRALE INERTIELLE.	88
TABEAU 4.2 :	LISTE DES DATASETS.	99
TABEAU A.1 :	RÉSULTATS DÉTAILLÉS DE LA RECONNAISSANCE DES SOLS AVEC L'ALGORITHME <i>RANDOM FOREST</i> CONFIGURÉ AVEC $B = 150$ ARBRES ET DE HAUT EN BAS LES TROIS VALEURS DE F : F_0 , F_1 ET F_2 POUR LA VERSION 1 DU <i>WEARABLE DEVICE</i>	127
TABEAU A.2 :	RÉSULTATS DÉTAILLÉS DE LA RECONNAISSANCE DES SOLS AVEC L'ALGORITHME <i>RANDOM FOREST</i> CONFIGURÉ AVEC $B = 300$ ARBRES ET DE HAUT EN BAS LES TROIS VALEURS DE F : F_0 , F_1 ET F_2 POUR LA VERSION 1 DU <i>WEARABLE DEVICE</i>	127
TABEAU A.3 :	RÉSULTATS DÉTAILLÉS DE LA RECONNAISSANCE DES SOLS AVEC L'ALGORITHME DES K PLUS PROCHES VOISINS CONFIGURÉ AVEC $K = 1$ ET DE HAUT EN BAS LA DISTANCE EUCLIDIENNE ET LA DISTANCE DE MANHATTAN POUR LA VERSION 1 DU <i>WEARABLE DEVICE</i>	128
TABEAU A.4 :	RÉSULTATS DÉTAILLÉS DE LA RECONNAISSANCE DES SOLS AVEC L'ALGORITHME <i>RANDOM FOREST</i> CONFIGURÉ AVEC $B = 150$ ARBRES ET $F = F_0$ POUR LA VERSION 2 DU <i>WEARABLE DEVICE</i>	128
TABEAU A.5 :	RÉSULTATS DÉTAILLÉS DE LA RECONNAISSANCE DES SOLS AVEC L'ALGORITHME <i>RANDOM FOREST</i> CONFIGURÉ AVEC $B = 150$ ARBRES ET $F = F_1$ POUR LA VERSION 2 DU <i>WEARABLE DEVICE</i>	128

TABLEAU A.6 :	RÉSULTATS DÉTAILLÉS DE LA RECONNAISSANCE DES SOLS AVEC L'ALGORITHME <i>RANDOM FOREST</i> CONFIGURÉ AVEC $B = 150$ ARBRES ET $F = F2$ POUR LA VERSION 2 DU <i>WEARABLE DEVICE</i>	129
TABLEAU A.7 :	RÉSULTATS DÉTAILLÉS DE LA RECONNAISSANCE DES SOLS AVEC L'ALGORITHME <i>RANDOM FOREST</i> CONFIGURÉ AVEC $B = 300$ ARBRES ET $F = F0$ POUR LA VERSION 2 DU <i>WEARABLE DEVICE</i>	129
TABLEAU A.8 :	RÉSULTATS DÉTAILLÉS DE LA RECONNAISSANCE DES SOLS AVEC L'ALGORITHME <i>RANDOM FOREST</i> CONFIGURÉ AVEC $B = 300$ ARBRES ET $F = F1$ POUR LA VERSION 2 DU <i>WEARABLE DEVICE</i>	129
TABLEAU A.9 :	RÉSULTATS DÉTAILLÉS DE LA RECONNAISSANCE DES SOLS AVEC L'ALGORITHME <i>RANDOM FOREST</i> CONFIGURÉ AVEC $B = 300$ ARBRES ET $F = F2$ POUR LA VERSION 2 DU <i>WEARABLE DEVICE</i>	130
TABLEAU A.10 :	RÉSULTATS DÉTAILLÉS DE LA RECONNAISSANCE DES SOLS AVEC L'ALGORITHME DES K PLUS PROCHES VOISINS CONFIGURÉ AVEC $K = 1$ ET LA DISTANCE EUCLIDIENNE POUR LA VERSION 2 DU <i>WEARABLE DEVICE</i>	130
TABLEAU A.11 :	RÉSULTATS DÉTAILLÉS DE LA RECONNAISSANCE DES SOLS AVEC L'ALGORITHME DES K PLUS PROCHES VOISINS CONFIGURÉ AVEC $K = 1$ ET LA DISTANCE DE MANHATTAN POUR LA VERSION 2 DU <i>WEARABLE DEVICE</i>	130
TABLEAU A.12 :	RÉSULTATS DÉTAILLÉS DE LA RECONNAISSANCE DES SOLS AVEC L'ALGORITHME <i>RANDOM FOREST</i> CONFIGURÉ AVEC $B = 150$ ARBRES ET $F = F0$ POUR LE TÉLÉPHONE INTELLIGENT.	131
TABLEAU A.13 :	RÉSULTATS DÉTAILLÉS DE LA RECONNAISSANCE DES SOLS AVEC L'ALGORITHME <i>RANDOM FOREST</i> CONFIGURÉ AVEC $B = 150$ ARBRES ET $F = F1$ POUR LE TÉLÉPHONE INTELLIGENT.	131
TABLEAU A.14 :	RÉSULTATS DÉTAILLÉS DE LA RECONNAISSANCE DES SOLS AVEC L'ALGORITHME <i>RANDOM FOREST</i> CONFIGURÉ AVEC $B = 150$ ARBRES ET $F = F2$ POUR LE TÉLÉPHONE INTELLIGENT.	131

TABLEAU A.15 : RÉSULTATS DÉTAILLÉS DE LA RECONNAISSANCE DES SOLS AVEC L'ALGORITHME <i>RANDOM FOREST</i> CONFI- GURÉ AVEC $B = 300$ ARBRES ET $F = F0$ POUR LE TÉ- LÉPHONE INTELLIGENT.	132
TABLEAU A.16 : RÉSULTATS DÉTAILLÉS DE LA RECONNAISSANCE DES SOLS AVEC L'ALGORITHME <i>RANDOM FOREST</i> CONFI- GURÉ AVEC $B = 300$ ARBRES ET $F = F1$ POUR LE TÉ- LÉPHONE INTELLIGENT.	132
TABLEAU A.17 : RÉSULTATS DÉTAILLÉS DE LA RECONNAISSANCE DES SOLS AVEC L'ALGORITHME <i>RANDOM FOREST</i> CONFI- GURÉ AVEC $B = 300$ ARBRES ET $F = F2$ POUR LE TÉ- LÉPHONE INTELLIGENT.	132
TABLEAU A.18 : RÉSULTATS DÉTAILLÉS DE LA RECONNAISSANCE DES SOLS AVEC L'ALGORITHME DES K PLUS PROCHES VOISINS CONFIGURÉ AVEC $K = 1$ ET LA DISTANCE EUCLIDIENNE POUR LE TÉLÉPHONE INTELLIGENT. . .	133
TABLEAU A.19 : RÉSULTATS DÉTAILLÉS DE LA RECONNAISSANCE DES SOLS AVEC L'ALGORITHME DES K PLUS PROCHES VOISINS CONFIGURÉ AVEC $K = 1$ ET LA DISTANCE DE MANHATTAN POUR LE TÉLÉPHONE INTELLIGENT. . .	133

LISTE DES FIGURES

FIGURE 1.1 – REPRÉSENTATION MULTICOUCHES DE LA RECONNAISSANCE D’ACTIVITÉS DANS LES ENVIRONNEMENTS INTELLIGENTS.	9
FIGURE 2.1 – SCHÉMATISATION DE L’ARCHITECTURE UTILISÉE PAR LE LIARA ET LE LABORATOIRE DOMUS.	16
FIGURE 2.2 – SCHÉMATISATION DES ARCHITECTURES UTILISÉES PAR LES HABITATS GATOR-TECH ET AMIQUAL4HOME.	20
FIGURE 2.3 – SCHÉMATISATION DE L’ARCHITECTURE UTILISÉE PAR L’HABITAT CASAS.	22
FIGURE 2.4 – SCHÉMATISATION DU PROCESSUS D’APPRENTISSAGE POUR LA RECONNAISSANCE D’ACTIVITÉS.	24
FIGURE 2.5 – SCHÉMATISATION D’UN EXEMPLE DE RÉSEAU BAYÉSIEN NAÏF.	35
FIGURE 2.6 – SCHÉMATISATION D’UN EXEMPLE D’ARBRE DE DÉCISION BINAIRE.	38
FIGURE 2.7 – SCHÉMATISATION D’UN EXEMPLE D’ALGORITHME DE CLUSTERING.. . . .	41
FIGURE 2.8 – SCHÉMATISATION D’UN SVM LINÉAIRE AINSI QUE D’UN SVM UTILISANT UNE FONCTION DE NOYAU.	43
FIGURE 2.9 – SCHÉMATISATION D’UN EXEMPLE DE RÉSEAU DE NEURONES ARTIFICIELS.	45
FIGURE 3.1 – EXEMPLES DE CAPTEURS DE COURBURE (A) ET DE FORCE (B).. . . .	55
FIGURE 3.2 – REPRÉSENTATION DES TOPOLOGIES RÉSEAUX POUR LES TECHNOLOGIES DE COMMUNICATION SANS-FIL. . .	58
FIGURE 3.3 – ILLUSTRATION DU FONCTIONNEMENT DU MODÈLE <i>PUBLISH/SUBSCRIBE</i>	65
FIGURE 3.4 – ILLUSTRATION DU PROCESSUS D’ÉCHANGE DE DONNÉES DANS LES DEUX MODES DE FONCTIONNEMENT DU BLE, SOIT LES MODES DIFFUSION ET CONNEXION. .	69

FIGURE 3.5 – EXEMPLE D’UN ÉCHANGE DE MESSAGES SOAP ENTRE UN CLIENT ET UN SERVEUR POUR OBTENIR LA VALEUR DU CAPTEUR CARDIAQUE..	71
FIGURE 3.6 – ILLUSTRATION D’UN ÉCHANGE DE MESSAGES ENTRE UN CLIENT ET UN SERVEUR DANS UNE ARCHITECTURE REST BASÉE SUR HTTP QUI PERMET DE RÉCUPÉRER LA VALEUR D’UN CAPTEUR CARDIAQUE..	74
FIGURE 3.7 – ILLUSTRATION D’UN ÉCHANGE DE MESSAGES ENTRE UN CLIENT ET UN SERVEUR DANS UNE ARCHITECTURE REST BASÉE SUR CoAP QUI PERMET DE RÉCUPÉRER LA VALEUR D’UN CAPTEUR CARDIAQUE..	77
FIGURE 4.1 – SoC ARDUINO 101 ET SON <i>SHIELD</i> DE PROTOTYPAGE INCLUANT UNE CARTE MÉMOIRE (1) AINSI QUE LA CENTRALE INERTIELLE <i>LSM9DS1</i> (2) PRÉSENTE SUR LA VERSION 2 DU DISPOSITIF..	85
FIGURE 4.2 – REPRÉSENTATION GRAPHIQUE DE L’IMPLÉMENTATION DU <i>FIRMWARE</i> EMBARQUÉ SUR LE <i>WEARABLE DEVICE</i>	86
FIGURE 4.3 – EXEMPLE DE L’ALGORITHME <i>RANDOM FOREST</i> UTILISANT $B = 3$ ARBRES..	91
FIGURE 4.4 – EXEMPLE DE L’ALGORITHME DES K PLUS PROCHES VOISINS OÙ $K = 3$	93
FIGURE 4.5 – BAC UTILISÉ LORS DES EXPÉRIMENTATIONS REMPLI DE GRAVIER EN HAUT ET DE SABLE EN BAS, DE DIMENSIONS : $L : 215\text{ CM} \times L : 90\text{ CM} \times H : 15\text{ CM}$	95
FIGURE 4.6 – CAPTURES D’ÉCRAN DE L’APPLICATION <i>ANDROID</i> QUI PERMET DE PILOTER ET D’ÉTIQUETTER LES DONNÉES ENREGISTRÉES EXÉCUTÉE SUR <i>CELL_OPER</i>	96
FIGURE 4.7 – ILLUSTRATION DES CINQ EMPLACEMENTS OÙ LE <i>WEARABLE DEVICE</i> EST POSITIONNÉ PENDANT L’EXPÉRIMENTATION.	98
FIGURE 4.8 – RÉSULTATS.	100
FIGURE 4.9 – INDÉPENDANCE DE POSISITION..	101
FIGURE 4.10 – RÉSULTATS.	102
FIGURE 4.11 – INDÉPENDANCE DE POSISITION..	103

FIGURE 4.12 – RÉSULTATS.	104
----------------------------------	-----

LISTE DES ABRÉVIATIONS

ASCII	American Standard Code for Information Interchange
ATT	ATtribute Protocol
ADL	Activity of Daily Living
AMQP	Advanced Message Queuing Protocol
ANN	Artificial Neural Network
BADL	Basic Activity Daily Living
BAN	Body Area Network
BLE	Bluetooth Low Energy
CoAP	Constrained Application Protocol
CORBA	Common Object Request Broker Architecture
CRF	Conditional Random Field
CSV	Comma-Separated Values
DBSCAN	Density-Based Spatial Clustering of Applications with Noise
DFT	Discrete Fourier Transform
DoF	Degrees of Freedom
DOMUS	Domotique et informatique Mobile à l'Université de Sherbrooke
DWPD	Discrete Wavelet Package Decomposition
DWT	Discrete Wavelet Transform
ECG	électrocardiogramme
EEG	électroencéphalogramme
EMG	électromyogramme
EADL	Enhanced Activity Daily Living
FFT	Fast Fourier Transform
FSR	Force Sensitive Resistor
GATT	Generic ATtribute
GAP	Generic Access Profile
GPS	Global Positioning System
HMM	Hidden Markov Model
HTML	Hypertext Markup Language
HTTP	HyperText Transfer Protocol
I²C	Inter-Integrated Circuit
IA	Intelligence Artificielle
IADL	Instrumental Activity Daily Living

IAm	Intelligence Ambiante
ID3	Iterative Dichotomiser 3
IMU	Inertial Measurement Unit
I/O	Input/Output
IoT	Internet of Things
JSON	JavaScript Object Notation
<i>k</i>-NN	<i>k</i> -Nearest Neighbors
LIARA	Laboratoire d’Intelligence Ambiante pour la Reconnaissance d’Activités
MQTT	Message Queuing Telemetry Transport
NFC	Near Field Communication
openHAB	open Home Automation Bus
OSGi	Open Services Gateway initiative
P2P	Peer-to-Peer
PCA	Principal Component Analysis
PNN	Probabilistic Neural Network
QoS	Quality of Service
REST	Representational State Transfer
RF	Random Forest
RFID	Radio-Frequency IDentification
SMTP	Simple Mail Transfer Protocol
SOAP	Simple Object Access Protocol
SoC	System on Chip
SPI	Serial Peripheral Interface
SPO₂	Saturation Pulsée en Oxygène
SSL	Secure Sockets Layer
SVM	Support Vector Machine
TCP	Transmission Control Protocol
TLS	Transport Layer Security
UDP	User Datagram Protocol
UQAC	Université du Québec à Chicoutimi
URI	Uniform Resource Identifier
UUID	Universally Unique IDentifier
VPN	Virtual Private Network
XML	eXtensible Markup Language
XMPP	Extensible Messaging and Presence Protocol

DÉDICACE

Je dédie cette thèse aux personnes qui m'ont supporté tout au long de cet accomplissement personnel. Ma famille, mes amis, mes collègues. Un sincère remerciement pour votre aide, votre soutien et parfois votre patience.

REMERCIEMENTS

CHAPITRE I

INTRODUCTION

1.1 CONTEXTE DE LA RECHERCHE

La surpopulation est l'un des principaux maux de ce XXI^e siècle, auquel l'humanité doit faire face. En effet, selon un rapport des Nations Unies, la population mondiale serait de 7,3 milliards aujourd'hui, alors que 5,3 milliards d'êtres humains seulement étaient recensés en 1990. De plus, les projections réalisées pour les prochaines décennies ne s'annoncent pas encourageantes ; à savoir 8,5 milliards pour 2030, 9,7 milliards pour 2050 et 11,2 milliards pour 2100 (United Nations, 2017b). Les causes de cette inflation d'envergure sont diverses et varient selon les continents. Par exemple, les pays en développement sont ceux qui montrent les plus forts taux de fertilité, tandis que les pays développés font, quant à eux, face à un certain vieillissement de leur population. Aussi, l'espérance de vie de la population mondiale s'est accrue de manière significative, et ce, principalement en raison des avancées médicales ainsi que de l'augmentation de la production agricole. En effet, les Nations Unies recensent 901 millions de personnes dont l'âge est supérieur à 60 ans. De plus, les prévisions pour les prochaines décennies annoncent 1,4 milliard d'individus en 2030 et 2,1 milliards en 2050 (United Nations, 2015).

Dans un premier temps, le vieillissement que connaît la population, majoritairement celle des pays développés, entraîne nécessairement un plus grand nombre de personnes dont l'autonomie se retrouve fortement diminuée, voire complètement perdue.

Ce déclin d'autonomie peut être corrélé aux maladies neurodégénératives (*p. ex.* la maladie d'Alzheimer, la maladie de Parkinson, la maladie de Huntington, *etc.*), mais également aux différents handicaps (handicap physique, sensoriel ou intellectuel). Selon la gravité de la perte d'autonomie engendrée par ces pathologies, une assistance rigoureuse demeure nécessaire, car les personnes touchées requièrent une prise en charge relativement constante (Alzheimer's Association, 2017). Actuellement, les acteurs de la prise en charge des malades sont majoritairement leurs proches (Paraponaris *et al.*, 2012). Néanmoins, ceux-ci doivent alors assumer les conséquences aussi bien sur le plan personnel et émotionnel qu'au niveau social et financier (Alzheimer's Association, 2017).

Dans un second temps, la forte croissance observée depuis les années 1990 jusqu'à nos jours entraîne un exode rural important. D'après un autre rapport produit par United Nations (2017a), la proportion de résidents urbains devrait atteindre 61% de la population mondiale dans les prochaines années. Ainsi, de plus en plus de mégapoles se créent (seulement 4 villes affichaient ce statut en 1975, pour 36 aujourd'hui), et tendent à devenir de plus en plus grosses (United Nations, 2017a). En effet, d'ici à 2025 l'Asie pourrait compter, à elle seule, pas moins de 10 villes dont la population serait supérieure à 40 millions d'habitants. De plus, cette croissance démographique mènera à une dégradation globale de l'environnement et des changements climatiques importants, car il faudra produire de plus en plus de ressources vitales, ce qui provoquera indubitablement un afflux toujours plus conséquent de pollution. De la même façon, le coût global de la vie (logements, nourriture, santé, *etc.*) augmentera, à terme, de façon manifeste (United Nations, 2017a).

Les récents progrès en matière de technologies de l'information et de microélectronique ont permis de faire émerger de nouveaux concepts comme celui de l' Intelligence Ambiante (IAm). Ce concept peut être traduit par une couche d'abstraction où l'informatique se retrouve au service de la communication entre les objets et les personnes. En pratique, il s'agit d'enrichir l'environnement dans lequel l'Homme évolue avec la technologie afin d'en extraire le contexte et apprendre son comportement pour prendre des décisions et lui porter assistance (Sadri, 2011). L'Intelligence Ambiante se retrouve notamment dans les habitats intelligents, à l'intérieur desquels, différents types de capteurs et d'effecteurs statiques et portables sont utilisés afin de récolter des données. Parmi ceux-ci, il est possible de retrouver des antennes RFID, des capteurs infrarouges et ultrasons, des contacteurs magnétiques et des accéléromètres. La production de telles données permet alors d'apporter de l'assistance et du confort au résident, mais également d'évaluer sa santé mentale et physique (Rashidi et Mihailidis, 2013; Haux *et al.*, 2016; Harris et Hunter, 2016; Johnson et Ianes, 2018).

Pour l'instant et dans une optique de court terme, les habitats intelligents demeurent d'excellents vecteurs d'assistance pour les personnes touchées par une perte d'autonomie partielle ou totale. De plus, s'ils permettent de compenser les lourdes dépenses que représentent leur prise en charge pour les systèmes de santé. Ils peuvent également à soulager les proches aidant vis-à-vis de la quantité de stress qu'ils éprouvent. À titre d'exemple, le rapport publié par Prince *et al.* (2016) rapporte que 47 millions de personnes sont actuellement affectées par un trouble neurocognitif ce qui, selon une estimation, coûterait 818 milliards de dollars US à l'échelle mondiale. Néanmoins, les habitats intelligents pourraient tendre à devenir de plus en plus indispensables à

long terme. En effet, ceux-ci pourraient avoir un rôle important dans les innovations d'urbanisme à venir, afin d'atténuer les effets engendrés par la surpopulation. Selon un rapport d'UN-Habitat, l'urbanisation représenterait le meilleur compromis face à l'augmentation croissante de la population, car l'activité humaine se retrouverait alors concentrée dans des surfaces limitées, ce qui réduirait l'ampleur des dommages environnementaux (UNFPA, 2007). Cependant, cela ne sera possible que si l'urbanisme actuel subit des améliorations significatives, où l'objectif est la conception de villes plus compactes, intégrées socialement, connectées, qui favorisent le développement urbain et qui sont résistantes aux changements climatiques (UNFPA, 2007).

Cette thèse ne traitera, cependant, que de la problématique générale de l'assistance aux personnes en perte d'autonomie. Ainsi, les sections suivantes ont pour objectif de définir les notions clés inhérentes à celle-ci.

1.2 L'ACTIVITÉ HUMAINE

La notion d'activité humaine dans la problématique de l'assistance aux personnes affectées par une perte d'autonomie demeure fondamentale. C'est pourquoi il convient de la définir de façon appropriée. Dans le domaine de la santé, il est convenu que l'utilisation du terme activité fait directement référence au concept d'activité de la vie quotidienne (Activity of Daily Living ou ADL) introduit et présenté par Katz *et al.* (1963). Il regroupe un ensemble d'activités permettant de mesurer l'habileté pour un individu à maintenir sa santé et son autonomie (*p. ex.* préparer à manger, s'habiller, se laver, *etc.*). Ainsi, le succès ou l'échec dans la réalisation de ces tâches constitue, pour les professionnels de la santé, une mesure fiable pour quantifier la perte d'autonomie d'un

patient présentant un handicap dont celle-ci en est soit une cause, soit une conséquence. Ceci permet alors d'adapter le type et le niveau d'assistance approprié pour chacun d'entre eux (Giovannetti *et al.*, 2002). Depuis les travaux de Katz *et al.* (1963), les chercheurs Lawton et Brody (1969) ont proposé un regroupement des ADLs en deux ensembles distincts qui sont :

Les activités basiques (Basic Activity Daily Living ou BADL) regroupent l'ensemble de toutes les activités fondamentales aux besoins primaires d'une personne. Par exemple, se déplacer sans aucun outil d'assistance (béquille, canne, *etc.*), se laver, se nourrir, se coucher, se lever, *etc.* Ces activités sont généralement composées de très peu d'étapes et ne requièrent aucune planification pour être accomplies avec succès.

Les activités instrumentalisées (Instrumental Activity Daily Living ou IADL) sont, quant à elles, l'ensemble des activités qui nécessitent une certaine planification et qui permettent de statuer sur l'autonomie d'une personne en société. On y retrouve, par exemple, l'appel téléphonique, la préparation d'un repas ou encore la gestion de l'argent. Aussi, ces activités requièrent souvent beaucoup plus d'étapes dans leur exécution que les BADLs.

Finalement, ce regroupement a été étendu par Rogers *et al.* (1998) afin d'y inclure un troisième et dernier ensemble d'activités laissées pour compte jusqu'alors. Il s'agit des Enhanced Activity Daily Living (EADL) qui comprend toutes les activités qui nécessitent une certaine adaptation ou un apprentissage pour être menées à bien. Par exemple, utiliser un nouvel appareil électronique dans la maison représente une activité nécessitant un apprentissage et une certaine adaptation pour l'habitant.

Maintenant que la notion fondamentale d'activité a été définie, il est nécessaire d'expliquer en quoi elle est au cœur du fonctionnement même des habitats intelligents puisque l'objectif de ceux-ci est d'offrir à leurs résidents une assistance adaptée grâce à la reconnaissance de leurs activités.

1.3 LA RECONNAISSANCE D'ACTIVITÉS

La reconnaissance d'activités est un domaine qui fait partie de l'Intelligence Artificielle (IA). De nos jours, ce dernier suscite un intérêt toujours plus grandissant chez les chercheurs pourtant, sa première définition n'est pas récente. En effet, selon Schmidt *et al.* (1978), la reconnaissance d'activités peut se traduire comme la découverte du but qu'un acteur souhaite atteindre à partir d'une séquence d'actions qu'il est en train de réaliser. Ainsi, la reconnaissance d'activités est la déduction d'une suite d'actions dans l'espace et le temps (la structure d'activité) déterminée et exécutée par une entité qu'un observateur va alors chercher à reconnaître.

Depuis, Roy *et al.* (2013) ont proposé de caractériser la reconnaissance d'activités par la relation qu'il existe entre l'observateur (*p. ex.* l'habitat intelligent) et l'observé (*p. ex.* le résident). Ainsi, il demeure possible de mettre en place un découpage de la reconnaissance d'activités en différents types, selon le comportement que l'observé adopte envers l'observateur. Trois comportements distincts ont donc été recensés : positif, négatif ou neutre. Dans le premier cas, l'observé va agir de sorte à faciliter et même collaborer avec l'observateur dans son processus de reconnaissance. Pour ce faire, l'observé peut, par exemple, poser des questions à l'observateur en cas de doutes. Cependant, appliquer un tel type de reconnaissance relève de l'impossible

lorsque les résidents des habitats intelligents sont affectés par des troubles cognitifs comme la maladie d'Alzheimer. En effet, la nécessité d'adapter son comportement pour assister l'observateur dans son processus requiert une forte augmentation de la charge cognitive de l'habitant, ce à quoi, il leur est pratiquement impossible de faire face. Dans le second cas, où l'observé adopte un comportement négatif envers l'observateur, il va essayer délibérément, et par tous les moyens, d'empêcher le bon déroulement de la reconnaissance. Néanmoins, ceci n'arrive jamais avec les résidents atteints de l'Alzheimer, mais pourrait parfaitement se produire dans le cas d'autres maladies et/ou handicaps. Les personnes atteintes d'Alzheimer entrent plutôt dans la dernière catégorie de comportement, où l'observé n'agit ni pour aider ni pour empêcher le processus de reconnaissance.

La présentation de ces trois types de reconnaissance vient clore la définition générale de la reconnaissance d'activités. Il est maintenant nécessaire de s'intéresser à l'intégration de cette problématique au sein des environnements intelligents.

1.4 LA RECONNAISSANCE D'ACTIVITÉS DANS LES ENVIRONNEMENTS INTELLIGENTS

Depuis sa définition initiale, de nombreux travaux ont fait évoluer la reconnaissance d'activités afin que celle-ci puisse s'adapter au contexte bien spécifique des environnements intelligents (Patterson *et al.*, 2005; Boger *et al.*, 2006; Bouchard *et al.*, 2007; Ghayvat *et al.*, 2018). L'objectif majeur de ces adaptations était de remanier le concept d'environnement ambiant, afin qu'il puisse s'unir avec la problématique de la reconnaissance d'activités.

De ce fait, la première extension à la définition de ce processus appliquée de manière concrète à ces environnements a été décrite par Patterson *et al.* (2005). Leur recherche indique que les observations doivent être réalisées à partir des données fournies par des capteurs de bas niveau. Cette nouvelle vision vient directement s'inscrire dans l'ère de l'informatique ubiquitaire (Weiser, 1991) et devient, par conséquent, beaucoup plus pertinente face à la réalité du problème. L'observé évolue alors dans un environnement composé de différents capteurs, dont le rôle est de récolter les variations qui sont produites par les interactions entre l'acteur et son environnement. Par conséquent, ce sont ces changements qui vont permettre à l'observateur de réaliser le processus de reconnaissance d'activités.

Plus récemment, en se basant sur les travaux précédents de Patterson *et al.* (2005), Roy *et al.* (2013) ont proposé une liste de quatre problématiques pour accomplir le processus de reconnaissance d'activité au sein des environnements intelligents. La première concerne la récolte des valeurs d'un ensemble hétérogène de capteurs de manière uniforme. En d'autres termes, il s'agit d'offrir la possibilité de recueillir toutes les données produites par l'ensemble de capteurs au travers d'une interface unique, où cette dernière fait totalement abstraction du protocole de communication pour chaque capteur (*p. ex.* RFID, Bluetooth, Wi-Fi, I²C, *etc.*). Le second défi identifié par Roy *et al.* (2013) est l'interprétation de ces valeurs pour en déduire de l'information intelligible, comme la localisation du résident au sein de l'environnement. Ensuite, la troisième problématique est d'être en mesure de déterminer les actions qui sont effectuées par l'habitant *via* l'interprétation des valeurs renvoyées par les capteurs. Enfin, le dernier

défi mentionné par les auteurs concerne l'interprétation de la suite d'actions produites en une activité de plus haut niveau.

Pour répondre à ces quatre problématiques, Roy *et al.* (2013) ont proposé un modèle de reconnaissance d'activités multicouche dont la représentation graphique est donnée en figure 1.1. Les quatre couches qui composent ce modèle sont indépendantes les unes des autres. Chaque couche a pour objectif de ne répondre qu'à une seule problématique en particulier et doit fournir à la couche supérieure le résultat du traitement achevé. Ainsi, chacune des problématiques peut être traitée séparément.




Figure 1.1 : Représentation multicouches de la reconnaissance d'activités dans les environnements intelligents.

En définitive, il est donc possible d'effectuer une reconnaissance d'activités au sein d'un environnement intelligent à partir de capteurs de bas niveau—à condition que

les différentes problématiques énoncées précédemment soient respectées tout au long du processus.

1.5 LES HABITATS INTELLIGENTS ET LES *WEARABLE DEVICES*

Au cours des dix dernières années, de nombreux travaux concernant les environnements intelligents et plus particulièrement, les habitats intelligents ont vu le jour. Pour reconnaître les activités des résidents, ceux-ci ont adopté des architectures sensiblement identiques, où les valeurs des capteurs sont centralisées en une entité unique (un serveur) qui va, à elle seule, exécuter toutes les couches de la reconnaissance d'activités (Bouchard *et al.*, 2014; Hu *et al.*, 2016). Néanmoins, certaines distinctions demeurent entre ces différentes implémentations. Par exemple, le Laboratoire d'Intelligence Ambiante pour la Reconnaissance d'Activités (LIARA) (Bouchard *et al.*, 2014) et le Laboratoire de Domotique et informatique Mobile à l'Université de Sherbrooke (DOMUS) (Giroux *et al.*, 2009) représentent les habitats intelligents hérités du monde de l'industrie. Les autres implémentations d'habitats intelligents comme Gator-Tech (Helal *et al.*, 2005), MavHome (Cook *et al.*, 2003), CASAS (Cook *et al.*, 2013) ou encore Amiqua4home (Lago *et al.*, 2017) reposent toutes, quant à elles, sur des architectures par composants. Cependant, ces habitats intelligents connaissent certaines limitations. En effet, bien que les architectures centralisées simplifient l'utilisation des algorithmes de reconnaissance d'activités, elles ont un impact significatif sur la fiabilité de fonctionnement du système de reconnaissance et donc sur la sécurité du résident qui occupe l'habitat. Bien que de nouveaux travaux essayent de répondre à cette problématique (Cook *et al.*,

2013; Plantevin *et al.*, 2018), les habitats intelligents restent également, encore très dispendieux.

Par ailleurs, les recherches réalisées dans la reconnaissance d'activités au sein d'un habitat intelligent se sont intéressées, en grande partie, à reconnaître les activités d'un unique habitant dans l'environnement (mono-résident) Vikramaditya Jakkula (2007); Van Kasteren *et al.* (2008); Inomata *et al.* (2009); Ghazvininejad *et al.* (2011); Belley *et al.* (2014); Fortin-Simard *et al.* (2015). Bien que très performantes, ces solutions se sont retrouvées défaillantes lorsque l'habitat est occupé par plusieurs résidents (multi-résident). Ce cas de figure constitue pourtant une problématique bien plus proche de la réalité actuelle des habitats intelligents. De nouvelles techniques de reconnaissance d'activités ont donc été proposées (Crandall et Cook, 2009; Cook et Schmitter-Edgecombe, 2009; Alemdar *et al.*, 2013; Ayuningtyas *et al.*, 2014; Emi et Stankovic, 2015; Mokhtari *et al.*, 2018). Plusieurs d'entre elles (Mihailidis *et al.*, 2004; Tunca *et al.*, 2014) se sont alors tournées vers l'utilisation de *wearable devices*, beaucoup plus accessibles financièrement. D'autre part, grâce à la miniaturisation de ces appareils, ceux-ci tendent à être de moins en moins considérés comme intrusifs par leur utilisateurs (Gaskin *et al.*, 2017). En plus de la reconnaissance d'activités mono-résident et multi-résidents, ces capteurs portables ont permis l'ouverture de nouveaux horizons de recherche et sont principalement utilisés pour la surveillance de la santé, la réhabilitation physique, la détection de chutes, *etc.* (Patel *et al.*, 2012; Mukhopadhyay, 2014; Delahoz et Labrador, 2014).

L'augmentation de l'utilisation des *wearable devices* au sein des habitats intelligents a fait émerger de nouvelles problématiques. Dans un premier temps, puisque ceux-ci se trouvent placés sur les résidents, il devient alors possible d'envisager de nouveaux types de reconnaissance permettant d'améliorer la qualité de l'assistance proposée. Néanmoins, puisque les différentes architectures recensées dans la littérature n'ont pas été initialement prévues pour accueillir ce type de matériel, les *wearable devices* se retrouvent très mal, voir nullement intégrés à celles-ci. Il apparaît donc primordial de s'intéresser à une manière de mieux les intégrer, dans le but de proposer un processus de reconnaissance combinée entre les données fournies, à la fois par les capteurs ambiants et portables, ce qui apparaît difficilement faisable actuellement tant en termes d'intégration matérielle que d'exploitation logicielle. En effet, les dispositifs actuels exploitent uniquement les données qu'ils génèrent eux-mêmes, mais il apparaît crucial de proposer une solution afin de pouvoir utiliser, de manière générique, les données générées par plusieurs *wearable devices*.

1.6 DÉFINITION DU PROJET DE RECHERCHE

Retravailler cette section

Cette thèse s'articule donc autour de l'exploitation des *wearable devices* ainsi que de l'interopérabilité de ces derniers avec l'utilisation de l'intelligence ambiante au sein des habitats intelligents. Plus particulièrement, cette thèse permettra de répondre aux questions suivantes :

1. Quels nouveaux apports, en matière d'intelligence, les *wearable devices* vont permettre de proposer aux résidents des habitats intelligents afin d'améliorer l'assistance qui leur est requise ?
2. Comment optimiser l'intégration des *wearable devices* afin qu'ils puissent être utilisés en combinaison avec les capteurs statiques présents dans les habitats intelligents pour réaliser une reconnaissance basée sur l'interopérabilité de ces deux méthodes ?
3. Comment valoriser la réutilisation des différents algorithmes employés dans la reconnaissance d'activités avec les *wearable devices* afin de faciliter les expérimentations dans un cadre académique ?

Tout d'abord, différents *wearable devices* permettant de réaliser de nouveaux types de reconnaissances seront développés afin de proposer une meilleure assistance aux résidents de l'habitat intelligents. Ensuite, l'objectif de cette thèse est de mettre en place un framework pour faciliter l'intégration des *wearable devices* au sein des ces environnements. Celui-ci fournira une couche d'abstraction autant envers l'architecture de l'habitat dans lequel il est déployé qu'envers le dispositif lui-même. Enfin, cet outil aura également pour fonction de faciliter l'utilisation de ces appareils, dans un cadre académique, en offrant la possibilité de valider plus rapidement le fonctionnement des prototypes.

1.7 ORGANISATION DU DOCUMENT

Retravailler cette section

La suite de cette thèse se découpe en trois chapitres. Le chapitre 2 présente, dans un premier temps, les différentes architectures d'habitats intelligents existantes. Dans un second temps, ce chapitre explique plus en détail le processus de reconnaissance d'activité et plus spécifiquement, les différents algorithmes qui sont utilisés pour l'apprentissage et la classification. Ensuite, le chapitre 3 explicite le fonctionnement des *wearable devices* ainsi que les différentes applications de ceux-ci au sein des habitats intelligents.

CHAPITRE II

L'INTELLIGENCE AMBIANTE AU SEIN DES HABITATS INTELLIGENTS

2.1 INTRODUCTION

Dans le chapitre précédent, la reconnaissance d'activité a été définie et son application concrète au sein d'environnements intelligents a été brièvement abordée. Néanmoins, avant d'entrer plus en détail sur le fonctionnement du processus de la reconnaissance d'activité, il convient d'étudier les différents types d'environnements dans lesquels elle est appliquée. Ainsi, ce chapitre présente, dans un premier temps, l'état de l'art des différents types d'architectures existantes pour enfin, proposer une étude détaillée du processus de la reconnaissance d'activités. Cette dernière partie présentera notamment l'ensemble des étapes nécessaires pour y parvenir ainsi que les différents algorithmes utilisés.

2.2 LES HABITATS INTELLIGENTS EXISTANTS

Dans la dernière décennie, plusieurs implémentations d'habitats intelligents, visant à mettre en pratique le concept de reconnaissance d'activités multicouche tel que présenté par Roy *et al.* (2013), ont émergé (Cook *et al.*, 2003; Helal *et al.*, 2005; Giroux *et al.*, 2009; Cook *et al.*, 2013; Bouchard *et al.*, 2014; Lago *et al.*, 2017). Néanmoins, en l'absence de toute spécification formelle d'une architecture optimale pour ces habitats, chacune des applications proposées demeurent différentes malgré leur motivation commune. Puisque l'un des objectifs de cette thèse est de proposer une meilleure inté-

gration des *wearable devices* au sein des habitats intelligents—il convient d’identifier les réelles différences entre ces architectures afin d’en extraire leurs avantages et leurs inconvénients. Pour ce faire, cette première partie se découpe en trois sous-sections qui correspondent chacune à un type d’implémentation parmi les plus avancées dans le domaine soit, les architectures industrielles avec le LIARA (Bouchard *et al.*, 2014) et le DOMUS (Giroux *et al.*, 2009), les architectures basées composants avec MavHome (Cook *et al.*, 2003), Gator-Tech (Helal *et al.*, 2005) et Amiqua4home (Lago *et al.*, 2017) et enfin CASAS (Cook *et al.*, 2013), l’habitat intelligent qui repose sur un réseau maillé ZigBee. Cependant, cette thèse ne tient pas compte des habitats intelligents qui reposent sur l’utilisation de technologies considérées trop intrusives pour reconnaître les activités de leurs résidents, comme les caméras ou les microphones (Brumitt *et al.*, 2000; Vacher *et al.*, 2011).

2.2.1 LE LIARA ET LE LABORATOIRE DOMUS

Le LIARA (Bouchard *et al.*, 2014) et le Laboratoire DOMUS (Giroux *et al.*, 2009) sont deux environnements académiques de recherche pour la reconnaissance d’activités. Ces deux laboratoires disposent d’habitats intelligents qui reposent sur des technologies héritées du milieu industriel. Comme illustré à la figure 2.1, leur architecture s’articule essentiellement autour d’une entité de calcul centrale (le serveur) ainsi qu’un automate industriel qui permet de récupérer les valeurs des différents capteurs qui sont divisés en îlots. Ces valeurs sont ensuite enregistrées dans une base de données de type relationnelle. Ainsi, les couches supérieures de la reconnaissance d’activités peuvent être réalisées sur le serveur par le biais d’une unique interface.

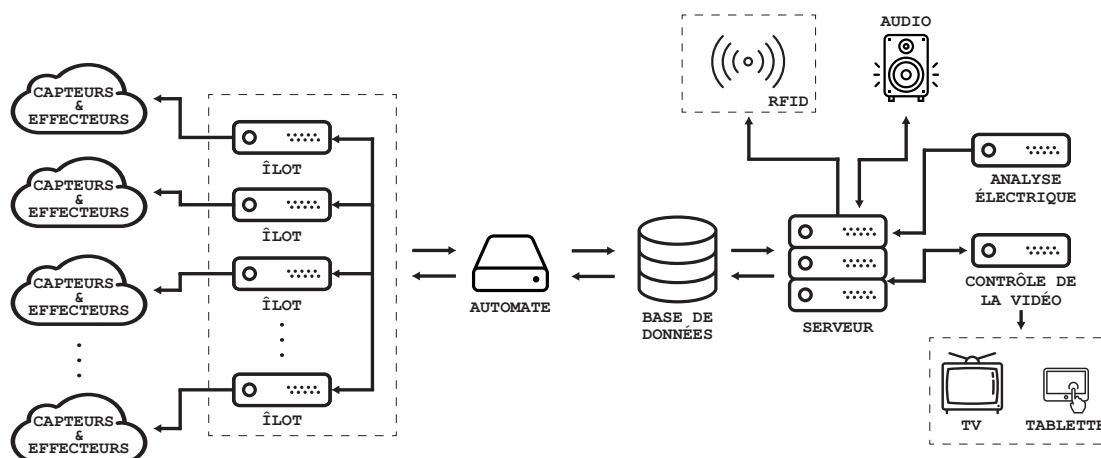


Figure 2.1 : Schématisation de l'architecture utilisée par le LIARA et le laboratoire DOMUS.

Le principal avantage d'une telle architecture concerne l'exploitation de matériel industriel directement. En effet, ce dernier étant conçu pour fonctionner sans interruption dans des environnements difficiles comme des usines, il demeure extrêmement robuste et fiable sur le long terme. Cela permet donc de garantir la qualité de fabrication pour l'habitat intelligent. Aussi, le choix d'une architecture centralisée favorise un accès simplifié aux données de l'habitat. La couche matérielle est abstraite pour les différents programmes de reconnaissance et d'assistance qui peuvent alors interroger directement la base de données.

Malgré ces avantages, une architecture comme celle du LIARA et du laboratoire DOMUS présentent des inconvénients majeurs. Le premier concerne le coût global. En effet, Plantevin (2018) a évalué le prix de ces habitats à 13 500 dollars US sans compter les capteurs, les effecteurs, l'installation et le support. Un investissement de cette ampleur est donc conséquent pour les personnes en perte d'autonomie, car dans

une grande majorité, ceux-ci vivent dans des conditions financières précaires, et ce, malgré la prise en charge de certains frais par leur régime d'assurance (Alzheimer's Association, 2018). De plus, bien que le matériel industriel soit un gage de qualité de l'habitat, il n'est pas impossible qu'une panne survienne, par exemple la perte d'un îlot, de l'automate ou du serveur. De ce fait, puisque l'architecture est centralisée, le fonctionnement de l'habitat peut être partiellement ou totalement altéré. Dans le pire des cas, l'assistance au résident devient donc impossible et des situations dangereuses pour sa sécurité peuvent survenir. Finalement, une architecture monolithique telle que celle-ci ne facilite pas l'intégration de nouveaux capteurs qui doivent être ajoutés manuellement dans le système. De plus, l'intégration de capteurs qui ne peuvent être reliés par câble aux îlots de l'habitat demeure extrêmement complexe (Plantevin, 2018). Il apparaît donc clairement que l'évolutivité de l'architecture ainsi que l'utilisation de *wearable devices* n'ont pas été pris en compte lors de la conception de cette architecture.

2.2.2 MAVHOME, GATOR-TECH ET AMIQUAL4HOME

Pour répondre à la problématique de l'évolutivité, des architectures basées composant ont été développées. Le premier exemple d'habitat intelligent exploitant ce type d'architecture est MavHome (Cook *et al.*, 2003). Cette dernière repose sur une interface Common Object Request Broker Architecture (CORBA)¹ permettant la liaison entre les différents composants logiciels et le contrôleur électrique des appareils présents dans l'habitat. Cependant, en raison de la complexité des contraintes imposées par ce standard, des solutions plus récentes comme Gator-Tech (Helal *et al.*, 2005), Amigual4home (Lago

1. www.corba.org

et al., 2017) ou encore les initiatives proposées par Novák et Binas (2011) et Cheng *et al.* (2012) ont préféré l'emploi de la technologie Open Services Gateway initiative (OSGi). Tous ces habitats partagent des caractéristiques identiques. Par conséquent, seuls les cas de Gator-Tech et d'Amiqual4home seront détaillés dans cette section, car ils reviennent fréquemment dans la littérature.

L'habitat Gator-Tech a pour objectif de répondre à une problématique des habitats de type industriel, à savoir la simplification du processus d'intégration de nouveaux capteurs. Pour ce faire, son architecture repose essentiellement sur la technologie OSGi². Comme illustré par la figure 2.2a, chaque capteur de l'habitat possède son propre pilote qui lui permet de communiquer avec l'intégralité du système. Ce pilote est stocké dans une mémoire morte dans le but de conserver les données, même lorsque le matériel n'est pas alimenté. Ainsi, lors de la mise en fonction d'un capteur, celui-ci s'enregistre de manière autonome auprès d'une définition de service. Cette dernière va alors servir de couche d'abstraction pour la création de services de base qui peuvent soit permettre de consommer des données fortement abstraites, soit être combinés afin d'obtenir un service composite. Un service de base peut, par exemple, renvoyer *“la plaque de cuisson est chaude”* lorsque la sonde de température de la cuisinière donne une valeur supérieure à 50°C ; alors qu'un service composite peut, quant à lui, agréger tous les services basiques des capteurs Radio-Frequency IDentification (RFID) pour localiser un résident dans l'habitat. De ce fait, il est possible de concevoir des programmes de reconnaissance et d'assistance sans jamais se préoccuper du protocole de communication des capteurs, ni du format dans lequel ils transmettent les données.


2. www.osgi.org/developer/architecture

Ce même fonctionnement est utilisé par l’habitat intelligent Amiqua4home. Cet environnement s’appuie sur open Home Automation Bus (openHAB)³, un *middleware open source* dédié aux habitats intelligents, qui s’appuie sur un environnement OSGi ainsi que sur le *framework* Eclipse SmartHome⁴ spécifiquement conçu pour fonctionner dans cet environnement. Ainsi, comme illustré par la figure 2.2b, openHAB permet de créer une couche d’abstraction autour des couches service, connaissance et logicielle visibles sur la figure 2.2a.


Le principal avantage de ce type d’architectures est qu’elles supportent parfaitement la mise à l’échelle de l’environnement dans le cas d’ajouts ou de remplacements de capteurs. Il semble également que l’intégration de *wearable devices* soit possible, sans effort particulier, grâce à la flexibilité offerte par les architectures basées composants. De plus, l’exploitation de données fortement abstraites facilite le développement de programmes de reconnaissance et d’assistance, puisqu’un raisonnement sur ce type de données demeure plus simple que d’exploiter les données brutes directement (Helal *et al.*, 2005). Enfin, il est possible que le coût d’un tel habitat soit considérablement réduit en comparaison à un habitat basé sur une architecture industrielle. En effet, dans le cas de Gator-Tech, son architecture requiert toujours un serveur central. Néanmoins, elle n’implique pas l’utilisation d’un automate ou d’îlots, et les capteurs utilisés au sein de cet environnement sont basés sur des plateformes à faible coût (Helal *et al.*, 2005). Cependant, tout comme pour les habitats de type industriels, Gator-Tech et les autres

3. www.openhab.org

4. www.eclipse.org/smarthome



(a) Gator-Tech



(b) Amiqua4home

Figure 2.2 : Schématisation des architectures utilisées par les habitats Gator-Tech et Amiqua4home

architectures basées composant souffrent du même inconvénient majeur, c'est-à-dire, le recours à un serveur central comme seule unité de calcul. Dans le cas présent, ce dernier provoque la création d'un goulot d'étranglement. En effet, un large flux de données qui transitent par le serveur peut entraîner un ralentissement de celui-ci. Il devient alors surchargé et l'assistance pour le résident n'est plus réalisée convenablement.

2.2.3 CASAS

Récemment, grâce aux avancées des technologies de communication sans-fil, de nouveaux types d'habitats intelligents ont émergés. Ainsi, des initiatives telles que CASAS (Cook *et al.*, 2013), ou encore celles proposées par Zhihua (2016) et Zhenyu *et al.* (2011) ont été proposées. Toutes s'articulent autour d'un réseau maillé ZigBee, une technologie de communication sans fil qui sera expliqué plus en détail en section 3.4.4. Bien qu'ils admettent des différences, ces trois habitats demeurent sensiblement identiques dans la conception de l'architecture qu'ils proposent. De ce fait, cette section ne traite exclusivement du cas de CASAS, puisque celui-ci reste le plus connus d'entre eux. En introduisant CASAS, Cook *et al.* (2013) voulaient principalement résoudre le problème du coût que représentent les habitats intelligents, mais également en faciliter leur installation. C'est ainsi que le concept d'habitat intelligent en boîte est né. Comme montré par la figure 2.3, l'architecture de CASAS se décompose en quatre composants principaux. Tout d'abord, il y a la couche physique qui contient le réseau maillé ZigBee. Dans le cas de cet habitat, il s'agit d'une topologie de réseau sans-fil où tous les nœuds, c'est-à-dire les capteurs et les effecteurs, sont connectés pair à pair et collaborent pour s'échanger des données. Le réseau maillé communique ensuite avec un service de

messagerie au travers un pont ZigBee. Ce dernier a pour but de transformer les données des capteurs en messages Extensible Messaging and Presence Protocol (XMPP) de plus haut niveau. Le service de messagerie étant de type *publish/subscribe*, il offre alors la possibilité à d'autres services de s'y connecter. C'est notamment le cas du service d'archivage. Ce dernier récupère, par l'intermédiaire du pont scribe, certains évènements qui se produisent dans l'habitat afin de les enregistrer dans une base de données d'archives. Finalement, les applications de reconnaissance et d'assistance exploitent les données du *middleware* en les récupérant *via* le pont applicatif.




Figure 2.3 : Schématisation de l'architecture utilisée par l'habitat CASAS.

Les habitats intelligents basés sur les réseaux maillés ZigBee sont des solutions réellement moins onéreuses que les autres types d'architectures d'habitats. En effet, Cook *et al.* (2013) rapportent un coût total estimé à 2 765 dollars US, soit presque 5 fois moins qu'un habitat industriel. Par ailleurs, puisque les habitats basés sur un

réseaux maillé reposent tous sur la technologie de communication sans-fil ZigBee, il semble relativement aisé d'y ajouter de nouveaux capteurs et notamment d'y intégrer des *wearable devices*. Cependant, l'inconvénient majeur du protocole ZigBee est que les signaux ne sont pas directement compatibles avec des systèmes évolués tels que les ordinateurs ou les téléphones intelligents. De plus, tous les *wearable devices* ne disposent pas toujours d'une connectivité ZigBee. En effet, la grande majorité d'entre eux ont plutôt adopté la technologie Bluetooth Low Energy (BLE) (Martin, 2014), qui est également devenue compatible avec la topologie réseau maillé récemment (Bluetooth, 2017).

Il apparaît donc clairement qu'une architecture adaptative pour l'intégration des *wearable devices* est nécessaire. Bien que les architectures basées sur un réseau maillé constituent un premier pas en ce sens, la variété des technologies de communication et des protocoles qu'elles peuvent exploiter n'est pas encore pleinement prise en compte dans leur conception.

2.3 LE PROCESSUS D'APPRENTISSAGE POUR RECONNAÎTRE DES ACTIVITÉS

Le processus d'apprentissage pour la reconnaissance d'activités est un ensemble d'étapes qu'il est généralement possible de réaliser pour reconnaître des activités. Tel qu'illustré par la figure 2.4, ce processus requiert des données initiales fournies par les capteurs ambiants ou portables. Celles-ci n'ont alors été soumises à aucun traitement en particulier, ce sont donc des données brutes. Principalement en fonction de la condition des capteurs et de la transmission des valeurs, les données obtenues peuvent se

retrouver altérées. Afin d'améliorer leur qualité, il est donc possible, dans un second temps, d'effectuer une étape de prétraitement. Ensuite, puisque les données renvoyées représentent un signal ayant une longueur potentiellement infinie, il est impératif de segmenter ce dernier en plusieurs fragments, sur chacun desquels, des propriétés discriminantes sont calculées. L'ensemble de celles-ci, une fois extraites, constitue alors une abstraction du fragment traité. Le signal fragmenté est donc réduit à un unique vecteur de caractéristiques pour chaque segment. Dans certains cas, il peut s'avérer que celui-ci contienne un nombre de propriétés suffisant pour impacter négativement la performance de la reconnaissance—auquel cas, une étape supplémentaire pour réduire la dimensionnalité du vecteur est requise. Cet ensemble de données est ensuite utilisé comme entrée d'un algorithme d'apprentissage qui, pour chacun des vecteurs réduits, retournera les noms des classes associées aux activités à reconnaître. Finalement, la dernière étape du processus consiste en une évaluation de la performance de la reconnaissance.




Figure 2.4 : Schématisation du processus d'apprentissage pour la reconnaissance d'activités.

2.3.1 LES ÉTAPES PRÉLIMINAIRES

Avant d'être en mesure d'utiliser les algorithmes d'apprentissage, il est nécessaire que les données brutes issues des capteurs passent par un ensemble d'étapes préliminaires pour être transformées en caractéristiques discriminantes. Ainsi, cette section va présenter les méthodes les plus utilisées en ce qui concerne le prétraitement et la segmentation des données, mais également l'extraction de caractéristiques et la réduction du nombre qui en est produit, c'est-à-dire la réduction de la dimensionnalité.

PRÉTRAITEMENT DES DONNÉES

Le prétraitement des données est la première étape du processus d'apprentissage pour la reconnaissance d'activités. En effet, après l'acquisition des valeurs renvoyées, autant par les capteurs ambiants que les capteurs portables présents au sein d'un environnement intelligent, plusieurs facteurs peuvent influencer sur la qualité de ces données. Par exemple, un mauvais fonctionnement du matériel ou un problème de transmission comme une latence réseau peuvent entraîner l'acquisition de données incohérentes, erronées ou encore partiellement manquantes. L'objectif de cette étape est donc d'améliorer les données récoltées en réduisant le bruit, ou en filtrant les éléments nuisibles, tout en essayant de conserver les caractéristiques dynamiques essentielles du signal.

Dans le cas où les données comprendraient des valeurs partiellement manquantes, plusieurs méthodes peuvent être employées pour pallier cette perte. Dans un premier temps, il est tout simplement possible d'ignorer les données incriminées. Néanmoins, cette méthode n'est pas pertinente lorsque l'absence d'information est très élevée. De ce

fait, il est possible de remplacer les valeurs manquantes pour un attribut donné grâce à une estimation qui peut être déterminée selon deux procédés différents. Le premier consiste à calculer la moyenne de toutes les valeurs non manquantes pour l'attribut en question. La seconde méthode implique que les données soient étiquetées et consiste à remplacer la valeur manquante d'un attribut par la moyenne des valeurs présentes qui appartiennent à la même classe celui-ci.

De plus, il est admis que les capteurs RFID et les accéléromètres sont connus pour être les deux types de capteurs (ambiant et portable) les plus sujets au bruit. Or, de nombreux travaux se basent sur l'exploitation de ceux-ci dans le but de reconnaître des activités (Ravi *et al.*, 2005; Stikic *et al.*, 2008; Buettner *et al.*, 2009; Khan, 2011; Mannini *et al.*, 2017). De ce fait, Wang *et al.* (2011) ont comparé quatre filtres différents ayant pour but de réduire le bruit dans les données générées par un accéléromètre, soit : un filtre médian (Huang *et al.*, 1979), un filtre passe-bas de type *Butterworth* (Butterworth, 1930), une transformée en ondelettes discrète spécifique (Discrete Wavelet Package Decomposition (DWPD)) (Mallat, 1989) et un filtre de Kalman (Welch et Bishop, 2006), où ce dernier s'est révélé comme le plus efficace. Abreu *et al.* (2014) ont, quant à eux, montré que le filtre de Kalman était également le plus performant pour réduire le bruit présent dans le leur système de localisation intérieure basé sur des capteurs RFID.

SEGMENTATION DES DONNÉES

Dans le processus d'apprentissage, la segmentation des données peut intervenir, soit après la première phase de prétraitement, soit directement sur les données brutes

si celles-ci ne sont pas altérées. Cette opération consiste à découper un signal donné en plusieurs fragments plus petits. En d'autres termes, le signal est morcelé en une séquence de segments qui sont délimités par un temps de départ et un temps d'arrivée. Du point de vue du traitement de signal, cette opération est appelée le fenêtrage. Ainsi, il est possible d'observer le signal d'origine $x(t)$ de longueur théoriquement infinie, sur une durée finie T en le multipliant par une fonction fenêtre d'observation $w(t)$ tel que,

$$x_w(t) = x(t) w(t), \quad 0 \leq t \leq T - 1. \quad (2.1)$$

En ce qui concerne la reconnaissance d'activités, il est possible de regrouper les techniques de segmentation en trois groupes distincts : la segmentation basée sur les activités, la segmentation basée sur des événements et la segmentation par fenêtre glissante (Banos *et al.*, 2014).

La segmentation basée sur les activités revient à partitionner le signal selon la détection d'un changement significatif correspondant à une activité. Un tel découpage peut-être réalisé grâce à l'analyse du domaine fréquentiel du signal ou de son énergie (Sekine *et al.*, 2000; Guenterberg *et al.*, 2009).

La segmentation basée sur les événements exploite, quant à elle, un découpage du signal selon la manifestation d'événements spécifiques. Par exemple, cette méthode est souvent utilisée dans la reconnaissance de la marche ou d'autres activités similaires comme courir, monter ou descendre des escaliers, *etc.* Puisque ces activités sont cycliques et requièrent des actions inévitables (*p. ex.*, le contact du pied sur le sol), il est

possible de segmenter le signal par l'analyse de l'accélération (Sant'Anna et Wickström, 2010), mais également en exploitant d'autres types de données comme celles issues de capteurs de pression (Crea *et al.*, 2012).

Enfin, la segmentation par fenêtre glissante peut se traduire comme étant la translation d'une fenêtre sur l'axe temporel du signal, où chaque déplacement de la fenêtre représente un segment. Une fenêtre est définie par une fonction mathématique, une taille ainsi qu'un pourcentage de superposition. En ce qui concerne ce dernier, si une fenêtre est définie comme ayant une taille de 100 secondes avec un pourcentage de superposition de 50%, le premier intervalle sera $[0, 100]$ tandis que le second sera $[50, 150]$ et ainsi de suite. Parmi les fonctions de fenêtrage les plus fréquemment utilisées, il est possible de mentionner, la fenêtre de Hamming ($w(t)_H$), celle de Kaiser ($w(t)_K$), de Hann ($w(t)_N$) ou encore la fenêtre de Blackman ($w(t)_B$) respectivement exprimées par :

$$w(t)_H = \begin{cases} 0.54 - 0.46 \cos\left(\frac{2\pi t}{T-1}\right), & \text{si } 0 \leq t \leq T-1 \\ 0, & \text{sinon.} \end{cases} \quad (2.2)$$

$$w(t)_K = \begin{cases} \frac{I_0\left[\alpha \sqrt{1 - \left(\frac{2t}{T-1} - 1\right)^2}\right]}{I_0[\alpha]}, & \text{si } 0 \leq t \leq T-1 \\ 0, & \text{sinon.} \end{cases} \quad (2.3)$$

$$w(t)_N = \begin{cases} 0.5 - 0.5 \cos\left(\frac{2\pi t}{T-1}\right), & \text{si } 0 \leq t \leq T-1 \\ 0, & \text{sinon.} \end{cases} \quad (2.4)$$

$$w(t)_B = \begin{cases} 0.42 - 0.5 \cos(\frac{2\pi t}{T-1}) + 0.08 \cos(\frac{4\pi t}{T-1}), & \text{si } 0 \leq t \leq T-1 \\ 0, & \text{sinon.} \end{cases} \quad (2.5)$$

où, I_0 est la fonction de Bessel modifiée d'ordre zéro, α est le paramètre réel non nul caractérisant la forme de la fenêtre et T est la taille de la fenêtre. Néanmoins, tous les paramètres impliqués dans le processus de la segmentation doivent être déterminés en fonction de la problématique, où l'objectif est de trouver le meilleur compromis entre la rapidité d'exécution et la performance de reconnaissance (Banos *et al.*, 2014).

EXTRACTION DE CARACTÉRISTIQUES

L'extraction de caractéristiques est une phase importante dans le processus d'apprentissage pour reconnaître des activités. L'objectif de cette opération consiste à produire un vecteur de caractéristiques discriminantes pour chaque fragment du signal généré, grâce à un certain nombre de fonctions mathématiques. Il existe deux principaux domaines auxquels appartiennent les différentes techniques d'extraction : le domaine temporel et le domaine fréquentiel (Huynh et Schiele, 2005; Figo *et al.*, 2010; Cleland *et al.*, 2013). Les caractéristiques issues du domaine temporel demeurent les plus simples à obtenir. Il est notamment possible d'y retrouver des métriques statistiques comme la moyenne, la variance, l'écart type, l'asymétrie ou encore le kurtosis (la courbure) du signal, mais également des métriques dites « enveloppe » comme la médiane, le minimum ou le maximum du signal. De plus, de nombreuses autres métriques temporelles peuvent être utilisées dans la reconnaissance d'activités, comme la corrélation entre

deux signaux ou encore le *zero crossing rate*—qui correspond au taux de changement de signe d'un signal. Les formules de l'asymétrie S , du kurtosis K et de la corrélation ρ de deux signaux n et n' sont respectivement données par :

$$S(n) = \frac{N}{(N-1)(N-2)} \cdot \left(\sum_{i=1}^N \frac{(n_i - \bar{n})^3}{\sigma_n^3} \right) \quad (2.6)$$

$$K(n) = \frac{N(N+1)}{(N-1)(N-2)(N-3)} \cdot \left(\sum_{i=1}^N \frac{(n_i - \bar{n})^4}{\sigma_n^4} - \frac{3(N-1)^2}{(N-2)(N-3)} \right) \quad (2.7)$$

$$\rho(n, n') = \frac{\text{cov}(n, n')}{\sigma_n \cdot \sigma_{n'}} \quad (2.8)$$

où N représente la taille d'un fragment du signal, n_i est le $i^{\text{ème}}$ élément du fragment, \bar{n} est la valeur moyenne du fragment et σ_n correspond à l'écart type du fragment.

D'autre part, afin d'exploiter des caractéristiques issues du domaine fréquentiel, il est nécessaire de réaliser un passage vers celui-ci, depuis le domaine temporel. Pour ce faire, il s'agit de calculer la transformée de Fourier discrète du signal. Dans la grande majorité des cas, c'est l'algorithme de la transformée de Fourier rapide (Fast Fourier Transform ou FFT) qui est utilisé à cet effet (Brigham et Morrow, 1967). Malgré sa popularité, il est également possible d'utiliser l'algorithme de Goertzel pour réaliser la transformation depuis le domaine temporel vers le domaine fréquentiel (Sysel et Rajmic, 2012). Dès lors, les caractéristiques fréquentielles qui peuvent être calculées sont, la composante continue (*DC Component*), l'énergie spectrale E et l'entropie H tel que,

$$E = \frac{1}{N} \cdot \left(\sum_{i=1}^N |n_i| \right) \quad (2.9)$$

$$H = - \sum_{i=1}^N P_i \ln P_i \quad (2.10)$$

où n représente un vecteur de nombres complexes de taille N issu de la FFT, n_i est le $i^{\text{ème}}$ élément du vecteur et P_i est la probabilité de n_i donnée par l'équation suivante :

$$P_i = \frac{n_i}{N - E} \quad (2.11)$$

En dernier lieu, Mitchell *et al.* (2013) ont proposé une méthode de reconnaissance d'activités qui repose sur l'analyse par ondelettes (Discrete Wavelet Transform ou DWT). À l'inverse de la transformée de Fourier, cette technique permet d'obtenir des caractéristiques à la fois issues du domaine temporel et fréquentiel, par décomposition d'un signal en un ensemble de coefficients d'ondelettes.

RÉDUCTION DE LA DIMENSIONNALITÉ

La dernière étape préliminaire concerne la réduction de la dimensionnalité du vecteur de caractéristiques. Cette étape est importante dans la mesure où elle permet de sélectionner l'ensemble des valeurs qui seront conservées pour pallier le *fléau de la dimension* (Bellman, 1957). Ce phénomène intervient lorsque la taille du vecteur de caractéristiques croît de manière conséquente. Les données peuvent alors se retrouver

isolées et deviennent éparées, ce qui a pour effet de dégrader l'efficacité de la reconnaissance d'activités. Ainsi, en réduisant la dimensionnalité de ces données, l'objectif est de conserver les caractéristiques pertinentes tout en minimisant la perte d'information. Bien que ce processus doive permettre une meilleure reconnaissance, l'exploitation d'un plus petit vecteur peut également induire un traitement postérieur plus rapide.

Actuellement, il existe une quantité importante de techniques de réduction de dimensionnalité. Par conséquent, Van Der Maaten *et al.* (2009) ont proposé une taxonomie dans laquelle ils recensent l'ensemble des méthodes existantes. En premier lieu, il est possible de retrouver des techniques de réduction de la dimensionnalité orientées vers la sélection de caractéristiques qui reposent sur des évaluations statistiques des données, comme la covariance ou l'entropie. L'avantage majeur de ces méthodes réside dans leur simplicité de mise en œuvre. D'autre part, bien qu'elle demeure une technique plus complexe, l'analyse par composantes principales (Principal Component Analysis ou PCA), a souvent été utilisée dans le domaine de la reconnaissance d'activités (He et Jin, 2009; Altun et Barshan, 2010; Chen *et al.*, 2012; Leightley *et al.*, 2013). Elle permet, de transformer des caractéristiques qui sont initialement corrélées en de nouvelles caractéristiques décorrélées les unes des autres, les composantes principales.

Le nombre de déclinaisons d'algorithmes de sélection de caractéristiques étant considérable, le choix quant à la méthode à adopter n'est pas trivial. En effet, celui-ci doit être fait en fonction de la problématique à traiter et l'algorithme adéquat est bien souvent déterminé de manière empirique.

2.3.2 LES ALGORITHMES D'APPRENTISSAGE

Dans la section précédente, les différents processus de prétraitement ont été présentés. Ces étapes sont importantes puisqu'elles permettent de préparer les données afin de raffiner leur qualité avant qu'elles soient utilisées par un algorithme d'apprentissage. Ainsi, reconnaître avec précision les activités d'un résident est l'objectif principal des habitats intelligents afin qu'ils puissent recevoir une assistance la plus adaptée possible. Par conséquent, de nombreuses méthodes algorithmiques issues du domaine de l'intelligence artificielle ont été proposées pour parvenir à reconnaître des activités. Cette section présente donc l'ensemble des différentes méthodes parmi les plus utilisées dans ce domaine.

Les algorithmes d'apprentissage, également qualifiés d'algorithmes de reconnaissance ou de classification, peuvent être décomposés en deux grandes familles : les méthodes supervisées et non supervisées. Un algorithme est dit supervisé si les données recueillies sont divisées en deux sous-ensembles respectivement appelés ensemble d'entraînement et de validation où les deux ensembles de données contiennent des instances étiquetées avec la classe correspondante à une activité donnée. À l'inverse, les algorithmes non supervisés ne requièrent pas l'étiquetage des données. Cependant, il est également possible de rencontrer, à plus faible mesure, des techniques d'apprentissage semi-supervisées qui combinent l'utilisation de données étiquetées et non-étiquetées lors la phase d'entraînement (Zhu, 2005; Chapelle *et al.*, 2006).

LES ALGORITHMES PROBABILISTES

Dans l'univers des algorithmes probabilistes, il est possible de retrouver méthodes bayésiennes qui constituent des méthodes supervisées probabilistes. Celles-ci s'articulent autour des réseaux bayésiens. Un réseau bayésien est défini par un graphe orienté acyclique dans lequel, chacun des nœuds (sommets) représente une variable aléatoire et chacune des arêtes correspond à la dépendance conditionnelle existante entre un ou plusieurs nœuds du graphe (Heckerman *et al.*, 1995). Pour appliquer ce principe dans un système de reconnaissance d'activités, il s'agit de considérer que les nœuds du graphe correspondent aux actions ou aux activités et que les arêtes sont les liens qui lient des actions aux activités. Ces actions peuvent être conjointes à plusieurs activités. Par conséquent, si la probabilité de chaque activité ainsi que les probabilités conditionnelles des nœuds sont connues, il est alors possible de mettre à jour la probabilité de chacune des activités en fonction des observations faites dans l'environnement.

De manière plus concrète, la figure 2.5 illustre l'exemple d'un système de reconnaissance s'appuyant sur un réseau bayésien. Celui-ci est en charge de reconnaître lorsqu'un résident est en train de réaliser trois activités dans la cuisine d'un environnement intelligent soit, « *faire du thé* » (A_1), « *faire du riz* » (A_2) et « *faire du café* » (A_3). Grâce à l'observation des habitudes de l'habitant, il est possible de définir les probabilités initiales des activités ainsi que les probabilités conditionnelles. Elles sont respectivement données dans la figure 2.5, au-dessus de chaque activité à reconnaître et sous chacune des actions nécessaires à leur réalisation. Ensuite, si l'évènement e_2 correspondant à l'action « *sortir le riz* » est observé, les probabilités de chaque activité

selon cet évènement $p(A_i|e_2)$ sont calculées en appliquant la formule de Bayes définie par :

$$p(A_i|e_n) = \frac{p(e_n|A_i) \times p(A_i)}{\sum_{j=1}^J p(e_n|A_j) \times p(A_j)} \quad (2.12)$$

où $p(A_i)$ est la probabilité initiale de l'activité A_i et $p(e_n|A_i)$ est la probabilités conditionnelles de l'activité A_i selon l'évènement e_n .

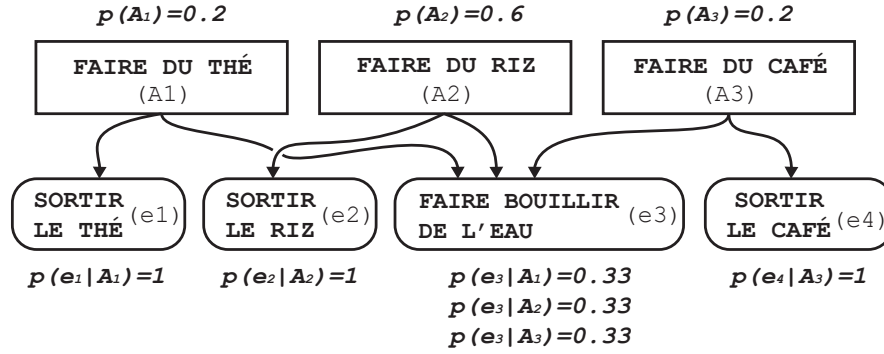


Figure 2.5 : Schématisation d'un exemple de réseau bayésien naïf.

Grâce aux données fournies par cet exemple, il est donc possible de réaliser l'application numérique suivante à l'aide de l'équation 2.12 :

$$\begin{aligned}
p(A_1|e_2) &= \frac{p(e_2|A_1) \times p(A_1)}{p(e_2|A_1) \times p(A_1) + p(e_2|A_2) \times p(A_2) + p(e_2|A_3) \times p(A_3)} \\
&= \frac{0 \times 0.2}{0 \times 0.2 + 1 \times 0.6 + 0 \times 0.2} = 0
\end{aligned}$$

$$\begin{aligned}
p(A_2|e_2) &= \frac{p(e_2|A_2) \times p(A_2)}{p(e_2|A_1) \times p(A_1) + p(e_2|A_2) \times p(A_2) + p(e_2|A_3) \times p(A_3)} \\
&= \frac{1 \times 0.6}{0 \times 0.2 + 1 \times 0.6 + 0 \times 0.2} = 1
\end{aligned}$$

$$\begin{aligned}
p(A_3|e_2) &= \frac{p(e_2|A_3) \times p(A_3)}{p(e_2|A_1) \times p(A_1) + p(e_2|A_2) \times p(A_2) + p(e_2|A_3) \times p(A_3)} \\
&= \frac{0 \times 0.2}{0 \times 0.2 + 1 \times 0.6 + 0 \times 0.2} = 0
\end{aligned}$$

Finalement, les probabilités sont mises à jour et il apparaît que l'activité « *faire du riz* » (A_2) est la seule activité possible puisque celle-ci admet une probabilité de 1 lorsque l'évènement « *sortir le riz* » (e_2) est observé. Le système conclut donc que le résident de l'habitat intelligent est en train de préparer une portion de riz.

Les principaux avantages dans l'utilisation des réseaux bayésiens sont, la simplicité de leur implémentation ainsi que leur performance, tant en termes de taux de reconnaissance dans le cas des activités au sein d'un habitat intelligent, qu'en termes de temps d'exécution et de consommation d'espace mémoire (Friedman *et al.*, 1997). Néanmoins, ceux-ci nécessitent de connaître l'ensemble des activités, des actions et des probabilités conditionnelles qui les relient pour fonctionner; ce qui constitue un inconvénient majeur, car ces informations ne sont pas toujours disponibles.

Les modèles de Markov cachés (Hidden Markov Models ou HMMs) ainsi que les champs aléatoires conditionnels (Conditional Random Fields ou CRFs) sont d'autres exemples d'algorithmes statistiques qui ont été utilisés pour la reconnaissance d'activités au sein des habitats intelligents (Oliver *et al.*, 2004; Nazerfard *et al.*, 2010; Van Kasteren *et al.*, 2011). Les HMMs peuvent être représentés comme des automates probabilistes à états finis dont l'évolution au cours du temps est entièrement déterminée par une probabilité initiale et des probabilités de transitions entre états. De plus, l'état du système, soit l'activité à reconnaître, n'est pas directement observable, mais caché par un processus d'observation. Autrement dit, au temps t , le système qui est dans l'état invisible q_t émet l'observation O_t . Ces observations sont, quant à elles, visibles et elles peuvent, par exemple, correspondre à la valeur d'un capteur. Tout comme pour les réseaux bayésiens, les HMMs offrent d'excellentes performances de reconnaissance et d'exécution. Néanmoins, la complexité de leur mise en place et de leur compréhension ainsi que la connaissance initiale requise pour leur fonctionnement sont autant de facteurs limitant leur utilisation à la reconnaissance d'un nombre très restreint d'activités.

Par ailleurs, les CRFs permettent, quant à eux, de modéliser les dépendances entre un ensemble d'observations réalisées sur une séquence et un ensemble d'étiquettes. En comparaison avec un HMM, un CRF ne repose pas sur l'hypothèse forte d'indépendance des observations entre elles, conditionnellement aux états associés (les activités). De plus, ils ne combinent pas de probabilités conditionnelles locales, évitant ainsi une estimation biaisée de ces probabilités si trop peu d'exemples étiquetés sont disponibles. Autrement dit, les CRFs permettent de limiter le nombre de paramètres initiaux requis dans la mise en place d'un HMM, offrant alors une généralisation du modèles de Markov.

LES ARBRES DE DÉCISION

Les arbres de décision appartiennent à la catégorie des méthodes d'apprentissage supervisées. Comme illustré par la figure 2.6, la classification des données est faite par une suite de choix logiques représentée sous forme d'un arbre, où chacun de ses nœuds possède un unique parent excepté le nœud racine. Ainsi, les feuilles de l'arbre correspondent aux classes des activités à reconnaître et les nœuds non terminaux sont des règles de classification qui doivent être vérifiées grâce aux attributs de la donnée qui est testée.

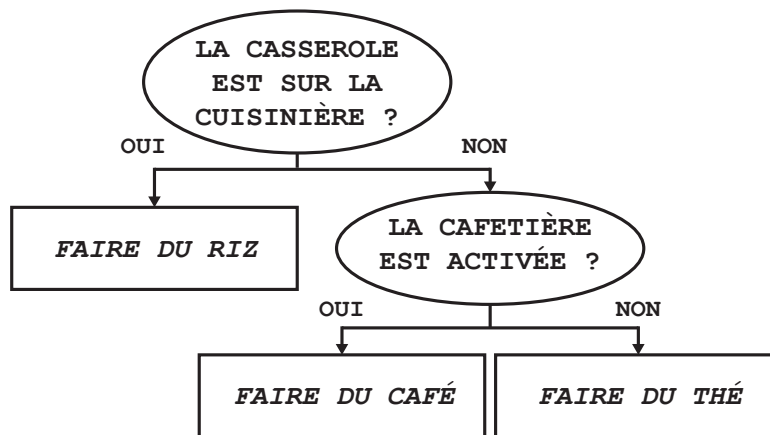


Figure 2.6 : Schématisation d'un exemple d'arbre de décision binaire.

Dans le domaine de la reconnaissance d'activités, les algorithmes d'arbres de décision qui sont les plus fréquemment utilisés sont, Iterative Dichotomiser 3 (ID3) ainsi que son extension, C4.5 (Quinlan Ross, 1993). Les principales différences entre ces deux algorithmes sont qu'à l'inverse d'ID3, C4.5 accepte les variables continues en plus des variables discrètes et ce dernier est également capable de gérer les données manquantes de façon automatique. Enfin, il permet de réduire le risque de sur-apprentissage, qui

est très élevé avec l'algorithme ID3, grâce à une technique de *pruning* (Bao et Intille, 2004; Ravi *et al.*, 2005; Tapia *et al.*, 2007). Ce phénomène intervient lorsque le modèle d'apprentissage est trop similaire aux données d'entraînement et donc plus suffisamment générique pour reconnaître correctement de nouvelles activités. Malgré ces différences, le fonctionnement de ces deux algorithmes reste très similaire. Pour chaque attribut de l'ensemble de données qui n'a pas déjà été traité, son entropie H (cf. équation (2.10)) est calculée. Ensuite, l'attribut ayant l'entropie la plus faible est sélectionné et une séparation des données est faite en fonction de celui-ci (p. ex. « *la casserole est sur la cuisinière* » ou « *la casserole n'est pas sur la cuisinière* »). Enfin, la structure finale de l'arbre est créée de manière réursive en ne considérant uniquement les attributs qui n'ont jamais été sélectionnés, pour chaque sous-ensemble de données. Ceci vient donc conclure la phase d'entraînement d'un arbre de décision. La phase de reconnaissance, quant à elle, ne nécessite qu'un simple parcours de l'arbre. Ainsi, en reprenant l'exemple de la figure 2.6—si les données de l'instance à reconnaître correspondent au positionnement de la casserole sur la cuisinière de l'habitat intelligent, alors l'activité réalisée par le résident est « *faire du riz* ».

L'utilisation des arbres de décision offre plusieurs avantages. Dans un premier temps, ceux-ci restent relativement simples à implémenter, mais surtout, ils offrent une très grande facilité de compréhension. De plus, ils ont démontré une excellente performance tant en termes de rapidité d'exécution qu'en termes de taux de reconnaissance (Bao et Intille, 2004). En revanche, ils se sont révélés beaucoup moins efficaces dans des systèmes impliquant la reconnaissance d'un très grand nombre d'activités parmi lesquelles certaines peuvent se ressembler. De plus, les arbres de décision concèdent deux

autres limites importantes qui sont, la nécessité d’avoir un très grand nombre de données pour être entraînés correctement et l’obligation de répéter la phase d’entraînement après chaque ajout d’une nouvelle activité ou après la modification des données d’une activité existante.

LE CLUSTERING

Les méthodes de *clustering* représentent une large partie des algorithmes d’apprentissage non-supervisés (Witten *et al.*, 2011). Le fonctionnement général de toutes les techniques de *clustering* existantes consiste en la division homogène d’un ensemble de données en différents *clusters* qui doivent partager des caractéristiques communes. Les *clusters* sont donc des sous-ensembles des données d’apprentissage. La séparation des données en *clusters* est réalisée, à la fois par minimisation de la distance intra-classe ; c’est-à-dire, la distance entre tous les éléments d’un même *cluster*, ainsi que par la maximisation de la distance inter-classe, qui correspond à la distance entre tous les *clusters*. Ensuite, pour chaque cluster, une donnée représentative lui est attribuée. En fonction de l’algorithme qui est employé, cette dernière peut être déterminée différemment. Dans certains cas, une nouvelle valeur (le barycentre) est calculée à l’aide des données déjà présentes dans le *cluster*. Dans d’autres cas, c’est une donnée existante qui sera élue comme la plus représentative pour chaque *cluster*. Un exemple d’une méthode de *clustering* utilisant le calcul des barycentres est illustré en figure 2.7

L’algorithme de *clustering* le plus utilisé dans le domaine de la reconnaissance d’activités est l’algorithme des *K*-moyennes (Messing *et al.*, 2009; Kovashka et Grauman,

2010). Cet algorithme requiert que le nombre total de *clusters* K soit fixé à l'avance. Ainsi, l'algorithme d'apprentissage commence par initialiser les barycentres, où la valeur qui leur est attribuée peut varier en fonction du problème à traiter. En effet, ceux-ci peuvent être initialisés à nul, avec des valeurs purement aléatoires ou encore avec des valeurs prises parmi les données existantes. Lorsque les barycentres sont définis, l'algorithme va, de manière itérative, commencer par calculer la distance de chaque instance de l'ensemble de données par rapport à chacun des K barycentres. Chacune d'elles sera alors associée à son barycentre le plus proche. L'étape suivante consiste à mettre à jour la valeur des barycentres en fonction des *clusters* qui se sont formés. Enfin, ce processus est répété jusqu'à l'obtention d'une convergence, c'est-à-dire, jusqu'à la stabilisation des valeurs des barycentres ; ce qui conduit à l'obtention du modèle d'apprentissage. Comme illustré dans l'exemple de la figure 2.7, ce modèle d'apprentissage admet trois *clusters*, où chacun d'eux correspond au regroupement des données selon les trois mêmes activités qui sont utilisées depuis le début de ce chapitre. Dès lors, la classification d'une nouvelle instance nécessite de calculer la distance entre cette dernière et tous les barycentres. La plus petite distance obtenue détermine donc à quelle classe d'activité cette nouvelle donnée appartient. Dans cet exemple, la nouvelle donnée correspond donc à l'activité « *faire du café* ».




Figure 2.7 : Schématisation d'un exemple d'algorithme de clustering.

Parmi toutes les mesures de distance qu'il est possible d'utiliser, celles qui sont les plus fréquemment utilisées dans l'algorithme des K -moyennes lorsque les données ont n dimensions sont, la distance Euclidienne D_e et la distance de Manhattan D_m , respectivement rappelées par les équations (2.13) et (2.14) tel que,

$$D_e = \sqrt{\sum_{i=1}^n (x_i - y_i)^2} \quad (2.13)$$

$$D_m = \sum_{i=1}^n |x_i - y_i| \quad (2.14)$$

Bien que le côté non-supervisé de ces méthodes constitue un avantage majeur dans leur utilisation pour reconnaître des activités, elles n'en demeurent pas moins dénuées d'inconvénients. En effet, le processus d'entraînement est souvent coûteux en termes de temps d'exécution et en termes de consommation de la mémoire. De plus,

le manque de flexibilité induit par la définition préalable du nombre de *clusters* est un inconvénient majeur pour un système de reconnaissance où le nombre d'activités demeure potentiellement infini. Pour combler ce dernier inconvénient, il est possible de recourir à l'algorithme Density-Based Spatial Clustering of Applications with Noise (DBSCAN), car son utilisation permet de s'affranchir d'une initialisation manuelle du nombre de clusters. Néanmoins, celui-ci éprouve des difficultés lorsqu'il s'agit de gérer des clusters ayant des densités différentes et ceci est fréquent dans le domaine de la reconnaissance d'activités. DBSCAN n'est alors pas toujours le meilleur compromis.

LES MACHINES À SUPPORT DE VECTEURS

Les machines à support de vecteurs (Support Vector Machine (SVM)) font partie des techniques d'apprentissage supervisées. L'objectif d'un SVM est de créer une séparation des données d'entraînement optimale par le biais d'un hyperplan. De ce fait, l'algorithme va chercher à maximiser la marge, c'est-à-dire, la distance entre l'hyperplan et les données les plus proches de celui-ci. Ces données sont les supports de vecteurs. La figure 2.8a montre un exemple de machine à support de vecteurs linéaire. En revanche, il est possible que dans certains cas, les données ne soient pas linéairement séparables, c'est-à-dire qu'aucun hyperplan de marge optimale n'existe. Pour pallier cela, il est possible d'utiliser une fonction de noyau (linéaire, quadratique, polynomiale, de base radiale gaussienne, sigmoïde, *etc.*) qui permet alors de convertir des données d'apprentissage en un ensemble de dimension supérieur, où il est possible de créer un hyperplan de marge optimale permettant de séparer les données, tel qu'illustré en

figure 2.8b. Afin d'identifier à quelle classe d'activité la nouvelle donnée appartient, le processus de reconnaissance va simplement calculer de quel côté de l'hyperplan celle-ci se situe. Ainsi, dans le cas de l'exemple proposé en figure 2.8a la nouvelle donnée est à droite de l'hyperplan, elle est donc identifiée comme l'activité « *faire du café* ».




Figure 2.8 : Schématisation d'un SVM linéaire ainsi que d'un SVM utilisant une fonction de noyau.

Les SVM sont souvent considérés comme des boîtes noires, car ils ne permettent pas l'extraction d'un modèle compréhensible, à l'inverse des arbres de décision, par exemple. Néanmoins, ils sont fréquemment utilisés dans le domaine de la reconnaissance d'activités pour plusieurs raisons (He et Jin, 2009; Anguita *et al.*, 2012). La première est qu'ils permettent d'obtenir des taux de reconnaissance très élevés. De plus, le processus de reconnaissance est très efficace en termes de consommation des ressources et peut donc facilement être réalisé sur des systèmes portables. Toutefois, les machines à support de vecteurs ne sont pas adaptées pour traiter un très gros volume de données lors du

processus d'apprentissage—ce dernier impliquant de lourds calculs pour construire le modèle.

LES RÉSEAUX DE NEURONES ARTIFICIELS

Les réseaux neurones artificiels (Artificial Neural Networks ou ANNs) sont des méthodes d'apprentissage qui sont supervisées. Elles visent à imiter la pensée humaine par la modélisation simplifiée des systèmes neuronaux du cerveau de l'Homme et des animaux. Les ANNs sont composés de plusieurs neurones connectés entre eux qui s'échangent des signaux (Witten *et al.*, 2011). Chaque neurone est composé d'un nombre n d'entrées synaptiques qui sont chacune associées à un poids (w). Celles-ci sont ensuite agglomérées en une seule donnée grâce à un additionneur. Cette valeur est alors passée à une fonction d'activation qui va, pour chacun des neurones, renvoyer un signal de sortie positif ou négatif en fonction d'un certain seuil. Ainsi, pour effectuer un apprentissage supervisé avec les réseaux de neurones, la valeur des poids associés à chacune des synapses doit être modifiée afin que l'erreur entre les sorties du réseau et l'étiquette de la donnée testée soit atténuée. Dès que tous les poids sont mis à jour, la construction du modèle d'apprentissage est terminée et le processus reconnaissance peut commencer. La figure 2.9 montre un exemple simplifié d'un perceptron multicouche, l'une des implémentations possibles des ANNs, permettant de reconnaître deux activités, « *faire du riz* » et « *faire du café* ». Dans cet exemple, les neurones d'entrée admettent les valeurs des capteurs de l'environnement intelligent et les neurones de sorties correspondent aux activités à reconnaître. Pour simplifier l'exemple, les valeurs de sorties sont exprimées

sous la forme de booléens, mais les ANNs expriment normalement les sorties sous la forme de probabilités. Par conséquent, c'est la probabilité la plus élevée qui détermine l'étiquette de la donnée testée. Dans ce cas, lorsque le placard est ouvert ; que de l'eau s'écoule du robinet ; que la plaque de cuisson avant-gauche est allumée ; que la casserole est sur la cuisinière et que la cafetière n'est pas allumée, l'activité prédite par cet ANN est « *faire du riz* ».




Figure 2.9 : Schématisation d'un exemple de réseau de neurones artificiels.

De nombreux travaux dans le domaine de la reconnaissance d'activités ont démontré la performance des ANNs ainsi que leur robustesse quant à l'exploitation de données fortement bruitées (Pärkkä *et al.*, 2006; Delachaux *et al.*, 2013). Néanmoins, ces techniques nécessitent un temps d'apprentissage considérable pouvant atteindre plusieurs jours. Ceci demeure un inconvénient majeur d'autant plus que ce processus doit être reproduit après chaque ajout d'une nouvelle activité ou après la modification d'une activité déjà existante. De plus, il est très facile, pour un système de reconnaissance basé sur un réseau neural, de tomber dans le sur-apprentissage.

Dans la dernière décennie, l'augmentation exponentielle de la puissance des appareils informatiques a permis de propulser l'utilisation des techniques d'apprentissage profond (deep learning) qui sont des applications particulières des ANNs traditionnels qui ont été présenté précédemment. Celles-ci ont démontré leur excellente performance de reconnaissance dans beaucoup de domaines, dont celui de la reconnaissance d'activités (Yang *et al.*, 2015; Li *et al.*, 2016; Wang *et al.*, 2018). Bien qu'il soit possible que les techniques d'apprentissage profond soient capables de traiter des données brutes directement, c'est-à-dire de se passer de toutes les étapes préliminaires pour la construction du modèle d'apprentissage, elles admettent encore de nombreux inconvénients additionnels à ceux des ANNs. En effet, les modèles sont souvent utilisés comme des boîtes noires, car lorsque les résultats obtenus ne sont pas satisfaisants, il est pratiquement impossible d'en expliquer les raisons et surtout de trouver des solutions pour remédier au problème. De plus, ces techniques requièrent un volume conséquent de données pour être entraînées correctement et ainsi, obtenir un modèle générique et réutilisable.

2.3.3 LA MESURE DE LA PERFORMANCE

L'étape finale du processus d'apprentissage pour la reconnaissance d'activités consiste en une évaluation de la performance du système. Pour ce faire, il existe de nombreuses métriques qui s'appuient sur l'utilisation d'une matrice de confusion (Fawcett, 2006). Cette dernière permet l'identification de la relation qui lie la classe actuelle d'un enregistrement et celle qui est prédite par l'algorithme d'apprentissage. Par exemple, la matrice de confusion retournée par l'un de ces algorithmes dans le cas d'une reconnaissance binaire est donnée par le tableau 2.1. Lorsqu'une instance est positive et qu'elle est

prédite comme positive, alors il s'agit d'un vrai positif (*VP*), sinon c'est un faux négatif (*FN*). Dans le cas contraire, si l'instance est négative, et qu'elle est prédite comme positive, alors s'agit d'un vrai négatif (*VN*), sinon c'est un faux positif (*FP*).

Tableau 2.1 : Matrice de confusion d'un système de reconnaissance binaire.

		classe prédite	
		oui	non
classe actuelle	oui	<i>VP</i>	<i>FN</i>
	non	<i>FP</i>	<i>VN</i>

Parmi l'ensemble des métriques permettant d'évaluer la performance d'un algorithme d'apprentissage, la mesure de la justesse est la plus fréquemment utilisée, du fait de sa simplicité. Elle permet de déterminer le ratio entre le nombre de prédictions correctement réalisées et le nombre total de cas tel que,

$$justesse = \frac{VP + VN}{VP + FP + VN + FN} \quad (2.15)$$

Néanmoins, malgré sa popularité, la justesse ne permet pas d'évaluer avec robustesse la qualité des prédictions. En effet, cette dernière ne prend pas en considération les prédictions qui peuvent être faites par chance. Par conséquent, une bonne justesse n'implique pas nécessairement une bonne performance de reconnaissance. C'est le phénomène du *paradoxe de la justesse*. Pour tenir compte de cet effet de bord souvent négligé, d'autres métriques comme la Kappa de Cohen (*k*) ou la *F-Mesure* doivent être calculées (Ben-David, 2007). La première est exprimée par :

$$k = \frac{P_o - P_e}{1 - P_e} \quad (2.16)$$

où P_o et P_e sont respectivement, les probabilités observées, c'est-à-dire le taux de succès obtenu par l'algorithme ; et les probabilités espérées, c'est-à-dire le taux de succès hypothétique de l'algorithme. La relation (2.17) permet, quant à elle, d'obtenir la F-mesure, tel que,

$$F\text{-Mesure} = 2 \cdot \frac{\text{précision} \cdot \text{rappel}}{\text{précision} + \text{rappel}} \quad (2.17)$$

où la *précision* et le *rappel* sont respectivement donnés par les équations (2.18) et (2.19) tel que,

$$\text{précision} = \frac{VP}{VP + FP} \quad (2.18)$$

$$\text{rappel} = \frac{VP}{VP + FN} \quad (2.19)$$

2.4 CONCLUSION

Dans un premier temps, ce chapitre s'est intéressé aux habitats intelligents existants qui ont été regroupés en trois catégories. Premièrement, les habitats intelligents académiques LIARA et le laboratoire DOMUS sont deux architectures qui reposent sur des technologies héritées du milieu industriel. Ces deux habitats, dont le coût total est très dispendieux, ont démontré une faiblesse en termes d'évolutivité et, par consé-

quent, l'absence d'une quelconque solution pour y intégrer facilement des *wearable devices*. Ensuite, les architectures d'habitats basés composants comme Gator-Tech ou Amigual4home ont répondu à cette problématique, car elles se sont révélées beaucoup plus flexibles quant à l'intégration de nouveaux composants matériels qu'ils soient de type ambiant ou portable. Néanmoins, la surcharge du serveur central pouvant être occasionnée par un grand nombre de flux de données n'en fait pas pour autant la solution idéale. Enfin, les architectures basées sur un réseau maillé, sont apparues comme les plus avancées en terme de flexibilité pour y intégrer des *wearable devices* malgré le support de la technologie de communication ZigBee uniquement.

Dans sa deuxième partie, ce chapitre a présenté plus en détails l'ensemble des étapes nécessaires pour réaliser le processus d'apprentissage pour reconnaître des activités. Les différentes techniques permettant de raffiner la qualité des données brutes renvoyées par les différemment capteurs et qui constituent la première phase du processus ont été exposés. Ensuite, les algorithmes de d'apprentissage les plus utilisés dans le domaine de la reconnaissance d'activités ont été examinés. Finalement, ce chapitre s'est achevé par la description des différentes méthodes permettant d'évaluer la performance de ces algorithmes et de la qualité intrinsèque de la reconnaissance d'activités.

CHAPITRE III

LES WEARABLE DEVICES AU SEIN DES HABITATS INTELLIGENTS

3.1 INTRODUCTION

Dans le chapitre précédent, le processus d'apprentissage pour la reconnaissance d'activités a été présenté dans un cas d'application générique. De nombreuses étapes, depuis l'obtention des données brutes jusqu'à la classification des activités à reconnaître, y ont été détaillées. Néanmoins, dans un contexte d'utilisation avec des *wearable devices*, la manière dont ces données sont acquises n'a, quant à elle, pas été mentionnée. De plus, l'adaptation de ce processus avec ces dispositifs fait intervenir une étape supplémentaire de transmission des données. Ce chapitre commence par définir la notion de *wearable devices*, puis il traite plus en détail des composants matériels et logiciels qui sont plus spécifiques dans l'utilisation de ces dispositifs au sein des habitats intelligents.

3.2 DÉFINITIONS

Selon le rapport publié par l'International Telecommunication Union (2012), l'internet des objets (Internet of Things ou IoT) représente une « infrastructure mondiale pour la société de l'information, qui permet de disposer de services évolués en interconnectant des objets (physiques ou virtuels) grâce aux technologies de l'information et de la communication interopérables existantes ou en évolution ». Ainsi, d'un point de vue conceptuel, l'IoT caractérise des objets physiques connectés ayant leur propre identité numérique et la capacité de communiquer les uns avec les autres. Ce réseau

crée en quelque sorte une passerelle entre le monde physique et le monde virtuel. En d'autres termes, il s'agit de fournir une identification numérique directe et normalisée (adresse IP, protocoles de communication, *etc.*) d'un objet physique grâce à un système de communication sans-fil qui peut être du Bluetooth ou encore du Wi-Fi.

Par conséquent, les *wearable devices* appartiennent aux objets connectés, puisqu'ils se caractérisent plus particulièrement comme une technologie qui embarque des capteurs et qui est disposée directement sur le corps humain. Godfrey *et al.* (2018) ont identifié deux types de *wearable devices* : les dispositifs autonomes (*p. ex.* les moniteurs d'activités physiques) et les dispositifs de mesure (*p. ex.* un moniteur de fréquence cardiaque porté sur la poitrine). Les dispositifs autonomes permettent de réaliser différents traitements, plus ou moins complexes, dont les résultats sont ensuite communiqués à d'autres appareils, tandis que les dispositifs de mesure ont, quant à eux, pour seul objectif de transférer les informations du capteur vers un serveur, par exemple.

Les principaux avantages offerts par les *wearable devices*, comme leur taille, leur faible prix ou leur facilité d'utilisation, ont favorisé leur usage dans différents domaines de recherche tels que la surveillance des activités physiques et sportives, la surveillance en continu de la santé ou encore la reconnaissance de gestes, d'activités ou de chutes. (Seon-Woo Lee et Mase, 2002; Istepanian *et al.*, 2011; Garcia-Ceja *et al.*, 2014; Bayat *et al.*, 2014; Yuan Jie Fan *et al.*, 2014; Gao *et al.*, 2014; Nielsen, 2014; Adib *et al.*, 2015; Davis *et al.*, 2016; Khan *et al.*, 2016; Chapron *et al.*, 2018).

3.3 LES CAPTEURS

Pour réaliser le processus d'apprentissage permettant de mettre en place une reconnaissance, la première étape consiste à récolter des données brutes qui sont produites par des capteurs. Cependant, puisqu'il en existe une grande diversité, il semble nécessaire d'identifier ceux qui sont les plus adéquats pour être proposés en tant que *wearable devices*. Pour ce faire, cette section présente, en se basant sur la taxonomie d'Acampora *et al.* (2013), les capteurs parmi ceux qui sont les plus utilisés dans ce domaine d'application.

3.3.1 LES CAPTEURS DE MOUVEMENTS

Les centrales inertielle (Inertial Measurement Units ou IMUs) sont les capteurs de mouvement qui sont le plus fréquemment implantés dans les *wearable devices* de par leur simplicité d'utilisation. Celles-ci peuvent comporter d'un à trois types de capteurs différents : les accéléromètres, les gyroscopes et les magnétomètres. Ils permettent de mesurer respectivement l'accélération linéaire, la vitesse angulaire et l'intensité du champ magnétique que subissent les objets auxquels ils sont fixés, grâce à un maximum de trois axes orthogonaux (x , y et z). L'adoption de ces capteurs a permis de nombreuses applications concrètes, telles que la reconnaissance de chutes chez les personnes âgées, l'identification de l'orientation du corps, la réadaptation, ainsi que la reconnaissance d'activités quotidiennes (Seon-Woo Lee et Mase, 2002; Garcia-Ceja *et al.*, 2014; Bayat *et al.*, 2014; Gao *et al.*, 2014; Davis *et al.*, 2016; Chapron *et al.*, 2018).

3.3.2 LES CAPTEURS PHYSIOLOGIQUES

Grâce aux progrès technologiques et plus particulièrement à la miniaturisation de l'électronique, de nouveaux types de capteurs, jusqu'alors réservés au domaine médical, ont pu être utilisés pour récolter les données physiologiques des utilisateurs, sans pour autant recourir aux services spécialisés d'un hôpital. Cependant, certaines techniques sont encore considérées comme complexes et intrusives à la fois. C'est, par exemple, le cas de l'électroencéphalogramme (EEG) qui demeure encore rarement exploité. Ce capteur physiologique permet d'obtenir la représentation de l'activité électrique du cerveau par l'intermédiaire d'électrodes disposées sur le crâne d'un individu. Néanmoins, plusieurs autres capteurs physiologiques ont, quant à eux, été très largement utilisés, et ce, dans de nombreux domaines de recherche. Parmi ceux-ci, il est possible de mentionner les capteurs qui permettent l'acquisition de l'électrocardiogramme (ECG), c'est-à-dire, la représentation graphique de l'activité électrique du cœur ; de l'électromyogramme (EMG), soit l'activité électrique produite par les muscles ; de capteurs mesurant la glycémie, qui indique le taux de concentration de glucose dans le sang, ou de la Saturation Pulsée en Oxygène (SPO₂), qui désigne le taux de saturation du sang en oxygène. Au sein des habitats intelligents, l'intégration de ces capteurs dans des *wearable devices* a principalement permis de proposer de nouvelles techniques pour la réhabilitation (Yuan Jie Fan *et al.*, 2014), la reconnaissance de gestes (Jung *et al.*, 2015; Benatti *et al.*, 2015; Tavakoli *et al.*, 2018) et la surveillance en continu de la santé des résidents pour détecter de possibles maladies (Istepanian *et al.*, 2011; Adib *et al.*, 2015; Khan *et al.*, 2016).

3.3.3 LES CAPTEURS DE COURBURE ET DE FORCE

Certains dispositifs considérés comme des *wearable devices* tels que les gants présentés par Sanford *et al.* (2015) et Zheng *et al.* (2016) ainsi que les chaussures conçues par Bamberg *et al.* (2008) et Bae et Tomizuka (2013), ont nécessité l'utilisation de capteurs de courbure (*flex sensors*) et de force (Force Sensitive Resistors ou FSRs). Ces capteurs fonctionnent grâce à des résistances dont la valeur change respectivement en fonction de la courbe qui est donnée au capteur ou de la pression qui est appliquée sur la surface de contact. Ainsi, comme illustré par ces différentes recherches, ces capteurs se sont montrés utiles dans certaines applications de réadaptation et de reconnaissance de gestes et d'activités. La figure 3.1 montre respectivement un capteur de courbure (3.1a) ainsi qu'un capteur de force (3.1b).



(a) Capteur de courbure



(b) Capteur de force (FSR)

Figure 3.1 : Exemples de capteurs de courbure (a) et de force (b).

3.3.4 LES CAPTEURS ENVIRONNEMENTAUX

Les capteurs environnementaux comportent principalement les capteurs de pression barométrique, d'humidité, de température et de dioxyde de carbone (CO₂). Ils sont principalement utilisés pour fournir des informations relatives à l'environnement proche des utilisateurs de *wearable devices*. Ainsi, les données produites par ce type de capteur peuvent être utilisées pour identifier le contexte d'utilisation dans lequel leurs porteurs évoluent et par conséquent, renforcer les analyses réalisées grâce aux autres capteurs (Acampora *et al.*, 2013). Par ailleurs, certains capteurs d'humidité et de température ont également été utilisés pour fournir des informations nécessaires à la surveillance de l'état de santé des utilisateurs des *wearable devices* (Anliker *et al.*, 2004).

3.4 LES TECHNOLOGIES DE COMMUNICATION SANS-FIL

Lorsqu'il est appliqué à des *wearable devices*, le processus d'apprentissage nécessite une étape supplémentaire qui est la transmission de données. Ces dernières peuvent être les données brutes, les caractéristiques ou les décisions qui sont émises en sortie de l'algorithme d'apprentissage. En fonction des cas et des capteurs que peut comporter le dispositif, la fréquence d'émission ainsi que le poids des données à transmettre peut fortement varier. Ainsi, il est nécessaire de choisir une technologie de communication sans-fil adéquate pour chaque situation. Cette section va donc s'intéresser à celles qui sont les plus communément utilisées par les *wearable devices* existants.

3.4.1 LES TOPOLOGIES DES RÉSEAUX

Avant d’entrer dans le détail des technologies de communication utilisées par les *wearable devices*, il est important de commencer par énoncer les topologies de réseaux existantes dans le domaine du sans-fil. En effet, elles jouent un rôle important dans le bon fonctionnement de la communication réseau et l’identification de leur différentes caractéristiques va permettre, *a posteriori*, de mieux cibler les besoins pour le développement de nouveaux systèmes. D’après Tanenbaum et Wetherall (2010), les topologies les plus fréquemment mises en place dans un contexte sans-fil sont :

- La **diffusion** (*broadcast*) (figure 3.2a) où un message est envoyé par un nœud émetteur à tous les nœuds récepteurs du réseau qui sont à sa portée. Le canal de communication est unidirectionnel et aucun accusé de réception n’est transmis au nœud émetteur depuis les nœuds récepteurs.
- Les **réseaux en étoile** (figure 3.2b) admettent un nœud émetteur-récepteur central qui communique, à travers plusieurs canaux bidirectionnels, avec plusieurs autres nœuds émetteurs-récepteurs périphériques. Ces émetteurs-récepteurs périphériques ne peuvent pas communiquer directement les uns avec les autres.
- Les **réseaux pair-à-pair (Peer-to-Peer ou P2P)** permettent à deux nœuds émetteurs-récepteurs, reliés par un canal de communication bidirectionnel, d’échanger des données dans les deux sens, tel qu’illustré par la figure 3.2c.
- Les **réseaux maillés** (figure 3.2d) permettent l’échange de données entre n’importe quels nœuds du réseau sans passer par un nœud central. La communication

est bidirectionnelle et chaque nœud peut-être relié à plusieurs autres nœud qui composent le réseau.

- Le **mode scan** (figure 3.2e) permet à un nœud central de fonctionner en mode réception, c'est-à-dire, en attente de recevoir un signal provenant de n'importe quel nœud émetteur qui est à sa portée. La communication entre les deux nœuds est unidirectionnelle et se fait du nœud émetteur vers le nœud central.




Figure 3.2 : Représentation des topologies réseaux pour les technologies de communication sans-fil.

3.4.2 WI-FI

Le Wi-Fi, régi par le standard IEEE 802.11⁵, est probablement la technologie de communication sans-fil la plus connue, car nous l'utilisons massivement depuis deux décennies. En constante amélioration, chaque génération du standard a apporté aussi bien des vitesses plus rapides et une latence réduite, qu'une meilleure expérience utilisateur dans une multitude d'environnements et avec divers types de périphériques. Toutes utilisations confondues, le standard qui est actuellement le plus utilisé est le Wi-Fi 802.11ac. Bien qu'il offre des vitesses de transfert de données à haut débit (de 400 Mbit/s à 2.6 Gbit/s), sa portée reste dans la moyenne de celles proposées par d'autres technologies, soit plusieurs dizaines de mètres. Néanmoins, dans le contexte des *wearable devices*, le standard 802.11n sur la bande de Fréquence 2.4GHz, qui est le plus utilisé. Bien que celui-ci permette d'obtenir une portée plus élevée de quelques dizaines de mètres, les vitesses de transfert de données demeurent plus faibles (de 72 à 288 Mbit/s). Par ailleurs, le plus gros inconvénient de cette technologie reste sa forte consommation énergétique, ce qui est un facteur extrêmement limitant pour les objets connectés (IoT), parmi lesquels se retrouvent les *wearable devices*.

Dans un futur proche, les évolutions prévues dans les standards 802.11ah et 802.11ax vont principalement se concentrer sur l'amélioration de la consommation énergétique afin que l'utilisation du Wi-Fi devienne adaptée pour l'IoT. Néanmoins, la contrepartie de cette évolution est l'impact sur la vitesse de transfert de données, qui va alors, devenir beaucoup plus faible (8 Mbit/s) (Sun *et al.*, 2013).

5. <https://goo.gl/X9WKyx>

3.4.3 BLUETOOTH LOW ENERGY (BLE)

Le BLE⁶ a été lancé en 2010 dans le cadre de la spécification du Bluetooth 4.0. Bien souvent, il est considéré comme une version plus légère et plus optimisée du Bluetooth classique (versions 1 à 3), mais en réalité, le BLE présente une conception totalement différente. En effet, ce dernier a été pensé pour être une technologie de communication proposant une consommation d'énergie très faible, spécifiquement optimisée pour pouvoir offrir un coût réduit, une faible bande passante, ainsi qu'une complexité moindre. En comparaison aux autres technologies de communication sans-fil à faible consommation, le BLE a connu une adoption très rapide principalement grâce à la croissance phénoménale des téléphones intelligents et plus généralement de l'informatique mobile. Ainsi, les leaders de l'industrie mobile comme Apple ou Samsung ont favorisé le large déploiement de cette technologie qui est aujourd'hui, la technologie de communication la plus utilisée par les *wearable devices* (Gomez *et al.*, 2012).

D'autre part, avec l'arrivée des premiers appareils supportant la version 5 du Bluetooth, cette technologie devient la seule à supporter, intuitivement, l'intégralité des topologies réseaux présentées dans la section 3.4.1. En effet, en plus d'offrir un débit et une portée deux fois supérieurs à celui de la quatrième version, soit 2 Mbit/s et 250 mètres respectivement, cette nouvelle spécification intègre également la nouvelle norme : « Bluetooth Mesh 1.0 », qui va permettre la mise en place d'un réseau maillé⁷. Cependant, il ne sera pas possible de tirer profit de tous ces nouveaux avantages en même

6. <https://www.bluetooth.com/specifications>

7. <https://www.bluetooth.com/specifications/mesh-specifications>

temps, puisque cette cinquième version permettra deux modes de fonctionnement : haut débit ou longue portée. Ainsi, dans le premier cas, la vitesse de transfert sera favorisée au profit de la portée et inversement, ceci dans le but de continuer les efforts pour la réduction de la consommation d'énergie tout en améliorant les capacités.

3.4.4 ZIGBEE

La technologie ZigBee a été développée dans les années 1990 et avec l'avènement des objets connectés, elle est devenue l'une des technologies de communication parmi les plus utilisées. En comparaison avec le Wi-Fi, le ZigBee admet l'avantage de ne consommer que peu d'énergie. De plus, le standard IEEE 802.15.4⁸, qui régit cette technologie, indique que le ZigBee peut offrir une portée de plusieurs kilomètres, en fonction de la puissance de l'émetteur et de certaines caractéristiques environnementales.

Initialement, le ZigBee a été introduit pour répondre à des problématiques liées à l'hétérogénéité de l'IoT (Rahmani *et al.*, 2015; Cho *et al.*, 2013) et par extension, des technologies présentes au sein des habitats intelligents (Hui *et al.*, 2017). ZigBee permet de s'appuyer sur la conception d'une topologie de réseau maillé (*mesh*). De ce fait, certains *wearable devices* (Cruz *et al.*, 2018) et habitats intelligents (Cook *et al.*, 2013) ont vite adopté cette technologie, ce qui a, par exemple, permis à Cook *et al.* (2013), d'unifier et de simplifier la communication entre tous les capteurs présents dans l'habitat CASAS.

8. <https://goo.gl/X9WKyx>

3.4.5 LA COMMUNICATION EN CHAMP PROCHE

La communication en champ proche (Near Field Communication ou NFC) est une technologie de communication sans-fil à faible consommation et de courte portée, permettant l'échange d'informations entre des périphériques jusqu'à une distance de l'ordre du centimètre. L'avantage principal de cette technologie est que les périphériques NFC passifs, par exemple, les cartes de crédit, ne requièrent aucune alimentation. Ils deviennent actifs uniquement lorsqu'ils entrent dans le champ proche d'un périphérique qui est alimenté (*p. ex.* un lecteur).

Cette technologie de communication s'est principalement popularisée grâce aux méthodes de paiement sans contact (Ondrus et Pigneur, 2007), mais elle a également été utilisée dans plusieurs recherches relatives aux environnements intelligents. Par exemple, Pering *et al.* (2007) ont proposé un système de reconnaissance de gestes qui exploite le NFC d'un téléphone intelligent. Aussi, Chang *et al.* (2009) ont proposé une architecture pour l'automatisation du contrôle des installations électriques d'une maison, grâce à un système de reconnaissance d'utilisateurs de téléphones intelligents qui s'appuie principalement sur une détection d'appareils NFC présents dans l'environnement.

La limitation de cette technologie en termes de distance ne fait pas du NFC un concurrent direct du BLE ou du ZigBee. Son adoption concerne plutôt un marché de niche et il est préférable de le considérer comme complémentaire aux autres technologies de communication sans-fil présentées dans ce chapitre.

3.4.6 BILAN DES TECHNOLOGIES DE COMMUNICATION SANS-FIL

Dans cette section, les technologies de communications sans-fil les plus utilisées par les *wearable devices* ont été présentées. Puisqu'elles admettent des caractéristiques différentes, il convient donc d'en proposer une synthèse. Pour ce faire, le tableau 3.1 illustre les différences techniques pertinentes pour ces technologies. La consommation énergétique est identifiée, pour chacune d'elles, par les valeurs théoriques de la consommation moyenne ainsi que du pic de consommation, c'est-à-dire, la valeur maximum de l'intensité du courant. De plus, la latence théorique y est également proposée. Puisque cette dernière caractéristique permet de mesurer le temps nécessaire à la transmission d'un signal entre un émetteur et son récepteur, elle aura donc un impact significatif sur la consommation énergétique. En effet, une forte latence va permettre de consommer moins d'énergie et inversement dans le cas d'une latence faible.

Tableau 3.1 : Caractéristiques des différentes technologies de communication sans-fil employées par les *wearable devices*

	Portée	Débit	Latence	Pic de consommation	Consommation moyenne
Wi-Fi (802.11n)	70 m	150 - 600 MB/s	$O(1\text{ ms})$	150 mA	100 mA
Wi-Fi (802.11ac)	35 m	433 - 2600 MB/s	$O(1\text{ ms})$	150 mA	100 mA
BLE	250 m	1 - 2 MB/s	$O(1\text{ ms})$	15 mA	25 μA
ZigBee	> 1 km	250 kB/s	$O(1\text{ s})$	30 mA	30 mA
NFC	0.1 m	400 kB/s	$O(1\text{ s})$	50 mA	50 mA

Dans le vaste monde des technologies sans-fil et plus particulièrement celles à faible consommation d'énergie, seules quelques-unes d'entre elles se sont popularisées avec le développement de l'IoT et des *wearable devices*. Parmi celles-ci, il est possible de retrouver le Wi-Fi, le BLE, le ZigBee et le NFC. Bien que chacune d'elles puisse être utilisée avec ces dispositifs ayant une autonomie de fonctionnement limitée, elles admettent des capacités de portée, de débit et de robustesse différentes. Ces variations de performances impliquent que chaque méthode de communication possède un cas d'application qui lui est propre. Le choix de la technologie à adopter dans le processus de conception de *wearable devices* est donc crucial et doit être effectué rigoureusement en fonction de l'utilisation qui doit en être faite.

3.5 LES ÉCHANGES DE DONNÉES

Dans la section précédente, les différentes technologies de communication sans-fil ont été présentées. Ces différentes technologies constituent la couche matérielle du modèle de communication réseau. Par conséquent, cette section s'intéresse plus en détail aux différents protocoles de communication appartenant, quant à eux, aux couches hautes de ce même modèle de communication et qui sont les plus utilisés dans le contexte des réseaux capteurs sans-fil.

3.5.1 LE MODÈLE *PUBLISH/SUBSCRIBE*

Depuis l'arrivée des habitats intelligents, certaines architectures comme celle proposée pour CASAS (Cook *et al.*, 2013) ont adopté le modèle *publish/subscribe* pour l'ensemble de leurs réseaux de capteurs. Depuis, plusieurs travaux se sont principalement

intéressés à l'utilisation de ce modèle pour l'intégration de l'IoT au sein de ces habitats (Lee *et al.*, 2014; Upadhyay *et al.*, 2016; Van Den Bossche *et al.*, 2018).

Le modèle *publish/subscribe* est une alternative au modèle client/serveur traditionnel où un client communique directement avec le serveur. Dans ce modèle, il est possible de distinguer deux types de clients : ceux qui envoient des messages, les *publishers* et ceux qui les reçoivent, les *subscribers*. Dans une vaste majorité des utilisations de ce modèle, les *publishers* et les *subscribers* n'échangent jamais directement et il ne savent pas que l'autre existe physiquement. Le lien entre eux est fait par l'intermédiaire d'un troisième composant, le *broker*. Son rôle est de filter les messages entrant et de les redistribuer correctement aux différents *subscribers* comme illustré par la figure 3.3. L'avantage principal du modèle *publish/subscribe* est son élasticité. En effet, il est assez simple de voir comment il est possible de paralléliser les opérations exécutées par le *broker*. De plus, les messages peuvent être gérés comme des événements qu'il ne restera alors qu'à intercepter.




Figure 3.3 : Illustration du fonctionnement du modèle *publish/subscribe*.

Le modèle *publish/subscribe* connaît de nombreuses implémentations parmi lesquelles il est possible de retrouver Advanced Message Queuing Protocol (AMQP) (Vinoski, 2006), XMPP (Saint-Andre, 2011), RabbitMQ (Dossot, 2014) et ZéroMQ (Hintjens, 2013). Cependant, Message Queuing Telemetry Transport (MQTT) est la plus connue d'entre elles (Hunkeler *et al.*, 2008). En effet, grâce à sa portabilité⁹ et sa faible consommation de ressources (débit, mémoire et consommation d'énergie), elle demeure une excellente solution pour l'échange de données dans le domaine de l'IoT, où la puissance des dispositifs reste encore relativement limitée. En plus des avantages offerts par le modèle *publish/subscribe*, MQTT propose la définition de trois différents niveaux de qualité de service (Quality of Service ou QoS) : Le message est distribué une fois tout au plus, ou n'est pas distribué du tout ; le message est toujours distribué au moins une fois ou le message est toujours distribué une seule fois. Ceux-ci permettent donc une plus grande flexibilité en ce qui concerne le niveau de fiabilité requis par le système ; c'est-à-dire, la garantie que les messages sont, ou non, correctement envoyés et reçus. Aussi, dans son objectif de demeurer une solution légère, MQTT permet d'avoir recours à une option de sécurité relativement simple. Cette dernière consiste en une authentification des clients auprès du *broker* via un nom d'utilisateur et un mot de passe. Néanmoins, plusieurs couches de sécurité supplémentaires peuvent y être ajoutées (utilisation d'un réseau privé virtuel (Virtual Private Network ou VPN) ou le chiffrement des échanges de messages par SSL/TLS, *etc.*)

9. <https://github.com/mqtt/mqtt.github.io/wiki/libraries>

3.5.2 LE CAS SPÉCIFIQUE DU BLE

D'après le rapport publié par ON World Inc. (2017), le BLE serait la technologie de communication sans-fil la plus utilisée dans le domaine de l'IoT et plus particulièrement des *wearable devices*. De ce fait, la section 3.4.3 ayant présenté les principales caractéristiques techniques de bas niveau pour cette technologie, il est désormais nécessaire d'en présenter le fonctionnement de haut niveau. En effet, la communication par BLE oblige l'utilisation du protocole tel que défini par le standard. Par conséquent, l'implémentation d'un tout autre protocole de haut niveau déjà existant n'est pas possible avec cette technologie.

Le protocole du BLE est divisé en deux catégories : le contrôleur et l'hôte ; chacune admettant des sous-catégories parmi lesquelles il est possible de retrouver le Generic Access Profile (GAP) et le Generic ATtribute (GATT). Le GAP définit la topologie générale du réseau. En d'autres termes, si un dispositif Bluetooth est visible par d'autres, c'est par l'intermédiaire de ce profil. Il détermine comment les appareils peuvent, ou non, interagir entre eux. Le GATT, quant à lui, décrit en détail la manière dont les données sont formatées, conditionnées et transférées selon les règles définies par l'ATtribute Protocol (ATT). Pour communiquer avec le monde extérieur, un appareil BLE peut se trouver en deux modes différents : le mode diffusion (figure 3.2a) ou le mode communication, qui correspond à une topologie étoile (figure 3.2b). Ceux-ci sont définis dans les directives relatives au GAP.


Dans le cas du mode diffusion, il est important de distinguer deux rôles que peuvent avoir les appareils BLE : les diffuseurs et les observateurs. Pendant un intervalle

de temps donné (l'intervalle de diffusion), le diffuseur est responsable d'annoncer publiquement des données. Si un observateur demande à récupérer les données annoncées par le diffuseur, ce dernier doit alors lui transmettre—sinon elles sont annoncées de nouveau dès lors que l'intervalle de diffusion est écoulé. Un nouveau cycle peut alors recommencer. En outre, il est important de noter qu'aucune connexion n'est établie entre un observateur et un diffuseur. Le fonctionnement de ce processus est illustré par la figure 3.4a.


À l'inverse du mode diffusion, deux appareils BLE, lorsqu'ils sont en mode communication, doivent explicitement établir une connexion entre eux pour que des données puissent être échangées. Si un observateur demande une connexion à un diffuseur, le processus de diffusion s'arrête et il n'est plus possible d'obtenir les données qui étaient annoncées. Ce dernier adopte alors le rôle de périphérique et l'observateur devient le central. Un appareil BLE ayant le rôle de périphérique ne peut se connecter qu'à un seul dispositif central à la fois, mais un central peut, quant à lui, être connecté à plusieurs périphériques. Cependant, la connexion peut être interrompue intentionnellement ou non (*p. ex.* perte de l'alimentation), et ce, par n'importe quel dispositif.

Dès que la connexion est établie, la communication entre le dispositif central et le dispositif périphérique peut commencer. Le dispositif qui demande les données joue alors le rôle de serveur GATT. Puisque les rôles définis par le GAP et le GATT sont indépendants, le central et le périphérique peuvent tous deux devenir le serveur. Celui-ci est donc sollicité par le client GATT qui lui envoie des requêtes. Le serveur GATT indique un intervalle de connexion au client qui va alors essayer de se reconnecter après

chaque délai pour récupérer de nouvelles données, si elles existent. Une représentation graphique du fonctionnement de ce processus est donnée en figure 3.4b. Les données sont transmises du serveur au client par une collection de services. Ceux-ci sont utilisés pour diviser les données en entités logiques et contiennent des blocs de données spécifiques qui sont les caractéristiques. Un service peut avoir une ou plusieurs caractéristiques et chaque service se distingue des autres au moyen d'un identifiant numérique unique (Universally Unique IDentifier ou UUID), qui peut être défini soit sur 16 bits (pour les services BLE officiels), soit sur 128 bits (pour les services personnalisés). Les caractéristiques sont elles aussi identifiées par un UUID de 16 ou de 128 bits prédéfini. C'est via celles-ci que les informations sont échangées, car contrairement aux services, elles ne peuvent encapsuler qu'une unique donnée (*p. ex.* une valeur binaire, un entier, un tableau de valeurs).



(a) Échange de données en mode diffusion



(b) Échange de données en mode connexion

Figure 3.4 : Illustration du processus d'échange de données dans les deux modes de fonctionnement du BLE, soit les modes diffusion et connexion.

3.5.3 LES SERVICES WEB

Les services web permettent à différentes applications de communiquer entre elles en fournissant une plateforme commune pour l'échange de données. Les requêtes et les réponses émises par les applications sont soumises à des standards. Parmi les plus populaires, il est possible de retrouver le protocole Simple Object Access Protocol (SOAP), l'architecture Representational State Transfer (REST) et le protocole Constrained Application Protocol (CoAP).

LE PROTOCOLE SOAP

Le protocole SOAP, tout comme le modèle *publish/subscribe*, est lui aussi utilisé dans les habitats intelligents depuis leur apparition. En effet, c'est principalement le cas de ceux ayant opté pour une architecture par composants et plus particulièrement OSGi (comme Gator-tech (Helal *et al.*, 2005)), puisque cette technologie repose sur SOAP pour tirer profit des services web. Depuis, de nombreux travaux se sont intéressés à l'interopérabilité des données ambiantes fournies par les habitats intelligents avec les données produites par les *wearable devices* (Perumal *et al.*, 2008; Cubo *et al.*, 2014; Díaz-Rodríguez *et al.*, 2018).

SOAP est un protocole d'échange d'information structuré qui repose sur le langage eXtensible Markup Language (XML). Bien que ce dernier puisse être utilisé au-dessus de plusieurs autres protocoles tels que Simple Mail Transfer Protocol (SMTP), Transmission Control Protocol (TCP) ou User Datagram Protocol (UDP), il est majoritairement employé comme couche supérieure à HyperText Transfer Protocol (HTTP). Le protocole SOAP appartient au modèle client/serveur et permet aussi bien l'appel de procédures respectant les propriétés ACID (Atomicité, Cohérence, Isolation et Durabilité), que le transfert d'informations. Dans ce dernier cas, un message est envoyé au serveur qui va alors traiter l'information et répondre au client.

Un message SOAP est un document XML qui contient un en-tête (*header*) ainsi qu'un corps (*body*), le tout encapsulé dans une enveloppe. Cette dernière indique que le document XML correspond à un message SOAP et identifie le début ainsi que la fin du message. L'en-tête, qui demeure facultatif, peut contenir différents attributs relatifs

au message. Le corps, quant à lui obligatoire, contient les informations soit de la requête faite par le client, soit de la réponse du serveur, ainsi que des informations à propos des erreurs qui pourraient survenir. Les informations contenues dans le corps du message SOAP sont organisées sous forme de blocs. La figure 3.5 montre un exemple d'échange de messages SOAP à travers HTTP qui permet d'obtenir la valeur du capteur cardiaque d'un dispositif quelconque.

```

1      POST /Sensors HTTP/1.0
2      Host: www.liara.uqac.ca
3      Content-Type: text/xml; charset = utf-8
4      Content-Length: nnn
5
6      <?xml version = "1.0"?>
7      <SOAP-ENV:Envelope
8          xmlns:SOAP-ENV = "http://www.w3.org/2001/12/soap-envelope"
9          SOAP-ENV:encodingStyle = "http://www.w3.org/2001/12/soap-encoding">
10         <SOAP-ENV:Body xmlns:m = "http://www.liara.uqac.ca/sensors">
11             <m:GetSensorValue>
12                 <m:Sensor>HeartRate</m:Sensor>
13             </m:GetSensorValue>
14         </SOAP-ENV:Body>
15     </SOAP-ENV:Envelope>

```

(a) Requête SOAP

```

1      HTTP/1.0 200 OK
2      Content-Type: text/xml; charset = utf-8
3      Content-Length: nnn
4
5      <?xml version = "1.0"?>
6      <SOAP-ENV:Envelope
7          xmlns:SOAP-ENV = "http://www.w3.org/2001/12/soap-envelope"
8          SOAP-ENV:encodingStyle = "http://www.w3.org/2001/12/soap-encoding">
9         <SOAP-ENV:Body xmlns:m = "http://www.liara.uqac.ca/sensors">
10             <m:GetSensorValueResponse>
11                 <m:HeartRateValue>90</m:HeartRateValue>
12             </m:GetSensorValueResponse>
13         </SOAP-ENV:Body>
14     </SOAP-ENV:Envelope>

```

(b) Réponse SOAP

Figure 3.5 : Exemple d'un échange de messages SOAP entre un client et un serveur pour obtenir la valeur du capteur cardiaque.

L'avantage principal de l'utilisation de SOAP comme méthode de communication est principalement la sécurité qu'offre ce protocole. En effet, ce dernier peut être implé-

menté par dessus une couche de chiffrement Secure Sockets Layer (SSL), mais il permet également d'exploiter la spécification *Web Services Security* ou *WS-Security* qui apporte des fonctionnalités de sécurité supplémentaires appréciées des entreprises. Cependant, il demeure un protocole peu flexible et relativement lourd et complexe à mettre en place.

L'ARCHITECTURE REST

Dès le début des années 2000, l'introduction des architectures de type REST (Fielding, 2000) a permis de remplacer petit à petit le protocole SOAP, venant ainsi combler certaines de ses lacunes. Le principal avantage de ces architectures est leur indépendance vis-à-vis des protocoles existants. En effet, bien que les architectures REST soient aussi majoritairement définies par-dessus HTTP, elles pourraient tout autant l'être sur n'importe quel autre protocole—tant que celui-ci admet un schéma d'Uniform Resource Identifier (URI) normalisé. Tout comme pour SOAP, les architectures REST s'appuient sur le modèle de communication client/serveur. Cependant, à l'inverse de SOAP, un service web REST est sans état, c'est-à-dire que le serveur ne connaît pas l'état de chaque client entre les requêtes qu'il doit traiter. Ainsi, du point de vue du serveur, chaque requête est une entité distincte des autres. De plus, contrairement à SOAP, qui impose le format d'échange de données en XML, REST accepte que les ressources, c'est-à-dire, les données échangées entre le client et le serveur, soient exprimées selon plusieurs formats de données tels que XML, JavaScript Object Notation (JSON) ou encore Hypertext Markup Language (HTML). Ceci garantit alors un meilleur support pour les clients.

Lorsqu'elle est définie sur HTTP, une architecture REST manipule ses ressources avec les différentes méthodes HTTP (*GET*, *POST*, *PUT*, *DELETE*, *PATCH*). Ainsi, lorsqu'un client émet une requête indiquant l'opération qu'il souhaite effectuer sur une ressource donnée la réponse transmise par le serveur contient alors deux éléments importants—l'en-tête et le corps de la réponse. Plus précisément, l'en-tête contient des informations importantes à propos de l'échange d'information :

- La version du protocole HTTP utilisé pour le transport des données.
- Le code HTTP (Fielding et Reschke, 2014) qui indique l'état de la réponse.
- Le format de donnée.
- *etc.*

Le corps de la réponse, quant à lui, peut contenir une ressource, un message d'erreur, *etc.* La figure 3.6 illustre le processus de communication entre un client et un serveur dans une architecture REST basée sur les méthodes HTTP. Le client demande l'obtention de la valeur du capteur cardiaque d'un dispositif quelconque. Cette ressource est identifiée par l'URI `http://liara.uqac.ca/sensors/health/1`. Puisque le serveur est capable de fournir la réponse attendue, et ce, sans erreur, le code HTTP 200, ainsi que le nom et la valeur du capteur sont renvoyés au client au format JSON, tel que précisé dans l'en-tête de la réponse.

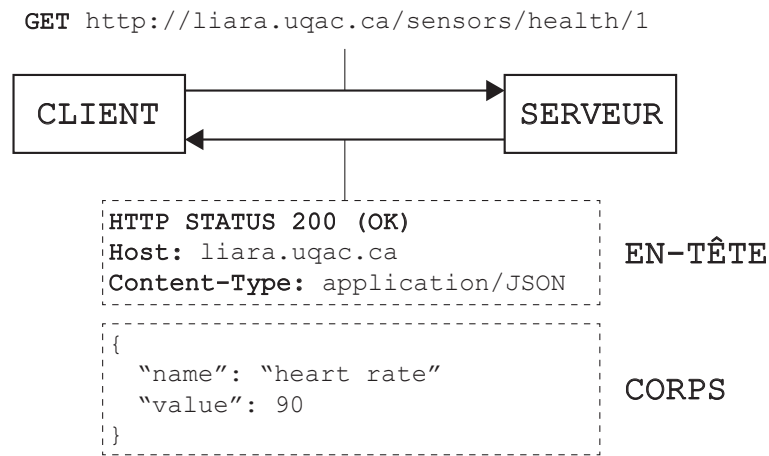


Figure 3.6 : Illustration d'un échange de messages entre un client et un serveur dans une architecture REST basée sur HTTP qui permet de récupérer la valeur d'un capteur cardiaque.

LE PROTOCOLE CoAP

Plus récemment, la recrudescence du nombre d'objets connectés et plus particulièrement de *wearable devices* a fait émerger plusieurs problématiques inhérentes à la limitation de leurs ressources telles qu'une puissance de calcul restreinte, une faible quantité de mémoire ou encore une autonomie réduite. Cependant, la limitation de ces dispositifs implique également de nouvelles problématiques au regard du processus d'échange de données. En effet, malgré une meilleure efficacité qu'avec le protocole SOAP, tant en termes de débit qu'en termes de consommation de ressources, l'exploitation des services web à travers une architecture REST s'est parfois montrée inadaptée dans le contexte de l'IoT (Kovatsch *et al.*, 2011). En effet, lorsqu'une architecture REST repose sur le protocole HTTP, il a été observé qu'une grande fréquence de requêtes ne retournant qu'un nombre faible de données entraînait une surcharge réseau, principalement à cause des en-têtes HTTP qui sont encodés en American Standard Code for

Information Interchange (ASCII) (Shelby, 2010). Néanmoins ce cas de figure correspond au fonctionnement typique d'un réseau de capteurs sans-fil, où chaque message qui est envoyé correspond généralement à une seule mesure. Par conséquent, le protocole CoAP a été introduit par Shelby *et al.* (2014) afin de mieux répondre aux besoins des appareils ayant de fortes contraintes liées au débit, à la consommation et à la puissance de calcul. Malgré son jeune âge, plusieurs recherches se sont tournées vers une implantation de CoAP au sein des habitats intelligents (Bergmann *et al.*, 2012; Mainetti *et al.*, 2015). Par ailleurs, de récents travaux, comme celui introduit par Plantevin *et al.* (2017), ont proposé de nouveaux protocoles de communication qui s'inspirent de la spécification de CoAP. Bien qu'ils soient encore très peu exploités, ceux-ci visent principalement à mieux intégrer l'IoT au sein des habitats intelligents, puisqu'ils permettent d'optimiser davantage le processus d'échange de données.

Pour mettre en place une architecture REST, CoAP reprend plusieurs concepts de HTTP comme les échanges de messages asynchrones, par exemple. Cependant plusieurs optimisations ont été faites pour le rendre plus adapté aux systèmes embarqués tel que la nécessité d'utiliser le protocole UDP qui permet de se passer des mécanismes de fiabilité qui sont obligatoire avec le protocole TCP lors d'échanges de messages. En outre, les en-têtes sont compressés afin de réduire la complexité du décodage et les besoins en bande passante. Les messages CoAP contiennent les informations suivantes :

- La version du protocole utilisée pour le transport des données.
- Le type du message indique s'il s'agit, d'un message fiable qui exige un acquittement (*CON*), d'un message asynchrone qui n'a pas besoin d'être acquitté (*NON*),

d'un message d'acquiescement, c'est-à-dire, une réponse à une requête *CON* (*ACK*), d'un message qui indique que le serveur a bien reçu la requête, mais qu'il n'a pas le contexte nécessaire pour fournir une réponse (*RST*).

- Le nombre d'options transmises dans l'en-tête (*OC*).
- Un code qui indique si le message est une requête, une réponse ou un message vide. Dans le cas d'une requête, la méthode utilisée est également précisée. Elles sont identiques aux méthodes HTTP.
- Un identifiant unique pour détecter les messages dupliqués et pour faire la correspondance entre un message *CON* et son *ACK* respectif.
- Différentes options, par exemple, un paramètre pour définir la durée de validité des données transmises.
- Les données en elles-mêmes.

La figure 3.7 illustre le processus de communication entre un client et un serveur dans une architecture REST basée sur CoAP. Le client demande l'obtention de la valeur du capteur cardiaque d'un dispositif quelconque où la requête et la ressource sont respectivement identifiées par le code *0x4d45* et l'URI */sensors/health/hr*. Le serveur transmet alors immédiatement le message *ACK* ainsi que la valeur du capteur.



Figure 3.7 : Illustration d'un échange de messages entre un client et un serveur dans une architecture REST basée sur CoAP qui permet de récupérer la valeur d'un capteur cardiaque.

Puisque la différence majeure entre CoAP et HTTP réside dans l'utilisation du protocole UDP, sous-jacent, ceci lui permet de supporter le *multicast*. Aussi, comme CoAP est principalement conçu pour l'IoT, ce protocole se base principalement sur IPv6 bien que, dans de plus rare cas, il puisse également exploiter IPv4. La communication à travers IPv6 permet donc à ce protocole de mieux prendre en compte le volume d'entités qui composent un réseau de capteurs sans-fil. Enfin, il permet de mettre en place aussi bien un modèle client/serveur, tel qu'illustré dans l'exemple précédent, qu'un modèle *publish/subscribe* à l'instar du protocole MQTT.

3.6 CONCLUSION

Dans un premier temps, ce chapitre s'est intéressé à la couche matérielle qui compose les *wearable devices*. Les capteurs les plus adéquats pour être embarqués dans ce type de dispositifs ont été regroupés en différentes catégories qui sont : les capteurs de mouvement, les capteurs physiologiques, les capteurs de courbure et de force ainsi que les capteurs environnementaux. Bien qu'il en existe beaucoup d'autres, ce chapitre a montré que ceux-ci demeurent les plus utilisés dans divers domaines de recherche

tels que la réhabilitation, la surveillance de la santé et surtout dans la reconnaissance de gestes et d'activités.

Ensuite, ce chapitre a présenté les technologies de communication sans-fil actuellement employées par les *wearable devices*, mais également les futures évolutions de chacune d'elles. Il est apparu que toutes s'inscrivent dans l'optique de mieux prendre en compte le nombre grandissant d'objets connectés, plus particulièrement en ce qui concerne leur limitation énergétique. De plus, en ne considérant que les capacités actuelles de chaque technologie, ce chapitre a proposé un comparatif de leurs différences en termes de capacité de portée, débit et robustesse. Ceci a permis de conclure que le choix de la technologie à adopter dans le processus de conception de *wearable devices* en fonction des contraintes liées à l'utilisation qui doit en être faite.

Enfin, dans sa dernière partie, ce troisième chapitre a exposé les différents protocoles et architecture de haut niveau permettant aux *wearable devices* d'échanger leurs données avec d'autres entités qui composent un réseau (capteurs intelligents, serveur central, *etc.*). Ainsi, dans les travaux sur les habitats intelligents et leurs évolutions pour y intégrer l'IoT, deux principaux modèles pour l'échange de données ont été retenus. Le premier est le modèle *publish/subscribe* et plus particulièrement le protocole MQTT. Le second concerne le modèle client/serveur, plus traditionnel. Bien qu'il admette un fonctionnement particulier, le cas du BLE s'appuie fortement sur ce deuxième modèle. De plus, des méthodes plus récentes issues du web social comme la consommation de services web appartiennent également à un modèle client/serveur. Pour tirer profit des services web, plusieurs technologies comme le protocole SOAP ou les architectures

REST ont été mises en place au sein des infrastructures d'habitats intelligents. Cependant, certaines limitations quant à l'intégration de l'IoT ont pu être observées. Pour combler ces problématiques, de nouvelles implémentations comme le protocole CoAP ont été mises en place dans ces habitats.

CHAPITRE IV

UN *WEARABLE DEVICE* POUR LA RECONNAISSANCE DES SOLS

4.1 INTRODUCTION

Au cours des dernières années, les grands fabricants de matériel électronique tels que *Garmin*, *Apple*, *Samsung* ou encore *Fitbit* ont contribué à populariser les *wearable devices* pour le grand public. En effet, selon le rapport réalisé par Nielsen (2014), 70% des consommateurs interrogés connaissent cette technologie et 15% d'entre eux se servent d'un *wearable device* dans leur vie de tous les jours en plus de leur téléphone intelligent. Ces dispositifs ont permis l'exploitation de nouveaux types de capteurs, en comparaison de ceux qui étaient déjà présents dans les téléphones (*p. ex.* les capteurs cardiaques) et ils ont permis d'accélérer l'adoption de technologies comme le BLE (Taplett, 2014). En ce sens et puisqu'ils représentent un moyen pratique et portable pour enregistrer des données physiologiques, les *wearable devices* ont été rapidement et massivement adoptés, principalement pour assurer le suivi des activités sportives (NPD Group, 2015). Il est donc devenu possible, pour leurs utilisateurs, de récolter une quantité considérable de données dans le but de produire des analyses statistiques et ainsi surveiller les évolutions dans la réalisation d'activités quotidiennes, qu'elles soient sportives ou non. Néanmoins, avec les avancements en matière d'apprentissage machine, il est possible d'affirmer que les applications développées spécifiquement pour les *wearables devices* peuvent être améliorées pour devenir plus ubiquitaires.

L'objectif de ce chapitre est donc d'introduire un nouveau cas d'utilisation d'un wearable device où la réponse à la question suivante : « *Est-il possible de reconnaître les types de sols à l'aide de données inertielles produites par la démarche humaine avec un wearable device—quel que soit l'endroit où il est porté ?* » est le principal sujet discuté dans deux publications respectivement présentées aux conférences *IEEE 14th International Conference on Ubiquitous Intelligence and Computing (UIC)* qui s'est déroulée en août 2017 à San Francisco aux États-Unis (Thullier *et al.*, 2017) et *IEEE 15th International Conference on Ubiquitous Intelligence and Computing (UIC)* qui s'est déroulée en octobre 2018 à Guangzhou en Chine (Thullier *et al.*, 2018).

Pour se faire, ce chapitre commence par présenter un état de l'art des recherches menées au sujet de la reconnaissance des sols par le biais de données inertielles. Ensuite, après avoir présenté la solution proposée ainsi que les expérimentations réalisées, ce chapitre va analyser et discuter les résultats obtenus. Finalement, la dernière partie dresse une conclusion de ce premier travail.

4.2 ÉTAT DE L'ART

L'idée de reconnaître des types de sols par le biais de données produites par une centrale inertielle provient du domaine de la robotique. En effet, Vail et Veloso (2004) ont tout d'abord expérimenté la détection de surface grâce à des données inertielles produites par un robot quadrupède. Pour réaliser l'apprentissage, les auteurs ont opté pour un algorithme dont le modèle est un arbre de décision (C4.5), car ils estiment qu'il s'agit d'un algorithme suffisamment rapide et facile à représenter et à implémenter. Pour quantifier la précision de leur modèle d'apprentissage, Vail et Veloso ont utilisé la technique

de la validation croisée en 10-plis (Kohavi, 1995), ce qui leur a permis d'obtenir un taux de reconnaissance global de 84.9% (ciment : 91% ; tapis : 81.2% ; champs : 81.2%). Par la suite, Kertesz (2016) ont également présenté une méthode permettant de reconnaître des sols avec un accéléromètre embarqué sur un robot quadrapède. Ceux-ci ont obtenu un taux de confiance de 96.2% en utilisant une forêt d'arbres décisionnels (**Random Forest!** ou RF) et en évaluant la précision de l'apprentissage avec la même technique que celle utilisé par Vail et Veloso. La différence majeure entre les deux travaux réside principalement dans le fait que les premiers ont utilisé des caractéristiques temporelles du signal inertiel (variance et corrélation) pour concevoir leur modèle d'apprentissage, tandis que les seconds ont utilisé des caractéristiques fréquentielles grâce à une FFT.

Par ailleurs, Bibuli *et al.* (2007) ont proposé une méthode de reconnaissance des sols pour un robot à quatre roues équipé de plusieurs types de capteurs, dont une centrale inertielle. Pour ce faire, ils ont tout d'abord calculé les composantes fréquentielles du signal inertiel *via* l'algorithme de la transformée de fourrier discrète (Discrete Fourier Transform ou DFT), pour chacun des axes du capteur. Chaque ensemble a ensuite été entraîné distinctement par son propre réseau de neurones artificiels (ANN). Par conséquent, les meilleurs résultats ont été obtenus avec les données de l'axe x du gyroscope, soit respectivement 90%, 71.2%, 70%, 98.8% et 83.5% pour les sols en graviers, gazon, sable, pavés et terre.

Enfin, Weiss *et al.* (2007) ont proposé une comparaison de plusieurs méthodes pour réaliser une reconnaissance de sols avec un robot à quatre roues doté d'un capteur inertiel. Plus précisément, ils ont comparé l'algorithme SVM avec d'autres types d'algorithmes

d'apprentissage où les données fournies en entrées sont des caractéristiques fréquentielles du signal inertiel correspondant à différentes vitesses du robot (0.2, 0.4 et 0.6 m/s) et pour six sols distincts (sol intérieur, asphalte, gravier, gazon, pavés, sol argileux). Avec l'obtention de 77% de taux de confiance, leur étude a montré de meilleurs résultats avec l'algorithme SVM qu'avec les autres algorithmes qui sont : un réseau de neurones probabiliste (Probabilistic Neural Network ou PNN), l'algorithme des k plus proches voisins, l'algorithme bayésien naïf et C4.5.

Bien que cette littérature soit, d'une certaine manière, pertinente pour comprendre comment reconnaître différents types de sols, il est possible que ces méthodes ne soient pas parfaitement adaptées pour effectuer une reconnaissance appropriée dans le contexte de la démarche humaine. Au mieux de notre connaissance, il apparaît que peu de recherches ont été proposées pour exploiter une telle reconnaissance avec l'humain. Pourtant, de nombreux cas d'utilisation à la reconnaissance des sols dans ce contexte nous paraissent exploitables. Le premier exemple concerne le domaine sportif où il serait possible de subdiviser un tracé GPS en de plus petits tracés déterminés par rapport à la composition du sol et ainsi fournir des détails supplémentaires sur un sentier de randonnée ou de course. Dans un second temps, une telle technologie pourrait être utile au domaine de la santé et plus particulièrement, celui de l'assistance. En effet, en ayant connaissance du type de sol, il serait possible de proposer des techniques de prévention des chutes plus efficaces puisque celles-ci sont plus susceptibles de survenir lorsque les personnes évoluent sur certains types de sols comme le carrelage humide d'une salle de bain.

De ce fait, Otis *et al.* (2016) ont récemment proposé une méthode basée sur la reconnaissance des types de sols pour réduire les risques de chutes qui demeurent particulièrement importants chez les personnes en perte d'autonomie ou plus simplement, les personnes âgées. Pour ce faire, une chaussure embarquant un accéléromètre a été fabriquée. Ensuite, un algorithme de *clustering* a été utilisé pour segmenter les caractéristiques fréquentielles discriminantes obtenues par le biais de la FFT sur le signal accélérométrique lorsque celui-ci a été enregistré sur les sols suivants : gravier, ciment sable, neige et glace. En ce qui concerne les résultats obtenus, les auteurs mentionnent un taux d'erreurs compris entre 1% et 5% lors des essais en laboratoire, alors qu'ils ont observé une augmentation de ce taux en conditions réelles, soit 20% d'erreurs.

4.3 SOLUTION PROPOSÉE

4.3.1 LE WEARABLE DEVICE

Selon la littérature existante, l'utilisation de centrales inertielles pour réaliser la reconnaissance de sols s'est montré une technique aussi bien fonctionnelle avec des robots qu'avec les individus. De ce fait, la contribution présentée dans ce chapitre s'est, dans un premier temps, axée sur la conception d'un *wearable device* pour y parvenir. L'idée générale est de piloter, par l'intermédiaire d'un téléphone connecté en BLE, le dispositif afin d'enregistrer un volume important de données pendant une marche. Lors de la conception, le choix s'est porté sur le système sur puce (System on Chip ou SoC) *Arduino 101* qui embarque le module *Intel Curie*, également accompagné d'un *shield* de prototypage sur lequel est embarqué un lecteur de carte mémoire, tel qu'illustré en figure 4.1. Ce choix a été motivé par la composition même du module *Intel Curie*. En effet, ce

dernier intègre d'usine un module de communication BLE, un IMU 6 axes (6-Degrees of Freedom ou 6-DoF) ainsi qu'une quantité suffisante d'Entrées/Sorties (Input/Output ou I/O) pour connecter des composants supplémentaires et ainsi faciliter l'évolution du dispositif. De plus, les autres avantages au choix de ce matériel demeurent la simplicité et la fiabilité de l'*Arduino 101*, mais également la quantité de ressources disponibles pour cette plateforme. Finalement, la présence d'un lecteur de carte mémoire sur le *shield* de prototypage constitue un moyen simple et efficace pour faire face à la quantité de données inertielles qui doivent être stockées.

Dans une première version, la reconnaissance des types de sols a été réalisée par l'intermédiaire de l'IMU 6-DoF directement embarqué sur le SoC *Arduino*. Néanmoins, puisque la précision de celui-ci était inconnue avant les premières expérimentations et qu'il manquait les trois axes supplémentaires du magnétomètre, une seconde version du *wearable device* a été proposée. Pour cette dernière, un nouvel IMU 9-DoF, le *LSM9DS1*, a été interfacé directement sur le *shield* de prototypage.




Figure 4.1 : SoC Arduino 101 et son *shield* de prototypage incluant une carte mémoire (1) ainsi que la centrale inertielle *LSM9DS1* (2) présente sur la version 2 du dispositif.

4.3.2 LE *FIRMWARE*

Pour assurer le bon fonctionnement du matériel qui compose le *wearable device* il était tout d’abord nécessaire de développer un *firmware*¹⁰. Le fonctionnement de celui-ci s’articule autour de trois composants logiciels principaux qui sont illustrés en figure 4.2.




Figure 4.2 : Représentation graphique de l’implémentation du *firmware* embarqué sur le *wearable device*.

Le premier est le module de commande. Il est en charge des communications entre le téléphone et le dispositif par l’intermédiaire du module radio BLE. Ainsi, un téléphone ou n’importe quel autre dispositif compatible avec la technologie BLE peut être utilisé pour étiqueter les ensembles de données enregistrés avec les informations de configuration requises (le type de sol, l’identifiant anonyme du participant et l’emplacement du dispositif).

10. <https://github.com/FlorentinTh/SoilTypesRecognition-WearableFirmware>

Le second module principal est l'*IMU Recorder*. En fonction de la version du dispositif, il a pour rôle de stocker dans une mémoire tampon les valeurs de l'IMU qui transitent soit par un bus de données Serial Peripheral Interface (SPI) dans sa première version, soit *via* un bus de données Inter-Integrated Circuit (I²C), à une fréquence stabilisée à 60 Hz.

Le contenu de la mémoire tampon est ensuite envoyé au module de formatage des données toutes les secondes. Finalement, ce composant récupère l'ensemble des données de configuration du module de commande et s'occupe d'écrire les nouvelles données dans un fichier Comma-Separated Values (CSV) qui est stocké sur la carte mémoire. Dans la seconde version du *wearable device*, le module de formatage des données s'occupe également de calculer les angles d'Euler (précession, nutation et rotation propre) grâce aux trois axes supplémentaires fournis par le *LSM9DS1*.

4.3.3 LE PROCESSUS D'APPRENTISSAGE POUR LA RECONNAISSANCE DES TYPES DE SOLS

EXTRACTION DES CARACTÉRISTIQUES

Après que les données aient été enregistrées sur la carte mémoire, le processus d'apprentissage pour la reconnaissance des types de sol est réalisé. Celui-ci débute par l'extraction des caractéristiques. En ce sens, cette solution propose d'utiliser les caractéristiques temporelles et fréquentielles les plus employées dans le domaine de la reconnaissance d'activités tel que discuté à la section 2.3.1 et qui sont rappelées par le tableau 4.1.

Tableau 4.1 : Récapitulatif de toutes les caractéristiques utilisées par la solution proposée en fonction du nombre d’axes offerts par la centrale inertielle.

Domaine Temporel				Domaine Fréquentiel			
Caractéristique	Nb. Total de Caractéristiques			Caractéristique	Nb. Total de Caractéristiques		
	IMU 6 axes	IMU 9 axes	IMU 9 axes avec angles d'Euler		IMU 6 axes	IMU 9 axes	IMU 9 axes avec angles d'Euler
Moyenne pour chaque axe	6	9	12	Composante continue pour chaque axe	6	9	12
Moyenne de tous les axes	2	3	4	Énergie spectrale pour chaque axe (équation 2.9)	6	9	12
Écart type pour chaque axe	6	9	12	Entropie pour chaque axe (équation 2.10)	6	9	12
Écart type pour tous les axes	2	3	4	-	-	-	-
Asymétrie pour chaque axe (équation 2.6)	6	9	12	-	-	-	-
Asymétrie pour tous les axes	2	3	4	-	-	-	-
Kurtosis pour chaque axe (équation 2.7)	6	9	12	-	-	-	-
Kurtosis pour tous les axes	2	3	4	-	-	-	-
Corrélation entre toutes les combinaisons possibles d'axes incluant le total des axes	12	18	24	-	-	-	-
Zero Crossing Rate pour chaque axe	6	9	12	-	-	-	-
Zero Crossing Rate pour tous les axes	2	3	4	-	-	-	-
<i>Sous-total</i>	<i>52</i>	<i>78</i>	<i>104</i>	<i>Sous-total</i>	<i>18</i>	<i>27</i>	<i>36</i>
Total	IMU 6 axes	70					
	IMU 9 axes	105					
	IMU 9 axes avec angles d'Euler	140					

La première opération consiste en une simple moyenne non pondérée sur chacun des axes tant « physiques » des capteurs de l’IMU (gyroscope, accéléromètre et magnétomètre si 9-DoF) que « logiques » (angles d’Euler), s’ils existent. Ensuite, la moyenne générale de chacune de ces caractéristiques est calculée pour l’ensemble des axes. De la même manière, cette procédure a été appliquée à plusieurs autres calculs statistiques : l’écart type, l’asymétrie (équation 2.6), le kurtosis (équation 2.7), le *Zero Crossing Rate* et la corrélation entre toutes les combinaisons possibles d’axes par capteurs de l’IMU (équation 2.8). Dans un second temps, une transformation du domaine temporel vers

le domaine fréquentiel a été nécessaire pour obtenir les caractéristiques suivantes : la composante continue, l'énergie spectrale (équation 2.9) et l'entropie (équation 2.10). Ce passage d'un domaine à l'autre a été réalisée en utilisant l'algorithme de la transformation de Fourier rapide (FFT). Ainsi, en fonction de la centrale inertielle exploitée (6-DoF, 9-DoF ou 9-DoF avec angles d'Euler), ce sont 70, 105 ou 140 caractéristiques qui sont calculées sur chaque fenêtre temporelle non chevauchante dont la taille est fixée à 60 secondes. La taille de la fenêtre a été déterminée par une évaluation du temps moyen nécessaire pour marcher une distance de 4.3 *m*, ce qui correspond à un aller-retour dans le bac utilisé lors des expérimentations et dont le protocole est décrit à la section 4.4.

APPRENTISSAGE

Dès l'obtention des caractéristiques discriminantes, l'étape suivante requise pour réaliser la reconnaissance des sols est le processus d'apprentissage. Selon la littérature qui concerne la reconnaissance d'activités, mais également celle au sujet de la reconnaissance des sols en robotique discutée dans les sections 2.3.2 et 4.2, la performance de plusieurs algorithmes d'apprentissage a été démontrée. Néanmoins, ce premier travail propose une comparaison entre deux algorithmes qui n'ont pas encore été présentés dans cette thèse : la forêt d'arbres décisionnels et les k plus proches voisins (k -Nearest Neighbors ou k -NN). Ce choix est motivé par deux raisons principales. La première est que ces deux techniques d'apprentissage appartiennent à deux familles distinctes—respectivement, les arbres de décision et les algorithmes d'apprentissage « paresseux ». De plus, ceux-ci constituent tous deux des méthodes non paramétriques,

c'est-à-dire, qui ne font aucune supposition quant à la distribution de l'échantillon de données fournies en entrée. De ce fait, ces méthodes demeurent simples, flexibles, puissants et efficaces (Russell et Norvig, 2010). Par ailleurs, la performance en termes de taux de reconnaissance obtenue avec ces algorithmes est souvent exposée dans la littérature (Kertesz, 2016; Vail et Veloso, 2004).

Selon Breiman (2001), une forêt d'arbres décisionnels est une combinaison d'arbres prédictifs, aussi appelés arbre de décision, où chacun d'eux dépend d'un vecteur de données distinct, mais de même cardinalité. Ce vecteur contient un sous-ensemble aléatoire des données initiales issues de la phase d'extraction des caractéristiques. La décision finale du processus de reconnaissance de cet algorithme est déterminée par un vote majoritaire entre chacune des décisions émises en sortie des arbres de décision qui composent la forêt. La figure 4.3 illustre un exemple simplifié d'une forêt d'arbres décisionnels utilisant trois arbres.




Figure 4.3 : Exemple de l’algorithme *Random Forest* utilisant $B = 3$ arbres.

Pour exploiter la forêt d’arbres décisionnels en tant qu’algorithme d’apprentissage, il est important de définir préalablement au moins trois paramètres principaux. Le premier est le nombre d’arbres que doit comporter la forêt (B). Le second correspond au nombre de caractéristiques à considérer dans la division des nœuds de l’arbre lors de la construction de ce dernier (F) et enfin, la fonction nécessaire à la mesure de la qualité de cette division (C). En ce qui concerne le nombre de caractéristiques, Breiman suggère d’utiliser $F = \log_2(m) + 1$ ou m fait référence au nombre total d’attributs présents dans le jeu de données fourni en entrée. Néanmoins, il est également possible de trouver d’autres recommandations comme $F = \frac{1}{2}\sqrt{m}$ ou encore $F = \sqrt{m}$. Par ailleurs, en ce qui concerne la mesure de la qualité de la division des nœuds les fonctions qui sont les

plus couramment utilisées sont le calcul du coefficient de Gini et l'évaluation du gain en information basé sur l'entropie de Shannon dont les équations sont respectivement rappelées ci-après :

$$C(T) = Gini(T) = 1 - \sum_{i=1}^n (p_i)^2 \quad (4.1)$$

$$C(T) = E(T) = \sum_{i=1}^n -(p_i \log_2 p_i) \quad (4.2)$$

où T correspond aux données qui contiennent les instances de n étiquettes et p_i est la fréquence relative de l'étiquette $i \in n$ dans T . Le choix quant à ce paramètre dépend essentiellement du type d'arbres de décision qui sont utilisés lors de la construction de la forêt (*p. ex.* ID3, C4.5, CART, *etc.*).

D'autre part, l'algorithme des k plus proches voisins est considéré comme une technique d'apprentissage dite « paresseuse » ce qui veut dire qu'il n'admet pas de phase d'entraînement, ou que celle-ci demeure minime. Bien que cet algorithme soit relativement rapide et flexible, la décision finale d'étiquetage est réalisée en se basant sur l'intégralité du jeu de données utilisé pour l'entraînement. En conséquence, celui-ci doit être stocké en mémoire, ce qui implique alors de disposer d'une quantité de stockage importante. En effet, cette méthode suppose que les données peuvent être représentées dans un espace vectoriel de caractéristiques qui peut être multidimensionnel. Ainsi, la phase d'apprentissage de l'algorithme consiste seulement à stocker ses vecteurs ainsi que les étiquettes qui leur sont associés. Ensuite, lors de la phase de reconnaissance

il s'agit de déterminer quels sont les k vecteurs de caractéristiques qui sont les plus proches pour chaque nouvelle donnée à étiqueter, où k est un paramètre qui doit être défini antérieurement. Ces plus proches voisins sont alors extraits grâce à une fonction de mesure qui doit également être déterminée au préalable (*p. ex.* la distance Euclidienne ou la distance de Manhattan respectivement données en équations 2.13 et 2.14). Finalement, l'étiquette de la nouvelle donnée est alors attribuée selon un vote majoritaire entre celles de chaque k plus proche voisin. La figure 4.4 illustre un exemple de cette méthode d'apprentissage lorsque $k = 3$ plus proches voisins.




Figure 4.4 : Exemple de l'algorithme des k plus proches voisins où $k = 3$.

4.4 EXPÉRIMENTATIONS

Les expérimentations mises en place pour valider le système de reconnaissance des sols se sont déroulées en deux étapes et à deux périodes de l'année différentes. La première a été réalisée en hiver, avec la première version du *wearable device* : *wear_v1*. Elle a impliqué neuf étudiants universitaires, tous des hommes ayant entre 22 et 36

ans. Leurs poids se situaient entre 65 *kg* et 110 *kg* (poids médian : 80 *kg*) et leurs tailles étaient comprises entre 172 *cm* et 192 *cm* (taille médiane : 183 *cm*). Parmi ceux-ci, il y avait 7 droitiers pour 2 gauchers et tous étaient en bonne santé sans aucun problème de motricité. La seconde étape, quant à elle, s'est déroulée en été avec la deuxième version du dispositif : *wear_v2* et un téléphone intelligent : *cell* (*Huawei Nexus 6P* avec la version 8.0 d'*Android*). Cependant, seulement six participants sur les neuf de la première étape ont été en mesure de mener à bien cette seconde expérimentation.

4.4.1 MISE EN ŒUVRE

Dans un premier temps, puisque l'UQAC se situe dans une région où les conditions météorologiques peuvent être difficiles, la plupart des différents types de sols sont, en fonction de la période de l'année, recouverts de glace ou de neige. Pour pallier cette problématique, un bac a été fabriqué afin d'assurer le déroulement des expérimentations à l'intérieur du laboratoire. Le contenu de celui-ci était soit du gravier soit du sable, tel qu'illustré par la figure 4.5.




Figure 4.5 : Bac utilisé lors des expérimentations rempli de gravier en haut et de sable en bas, de dimensions : $l : 215 \text{ cm} \times L : 90 \text{ cm} \times H : 15 \text{ cm}$.

Dans un deuxième temps, une application *Android*¹¹ a été développée afin de piloter les expérimentations et par conséquent, annoter les jeux de données pour chacun des enregistrements produits par les participants. Ainsi, cette dernière a permis de définir les temps de début et de fin, ainsi que les différentes informations de configuration (le type de sol, l'identifiant anonyme du participant et l'emplacement du dispositif) par le biais d'un téléphone intelligent spécifiquement dédié à cette tâche : *cell_oper* (LG

11. <https://github.com/FlorentinTh/SoilTypesRecognition-AndroidAppDriver>

Nexus 5 avec la version 6.0.1 d'*Android*). Puisque le *wearable device* est doté d'une connectivité BLE, la première opération consiste à réaliser un balayage afin d'obtenir la liste des appareils dont le BLE est actif aux alentours. Dans notre cas, *cell_oper* est le dispositif périphérique et le *wearable device* est le dispositif central. Ensuite, dès que les deux appareils sont couplés, le *wearable device* devient alors le serveur GATT et *cell_oper* le client, tel qu'illustré par le premier écran de la figure 4.6. Enfin, l'enregistrement des données sur le *wearable device* débute dès lors que les informations de configuration sont renseignées et que le bouton d'envoi des données est appuyé, comme le montre le second écran de la figure 4.6

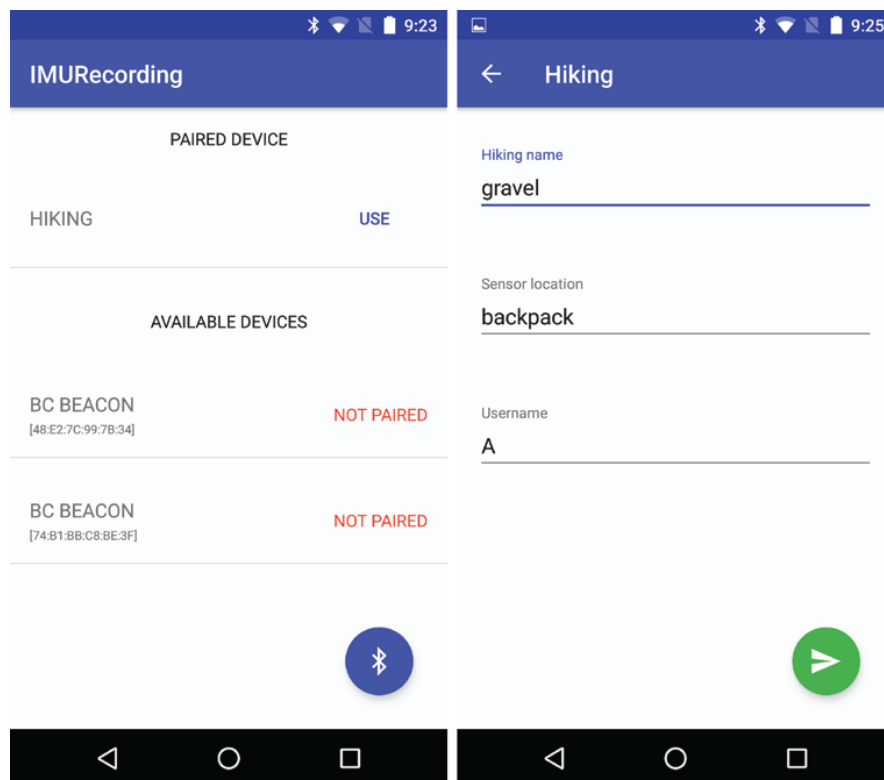


Figure 4.6 : Captures d'écran de l'application *Android* qui permet de piloter et d'étiquetter les données enregistrées exécutée sur *cell_oper*

L'avantage principal de cette méthode réside principalement dans la mobilité qu'offre l'utilisation d'un téléphone intelligent par rapport à un ordinateur traditionnel—ce qui a fortement facilité la tâche de supervision des expérimentations. De plus, l'application a pu être réutilisée sans subir de modifications aussi bien avec les deux versions du *wearable device* (*wear_v1* et *wear_v2*) qu'avec le téléphone intelligent utilisé pour l'enregistrement de données (*cell*).

Par ailleurs, le fonctionnement de la seconde application *Android*¹² qui a été développée demeure identique à celui du firmware du *wearable device*. En effet, celle-ci reçoit par BLE les mêmes informations de configuration envoyées par le biais de l'application qui s'exécute sur *cell_oper*. De la même manière, les données inertielles (accéléromètre, gyroscope, magnétomètre) ainsi que les angles d'Euler sont enregistrés toutes les secondes sur la mémoire flash du téléphone sur lequel elle est exécutée (*cell*) au format CSV à une même fréquence stabilisée à 60 Hz.

12. <https://github.com/FlorentinTh/SoilTypesRecognition-AndroidAppRecording>

4.4.2 PROCÉDURE



(a) De gauche à droite, positionnement du *wearable device* dans les poches de droite (1) et de gauche (2) ainsi qu'à l'intérieur d'un sac à dos ordinaire de 20L.



(b) Positionnement du *wearable device* à l'intérieur d'un sac bandoulière porté sur les épaules de droite et de gauche.

Figure 4.7 : Illustration des cinq emplacements où le *wearable device* est positionné pendant l'expérimentation.

4.5 RÉSULTATS ET DISCUSSION


4.5.1 ENSEMBLES DE DONNÉES

Tableau 4.2 : Liste des datasets.

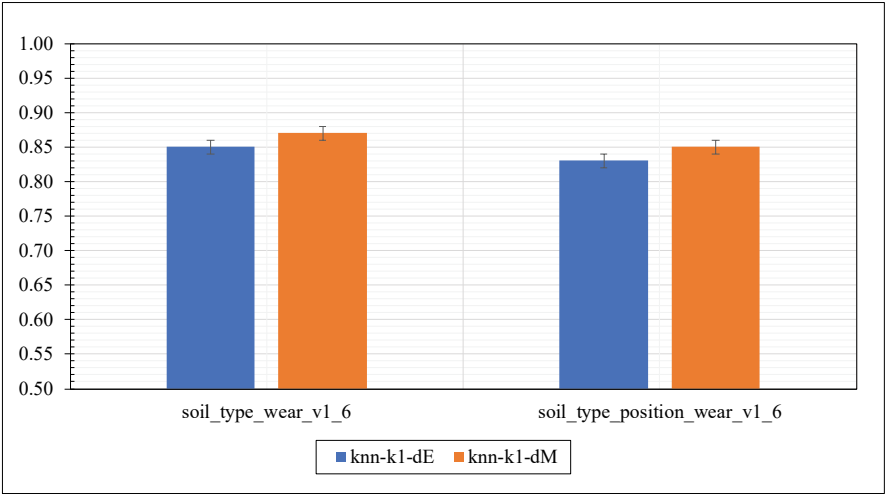
Dataset	Description
soil_type_ <i>[wear_v1 wear_v2 cell]</i> _ <i>[6 9 12]</i>	Lorem
soil_type_position_ <i>[wear_v1 wear_v2 cell]</i> _ <i>[6 9 12]</i>	Lorem

4.5.2 RÉSULTATS OBTENUS

VERSION 1 DU WEARABLE DEVICE




(a) RF




(b) KNN

Figure 4.8 : Résultats.



(a) RF



(b) KNN

Figure 4.9 : Indépendance de position.

VERSION 2 DU WEARABLE DEVICE






Figure 4.10 : Résultats.



(a) RF



(b) KNN

Figure 4.11 : Indépendance de position.




Figure 4.12 : Résultats.

4.5.3 DISCUSSION DES RÉSULTATS OBTENUS

4.6 CONCLUSION

CHAPITRE V

UN *WEARABLE DEVICE* POUR LA SÉCURITÉ & LA CONFIGURATION

AUTOMATIQUE DES HABITATS INTELLIGENTS

5.1 INTRODUCTION

5.2 ÉTAT DE L'ART

5.3 SOLUTION PROPOSÉE

5.4 EXPÉRIMENTATION PRÉLIMINAIRES

5.5 RÉSULTATS PRÉLIMINAIRES

5.6 DISCUSSION

5.7 CONCLUSION

CHAPITRE VI

UNE ARCHITECTURE D'HABITATS INTELLIGENTS MODERNISÉE

6.1 INTRODUCTION

6.2 ÉTAT DE L'ART

6.3 UNE ARCHITECTURE D'HABITATS INTELLIGENTS MODERNISÉE

6.3.1 GESTION DU CLUSTER

6.3.2 APPLICATIONS RELATIVES À LA RECONNAISSANCE D'ACTIVITÉS

6.4 LIMITATIONS

6.5 TESTS D'INTÉGRATION

6.6 CONCLUSION

CHAPITRE VII

CONCLUSION GÉNÉRALE

7.1 RÉALISATION DES OBJECTIFS

7.2 RÉPONSE À LA PROBLÉMATIQUE

7.3 LIMITATIONS ET PERSPECTIVES D'AMÉLIORATION

7.4 APPORTS PERSONNELS

BIBLIOGRAPHIE

Abreu, P. H., Xavier, J., Castro Silva, D., Reis, L. P. et Petry, M. (2014). Using Kalman filters to reduce noise from RFID location system. *The Scientific World Journal*. <http://dx.doi.org/10.1155/2014/796279>

Acampora, G., Cook, D. J., Rashidi, P. et Vasilakos, A. V. (2013). A survey on ambient intelligence in healthcare. *Proceedings of the IEEE*, 101(12), 2470–2494. <http://dx.doi.org/10.1109/JPROC.2013.2262913>

Adib, F., Mao, H., Kabelac, Z., Katabi, D. et Miller, R. C. (2015). Smart Homes that Monitor Breathing and Heart Rate. Dans *Proceedings of the 33rd Annual ACM Conference on Human Factors in Computing Systems - CHI '15*, 837–846., Seoul, Republic of Korea. ACM. <http://dx.doi.org/10.1145/2702123.2702200>

Alemdar, H., Durmaz Incel, O., Ertan, H. et Ersoy, C. (2013). ARAS Human Activity Datasets in Multiple Homes with Multiple Residents. Dans *Proceedings of the ICTs for improving Patients Rehabilitation Research Techniques*. <http://dx.doi.org/10.4108/icst.pervasivehealth.2013.252120>

Altun, K. et Barshan, B. (2010). Human Activity Recognition Using Inertial / Magnetic Sensor Units. *Human Behavior Understanding*. http://dx.doi.org/10.1007/978-3-642-14715-9_{_}5

Alzheimer's Association (2017). 2017 Alzheimer's disease facts and figures. *Alzheimer's and Dementia*. <http://dx.doi.org/10.1016/j.jalz.2017.02.001>

Alzheimer's Association (2018). 2018 Alzheimer's Disease Facts and Figures. *Alzheimer's & Dementia*. <http://dx.doi.org/10.1016/j.jalz.2018.02.001>

Anguita, D., Ghio, A., Oneto, L., Parra, X. et Reyes-Ortiz, J. L. (2012). Human activity recognition on smartphones using a multiclass hardware-friendly support vector machine. Dans *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*. http://dx.doi.org/10.1007/978-3-642-35395-6_30

Anliker, U., Ward, J., Lukowicz, P., Troster, G., Dolveck, F., Baer, M., Keita, F., Schenker, E., Catarsi, F., Coluccini, L., Belardinelli, A., Shklarski, D., Alon, M., Hirt, E., Schmid, R. et Vuskovic, M. (2004). AMON : A Wearable Multiparameter Medical

Monitoring and Alert System. *IEEE Transactions on Information Technology in Biomedicine*, 8(4), 415–427. <http://dx.doi.org/10.1109/TITB.2004.837888>

Ayuningtyas, C., Leitner, G., Hitz, M., Funk, M., Hu, J. et Rauterberg, M. (2014). Activity monitoring for multi-inhabitant smart homes. *SPIE Newsroom*. <http://dx.doi.org/10.1117/2.1201412.005697>

Bae, J. et Tomizuka, M. (2013). A tele-monitoring system for gait rehabilitation with an inertial measurement unit and a shoe-type ground reaction force sensor. *Mechatronics*. <http://dx.doi.org/10.1016/j.mechatronics.2013.06.007>

Bamberg, S. J., Benbasat, A. Y., Scarborough, D. M., Krebs, D. E. et Paradiso, J. A. (2008). Gait analysis using a shoe-integrated wireless sensor system. *IEEE Transactions on Information Technology in Biomedicine*. <http://dx.doi.org/10.1109/TITB.2007.899493>

Banos, O., Galvez, J.-M., Damas, M., Pomares, H. et Rojas, I. (2014). Window size impact in human activity recognition. *Sensors (Basel, Switzerland)*. <http://dx.doi.org/10.3390/s140406474>

Bao, L. et Intille, S. S. (2004). Activity Recognition from User-Annotated Acceleration Data. In *Pervasive Computing* 1–17.

Bayat, A., Pomplun, M. et Tran, D. A. (2014). A Study on Human Activity Recognition Using Accelerometer Data from Smartphones. *Procedia Computer Science*, 34, 450–457. <http://dx.doi.org/10.1016/J.PROCS.2014.07.009>

Belley, C., Gaboury, S., Bouchard, B. et Bouzouane, A. (2014). An efficient and inexpensive method for activity recognition within a smart home based on load signatures of appliances. Dans *Pervasive and Mobile Computing*. <http://dx.doi.org/10.1016/j.pmcj.2013.02.002>

Bellman, R. E. (1957). *Dynamic Programming*. Princeton University Press.

Ben-David, A. (2007). A lot of randomness is hiding in accuracy. *Engineering Applications of Artificial Intelligence*. <http://dx.doi.org/10.1016/j.engappai.2007.01.001>

Benatti, S., Casamassima, F., Milosevic, B., Farella, E., Schonle, P., Fateh, S., Burger,

T., Huang, Q. et Benini, L. (2015). A Versatile Embedded Platform for EMG Acquisition and Gesture Recognition. *IEEE Transactions on Biomedical Circuits and Systems*, 9(5), 620–630. <http://dx.doi.org/10.1109/TBCAS.2015.2476555>

Bergmann, O., Hillmann, K. T. et Gerdes, S. (2012). A CoAP-gateway for smart homes. Dans *2012 International Conference on Computing, Networking and Communications, ICNC'12*, 446–450., Maui, HI, USA. IEEE. <http://dx.doi.org/10.1109/ICCNC.2012.6167461>

Bibuli, M., Caccia, M. et Lapierre, L. (2007). Path-Following Algorithms and Experiments for an Autonomous Surface Vehicle. *IFAC Proceedings Volumes*, 40(17), 81–86. <http://dx.doi.org/10.3182/20070919-3-HR-3904.00015>

Bluetooth, S. (2017). Mesh Networking Specifications. Récupéré le 2018-02-10 de <https://bit.ly/2P400M2>

Boger, J., Hoey, J., Poupart, P., Boutilier, C., Fernie, G. et Mihailidis, A. (2006). A planning system based on Markov decision processes to guide people with dementia through activities of daily living. *IEEE transactions on information technology in biomedicine : a publication of the IEEE Engineering in Medicine and Biology Society*. <http://dx.doi.org/10.1109/TITB.2006.864480>

Bouchard, B., Giroux, S. et Bouzouane, A. (2007). A keyhole plan recognition model for alzheimer's patients : First results. *Applied Artificial Intelligence*. <http://dx.doi.org/10.1080/08839510701492579>

Bouchard, K., Bouchard, B. et Bouzouane, A. (2014). Practical Guidelines to Build Smart Homes : Lessons Learned. In T. & F. CRC press (dir.), *Opportunistic networking, smart home, smart city, smart systems*, numéro January 2015 1–37.

Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32. <http://dx.doi.org/https://doi.org/10.1023/A:1010933404324>

Brigham, E. O. et Morrow, R. E. (1967). The fast Fourier transform. *IEEE Spectrum*. <http://dx.doi.org/10.1109/MSPEC.1967.5217220>

Brumitt, B., Meyers, B., Krumm, J., Kern, A. et Shafer, S. (2000). Easyliving : Technologies for intelligent environments. Dans *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*. http://dx.doi.org/10.1007/3-540-39959-3_2

Buettner, M., Prasad, R., Philipose, M. et Wetherall, D. (2009). Recognizing daily activities with RFID-based sensors. Dans *Proceedings of the 11th international conference on Ubiquitous computing - Ubicomp '09*. <http://dx.doi.org/10.1145/1620545.1620553>

Butterworth, S. (1930). On the theory of filter amplifiers. <http://dx.doi.org/citeulike-article-id:5322726>

Chang, Y. S., Hung, Y. S., Chang, C. L. et Juang, T. Y. (2009). Toward a NFC phone-driven context awareness smart environment. Dans *UIC-ATC 2009 - Symposia and Workshops on Ubiquitous, Autonomic and Trusted Computing in Conjunction with the UIC'09 and ATC'09 Conferences*, Brisbane, QLD, Australia. IEEE. <http://dx.doi.org/10.1109/UIC-ATC.2009.37>

Chapelle, O., Schölkopf, B., Chapelle, O., Schölkopf, B. et Rai, P. (2006). *Semi-Supervised Learning*. <http://dx.doi.org/10.1007/s12539-009-0016-2>

Chapron, K., Plantevin, V., Thullier, F., Bouchard, K., Duchesne, E. et Gaboury, S. (2018). A More Efficient Transportable and Scalable System for Real-Time Activities and Exercises Recognition. *Sensors*, 18(1), 268. <http://dx.doi.org/10.3390/s18010268>

Chen, Y., Zhao, Z., Wang, S. et Chen, Z. (2012). Extreme learning machine-based device displacement free activity recognition model. *Soft Computing*. <http://dx.doi.org/10.1007/s00500-012-0822-8>

Cheng, S. T., Wang, C. H. et Horng, G. J. (2012). OSGi-based smart home architecture for heterogeneous network. *Expert Systems with Applications*. <http://dx.doi.org/10.1016/j.eswa.2012.04.077>

Cho, W. T., Lai, Y. X., Lai, C. F. et Huang, Y. M. (2013). Appliance-aware activity recognition mechanism for iot energy management system. *Computer Journal*, 56(8), 1020–1033. <http://dx.doi.org/10.1093/comjnl/bxt047>

Cleland, I., Kikhia, B., Nugent, C., Boytsov, A., Hallberg, J., Synnes, K., McClean, S. et Finlay, D. (2013). Optimal placement of accelerometers for the detection of everyday activities. *Sensors (Basel, Switzerland)*. <http://dx.doi.org/10.3390/s130709183>

Cook, D. J., Crandall, A. S., Thomas, B. L. et Krishnan, N. C. (2013). CASAS : A

smart home in a box. *Computer*. <http://dx.doi.org/10.1109/MC.2012.328>

Cook, D. J. et Schmitter-Edgecombe, M. (2009). Assessing the quality of activities in a smart environment. Dans *Methods of Information in Medicine*. <http://dx.doi.org/10.3414/ME0592>

Cook, D. J., Youngblood, M., O.Heierman, E., Gopalratnam, K., Rao, S., Litvin, A. et Khawaja, F. (2003). MavHome : an agent-based smart home. *Proceedings of the First IEEE International Conference On Pervasive Computing And Communications*. <http://dx.doi.org/10.1109/PERCOM.2003.1192783>

Crandall, A. S. et Cook, D. J. (2009). Coping with multiple residents in a smart environment. *Journal of Ambient Intelligence and Smart Environments*. <http://dx.doi.org/10.3233/AIS-2009-0041>

Crea, S., De Rossi, S. M., Donati, M., Reberšek, P., Novak, D., Vitiello, N., Lenzi, T., Podobnik, J., Munih, M. et Carrozza, M. C. (2012). Development of gait segmentation methods for wearable foot pressure sensors. Dans *Proceedings of the Annual International Conference of the IEEE Engineering in Medicine and Biology Society, EMBS*. <http://dx.doi.org/10.1109/EMBC.2012.6347120>

Cruz, F. R. G., Sejera, M. P., Bunnao, M. B. G., Jovellanos, B. R., Maano, P. L. C. et Santos, C. J. R. (2018). Fall detection wearable device interconnected through ZigBee network. Dans *HNICEM 2017 - 9th International Conference on Humanoid, Nanotechnology, Information Technology, Communication and Control, Environment and Management*, 1–6. IEEE. <http://dx.doi.org/10.1109/HNICEM.2017.8269563>

Cubo, J., Nieto, A. et Pimentel, E. (2014). A cloud-based internet of things platform for ambient assisted living. *Sensors*, 14(8), 14070–14105. <http://dx.doi.org/10.3390/s140814070>

Davis, K., Owusu, E., Bastani, V., Marcenaro, L., Hu, J., Regazzoni, C. et Feijs, L. (2016). Activity recognition based on inertial sensors for Ambient Assisted Living. Dans *19th International Conference on Information Fusion (FUSION)*, 371–378., Heidelberg.

Delachaux, B., Rebetez, J., Perez-Uribe, A. et Satizábal Mejia, H. F. (2013). Indoor activity recognition by combining One-vs.-All neural network classifiers exploiting wearable and depth sensors. Dans *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*.

http://dx.doi.org/10.1007/978-3-642-38682-4_25

Delahoz, Y. S. et Labrador, M. A. (2014). Survey on fall detection and fall prevention using wearable and external sensors. <http://dx.doi.org/10.3390/s141019806>

Díaz-Rodríguez, N., Grönroos, S., Wickström, F., Lilius, J., Eertink, H., Braun, A., Dillen, P., Crowley, J. et Alexandersson, J. (2018). An ontology for wearables data interoperability and ambient assisted living application development. In *Studies in Fuzziness and Soft Computing* 559–568. Springer International Publishing

Dossot, D. (2014). *RabbitMQ Essentials*. Packt Publishing.

Emi, I. A. et Stankovic, J. A. (2015). SARRIMA : Smart ADL Recognizer and Resident Identifier in Multi-resident Accommodations. *Proceedings of the Conference on Wireless Health*. <http://dx.doi.org/10.1145/2811780.2811916>

Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters*. <http://dx.doi.org/10.1016/j.patrec.2005.10.010>

Fielding, R. (2000). *Architectural Styles and the Design of Network-based Software Architectures*. (Thèse de doctorat). University of California, Irvine. <http://dx.doi.org/10.1.1.91.2433>

Fielding, R. et Reschke, J. (2014). Hypertext Transfer Protocol (HTTP/1.1) : Message Syntax and Routing. <http://dx.doi.org/10.17487/RFC7230>. Récupéré de <https://www.rfc-editor.org/info/rfc7230>

Figo, D., Diniz, P. C., Ferreira, D. R. et Cardoso, J. M. P. (2010). Preprocessing techniques for context recognition from accelerometer data. *Personal and Ubiquitous Computing*. <http://dx.doi.org/10.1007/s00779-010-0293-9>

Fortin-Simard, D., Bilodeau, J.-S., Bouchard, K., Gaboury, S., Bouchard, B. et Bouzouane, A. (2015). Exploiting Passive RFID Technology for Activity Recognition in Smart Homes. *IEEE Intelligent Systems*. <http://dx.doi.org/10.1109/MIS.2015.18>

Friedman, N., Geiger, D. et Goldszmit, M. (1997). Bayesian Network Classifiers. *Machine Learning*. <http://dx.doi.org/10.1023/a:1007465528199>

Gao, L., Bourke, A. et Nelson, J. (2014). Evaluation of accelerometer based multi-sensor versus single-sensor activity recognition systems. *Medical Engineering & Physics*, 36(6), 779–785. <http://dx.doi.org/10.1016/J.MEDENGPHY.2014.02.012>

Garcia-Ceja, E., Brena, R., Carrasco-Jimenez, J., Garrido, L., Garcia-Ceja, E., Brena, R. F., Carrasco-Jimenez, J. C. et Garrido, L. (2014). Long-Term Activity Recognition from Wristwatch Accelerometer Data. *Sensors*, 14(12), 22500–22524. <http://dx.doi.org/10.3390/s141222500>

Gaskin, J., Jenkins, J., Meservy, T., Steffen, J. et Payne, K. (2017). Using Wearable Devices for Non-invasive, Inexpensive Physiological Data Collection. *Proceedings of the 50th Hawaii International Conference on System Sciences*. <http://dx.doi.org/10.24251/HICSS.2017.072>

Ghayvat, H., Mukhopadhyay, S., Shenjie, B., Chouhan, A. et Chen, W. (2018). Smart home based ambient assisted living : Recognition of anomaly in the activity of daily living for an elderly living alone. Dans *I2MTC 2018 - 2018 IEEE International Instrumentation and Measurement Technology Conference : Discovering New Horizons in Instrumentation and Measurement, Proceedings*, 1–5. IEEE. <http://dx.doi.org/10.1109/I2MTC.2018.8409885>

Ghazvininejad, M., Rabiee, H. R., Pourdanghani, N. et Khanipour, P. (2011). HMM based semi-supervised learning for activity recognition. Dans *Proceedings of the 2011 international workshop on Situation activity & goal awareness - SAGAware '11*. <http://dx.doi.org/10.1145/2030045.2030065>

Giovannetti, T., Libon, D. J., Buxbaum, L. J. et Schwartz, M. F. (2002). Naturalistic action impairments in dementia. *Neuropsychologia*. [http://dx.doi.org/10.1016/S0028-3932\(01\)00229-9](http://dx.doi.org/10.1016/S0028-3932(01)00229-9)

Giroux, S., Leblanc, T., Bouzouane, A., Bouchard, B., Pigot, H. et Bauchet, J. (2009). The Praxis of Cognitive Assistance in Smart Homes. *BMI Book*. <http://dx.doi.org/10.3233/978-1-60750-048-3-183>

Godfrey, A., Hetherington, V., Shum, H., Bonato, P., Lovell, N. H. et Stuart, S. (2018). From A to Z : Wearable technology explained. *Maturitas*, 113, 40–47. <http://dx.doi.org/10.1016/j.maturitas.2018.04.012>

Gomez, C., Oller, J. et Paradells, J. (2012). Overview and evaluation of bluetooth low

energy : An emerging low-power wireless technology. *Sensors*, 12(9), 11734–11753. <http://dx.doi.org/10.3390/s120911734>

Guenterberg, E., Ostadabbas, S., Ghasemzadeh, H. et Jafari, R. (2009). An Automatic Segmentation Technique in Body Sensor Networks based on Signal Energy. Dans *Proceedings of the 4th International ICST Conference on Body Area Networks*, p. 21. ICST. <http://dx.doi.org/10.4108/ICST.BODYNETS2009.6036>

Harris, C. et Hunter, S. (2016). Smart-home technologies were found to support some domains of independent living when ageing at home : Perspectives of older adult consumers' families, health professionals and service providers. *Australian Occupational Therapy Journal*, 63(6), 439–440. <http://dx.doi.org/10.1111/1440-1630.12323>

Haux, R., Koch, S., Lovell, N., Marschollek, M., Nakashima, N. et Wolf, K.-H. (2016). Health-Enabling and Ambient Assistive Technologies : Past, Present, Future. *Yearbook of Medical Informatics*, 25(S 01), S76–S91. <http://dx.doi.org/10.15265/IYS-2016-s008>

He, Z. et Jin, L. (2009). Activity recognition from acceleration data based on discrete cosine transform and SVM. Dans *Conference Proceedings - IEEE International Conference on Systems, Man and Cybernetics*. <http://dx.doi.org/10.1109/ICSMC.2009.5346042>

Heckerman, D., Geiger, D. et Chickering, D. M. (1995). Learning Bayesian Networks : The Combination of Knowledge and Statistical Data. *Machine Learning*. <http://dx.doi.org/10.1023/A:1022623210503>

Helal, S., Mann, W., El-Zabadani, H., King, J., Kaddoura, Y. et Jansen, E. (2005). The Gator tech smart house : A programmable pervasive space. *Computer*. <http://dx.doi.org/10.1109/MC.2005.107>

Hintjens, P. (2013). *ZeroMQ Messaging for Many Applications*. O'Reilly Media.

Hu, Y., Tilke, D., Adams, T., Crandall, A. S., Cook, D. J. et Schmitter-Edgecombe, M. (2016). Smart home in a box : usability study for a large scale self-installation of smart home technologies. *Journal of Reliable Intelligent Environments*. <http://dx.doi.org/10.1007/s40860-016-0021-y>

Huang, T. S., Yang, G. J. et Tang, G. Y. (1979). A Fast Two-Dimensional Median

Filtering Algorithm. *IEEE Transactions on Acoustics, Speech, and Signal Processing*. <http://dx.doi.org/10.1109/TASSP.1979.1163188>

Hui, T. K., Sherratt, R. S. et Sánchez, D. D. (2017). Major requirements for building Smart Homes in Smart Cities based on Internet of Things technologies. *Future Generation Computer Systems*, 76, 358–369. <http://dx.doi.org/10.1016/j.future.2016.10.026>

Hunkeler, U., Truong, H. L. et Stanford-Clark, A. (2008). MQTT-S - A publish/subscribe protocol for wireless sensor networks. Dans *3rd IEEE/Create-Net International Conference on Communication System Software and Middleware, COMSWARE*, 791–798., Bangalore, India. IEEE. <http://dx.doi.org/10.1109/COMSWA.2008.4554519>. Récupéré de <http://ieeexplore.ieee.org/document/4554519/>

Huynh, T. et Schiele, B. (2005). Analyzing features for activity recognition. Dans *Proceedings of the 2005 joint conference on Smart objects and ambient intelligence innovative context-aware services : usages and technologies - sOc-EUSAI '05*. <http://dx.doi.org/10.1145/1107548.1107591>

Inomata, T., Naya, F., Kuwahara, N., Hattori, F. et Kogure, K. (2009). Activity Recognition from Interactions with Objects Using Dynamic Bayesian Network. Dans *Proceedings of the 3rd ACM International Workshop on Context-Awareness for Self-Managing Systems*. <http://dx.doi.org/10.1145/1538864.1538871>

International Telecommunication Union (2012). *Overview of the Internet of things*. Rapport technique, Geneva, Switzerland.

Istepanian, R. S. H., Hu, S., Philip, N. Y. et Sungoor, A. (2011). The potential of Internet of m-health Things “m-IoT” for non-invasive glucose level sensing. Dans *2011 Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, 5264–5266., Boston, MA, USA. IEEE. <http://dx.doi.org/10.1109/IEMBS.2011.6091302>

Johnson, I. et Ianes, P. (2018). Frail Elderly Persons and Smart Home Technologies. In S. Masiero et U. Carraro (dir.), *Rehabilitation Medicine for Elderly Patients* 119–123. Cham : Springer International Publishing

Jung, P.-G., Lim, G., Kim, S. et Kong, K. (2015). A Wearable Gesture Recognition Device for Detecting Muscular Activities Based on Air-Pressure Sensors. *IEEE*

Transactions on Industrial Informatics, 11(2), 485–494. <http://dx.doi.org/10.1109/TII.2015.2405413>

Katz, S., Ford, A. B., Moskowitz, R. W., Jackson, B. A. et Jaffe, M. W. (1963). Studies of Illness in the Aged : The Index of ADL : A Standardized Measure of Biological and Psychosocial Function. *JAMA : The Journal of the American Medical Association*. <http://dx.doi.org/10.1001/jama.1963.03060120024016>

Kertesz, C. (2016). Rigidity-Based Surface Recognition for a Domestic Legged Robot. *IEEE Robotics and Automation Letters*, 1(1), 309–315. <http://dx.doi.org/10.1109/LRA.2016.2519949>

Khan, A. M. (2011). Human Activity Recognition Using A Single Tri-axial Accelerometer. *Computer Engineering*. <http://dx.doi.org/10.1587/transfun.E93.A.1379>

Khan, Y., Ostfeld, A. E., Lochner, C. M., Pierre, A. et Arias, A. C. (2016). Monitoring of Vital Signs with Flexible and Wearable Medical Devices. *Advanced Materials*, 28(22), 4373–4395. <http://dx.doi.org/10.1002/adma.201504366>

Kohavi, R. (1995). A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection. Dans *IJCAI'95 Proceedings of the 14th international joint conference on Artificial intelligence*, volume 2, 1137–1143., Montreal, QC, Canada. Morgan Kaufmann Publishers Inc.

Kovashka, A. et Grauman, K. (2010). Learning a hierarchy of discriminative space-time neighborhood features for human action recognition. Dans *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*. <http://dx.doi.org/10.1109/CVPR.2010.5539881>

Kovatsch, M., Duquenooy, S. et Dunkels, A. (2011). A low-power CoAP for Contiki. Dans *8th IEEE International Conference on Mobile Ad-hoc and Sensor Systems, MASS 2011*, 855–860., Valencia, Spain. IEEE. <http://dx.doi.org/10.1109/MASS.2011.100>

Lago, P., Lang, F., Roncancio, C., Jiménez-Guarín, C., Mateescu, R. et Bonnefond, N. (2017). The contextact@A4H real-life dataset of daily-living activities activity recognition using model checking. Dans *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, volume 10257 LNAI, 175–188. <http://dx.doi.org/10.1007/>

Lawton, M. P. et Brody, E. M. (1969). Assessment of Older People : Self-Maintaining and Instrumental Activities of Daily Living. *The Gerontologist*. http://dx.doi.org/10.1093/geront/9.3_Part_1.179

Lee, C., Zappaterra, L., Choi, K. et Choi, H. A. (2014). Securing smart home : Technologies, security challenges, and security requirements. Dans *2014 IEEE Conference on Communications and Network Security*, 67–72., San Francisco, CA, USA. IEEE. <http://dx.doi.org/10.1109/CNS.2014.6997467>

Leightley, D., Darby, J. et McPhee, J. S. (2013). Human Activity Recognition for Physical Rehabilitation. *2013 IEEE International Conference on Systems, Man, and Cybernetics*. <http://dx.doi.org/10.1109/SMC.2013.51>

Li, X., Zhang, Y., Marsic, I., Sarcevic, A. et Burd, R. S. (2016). Deep Learning for RFID-Based Activity Recognition. Dans *Proceedings of the 14th ACM Conference on Embedded Network Sensor Systems CD-ROM - SenSys '16*. <http://dx.doi.org/10.1145/2994551.2994569>

Mainetti, L., Mighali, V. et Patrono, L. (2015). An IoT-based user-centric ecosystem for heterogeneous Smart Home environments. Dans *2015 IEEE International Conference on Communications (ICC)*, 704–709., London, UK. IEEE. <http://dx.doi.org/10.1109/ICC.2015.7248404>

Mallat, S. G. (1989). A Theory for Multiresolution Signal Decomposition : The Wavelet Representation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*. <http://dx.doi.org/10.1109/34.192463>

Mannini, A., Rosenberger, M., Haskell, W. L., Sabatini, A. M. et Intille, S. S. (2017). Activity recognition in youth using single accelerometer placed at wrist or ankle. *Medicine and Science in Sports and Exercise*. <http://dx.doi.org/10.1249/MSS.0000000000001144>

Martin, J. (2014). Bluetooth Smart's Rise From Obscurity to Mainstream. Récupéré le 2018-10-02 de <https://ubm.io/2NVafaN>

Messing, R., Pal, C. et Kautz, H. (2009). Activity recognition using the velocity histories of tracked keypoints. Dans *Proceedings of the IEEE International Conference on Computer Vision*. <http://dx.doi.org/10.1109/ICCV.2009.5459154>

Mihailidis, A., Barbenel, J. C. et Fernie, G. (2004). The efficacy of an intelligent cognitive orthosis to facilitate handwashing by persons with moderate to severe dementia. <http://dx.doi.org/10.1080/09602010343000156>

Mitchell, E., Monaghan, D. et O'Connor, N. E. (2013). Classification of sporting activities using smartphone accelerometers. *Sensors (Switzerland)*. <http://dx.doi.org/10.3390/s130405317>

Mokhtari, G., Anvari-Moghaddam, A., Zhang, Q. et Karunanithi, M. (2018). Multi-residential activity labelling in smart homes with wearable tags using BLE technology. *Sensors (Switzerland)*. <http://dx.doi.org/10.3390/s18030908>

Mukhopadhyay, S. C. (2014). Wearable sensors for human activity monitoring : A review. *IEEE Sensors Journal*. <http://dx.doi.org/10.1109/JSEN.2014.2370945>

Nazerfard, E., Das, B., Holder, L. B. et Cook, D. J. (2010). Conditional random fields for activity recognition in smart environments. Dans *Proceedings of the ACM international conference on Health informatics - IHI '10*, p. 282., New York, New York, USA. ACM Press. <http://dx.doi.org/10.1145/1882992.1883032>

Nielsen, C. (2014). Tech-Styles : are Consumers Really Interested In Wearing Tech on Their Sleeves ? Récupéré le 2019-09-18 de <https://bit.ly/2kQvX2h>

Novák, M. et Binas, M. (2011). An architecture overview of the smart-home system based on OSGi. Dans *SCYR 2011 : 11th Scientific Conference of Young Researchers of Faculty of Electrical Engineering and Informatics Technical University of Košice*, 221–224.

NPD Group (2015). The Demographic Divide : Fitness Trackers and Smartwatches Attracting Very Different Segments of the Market, According to The NPD Group. Récupéré le 2019-09-20 de <https://bit.ly/1IRegAj>

Oliver, N., Garg, A. et Horvitz, E. (2004). Layered representations for learning and inferring office activity from multiple sensory channels. Dans *Computer Vision and Image Understanding*. <http://dx.doi.org/10.1016/j.cviu.2004.02.004>

ON World Inc. (2017). *Bluetooth Low Energy IoT : A Market Dynamics Report*.

Ondrus, J. et Pigneur, Y. (2007). An assessment of NFC for future mobile payment systems. Dans *Conference Proceedings - 6th International Conference on the Management of Mobile Business, ICMB 2007*. IEEE. <http://dx.doi.org/10.1109/ICMB.2007.9>

Otis, M. J. D., Ayena, J. C., Tremblay, L. E., Fortin, P. E. et Ménélas, B.-A. J. (2016). Use of an Enactive Insole for Reducing the Risk of Falling on Different Types of Soil Using Vibrotactile Cueing for the Elderly. *PLOS ONE*, 11(9), e0162107. <http://dx.doi.org/10.1371/journal.pone.0162107>

Paraponaris, A., Davin, B. et Verger, P. (2012). Formal and informal care for disabled elderly living in the community : An appraisal of French care composition and costs. *European Journal of Health Economics*, 13(3), 327–336. <http://dx.doi.org/10.1007/s10198-011-0305-3>

Pärkkä, J., Ermes, M., Korpipää, P., Mäntyjärvi, J., Peltola, J. et Korhonen, I. (2006). Activity classification using realistic data from wearable sensors. *IEEE transactions on information technology in biomedicine : a publication of the IEEE Engineering in Medicine and Biology Society*. <http://dx.doi.org/10.1109/TITB.2005.856863>

Patel, S., Park, H., Bonato, P., Chan, L. et Rodgers, M. (2012). A review of wearable sensors and systems with application in rehabilitation. <http://dx.doi.org/10.1186/1743-0003-9-21>

Patterson, D. J., Fox, D., Kautz, H. et Philipose, M. (2005). Fine-grained activity recognition by aggregating abstract object usage. Dans *Proceedings - International Symposium on Wearable Computers, ISWC*. <http://dx.doi.org/10.1109/ISWC.2005.22>

Pering, T., Anokwa, Y. et Want, R. (2007). Gesture connect : Facilitating tangible interaction with a flick of the wrist. Dans *1st International Conference on Tangible and Embedded Interaction*, Baton Rouge, Louisiana, USA. ACM. <http://dx.doi.org/10.1145/1226969.1227022>

Perumal, T., Ramli, A. R., Leong, C. Y., Mansor, S. et Samsudin, K. (2008). Interoperability among Heterogeneous Systems in Smart Home Environment. Dans *SITIS 2008 - Proceedings of the 4th International Conference on Signal Image Technology and Internet Based Systems*, 177–186., Bali, Indonesia. IEEE. <http://dx.doi.org/10.1109/SITIS.2008.94>

Plantevin, V. (2018). *Une nouvelle architecture distribuée pour la reconnaissance d'activités au sein d'une maison intelligente*. (Thèse de doctorat). Université du Québec à Chicoutimi. Récupéré de <https://constellation.uqac.ca/4573/>

Plantevin, V., Bouzouane, A., Bouchard, B. et Gaboury, S. (2018). Towards a more reliable and scalable architecture for smart home environments. *Journal of Ambient Intelligence and Humanized Computing*. <http://dx.doi.org/10.1007/s12652-018-0954-5>

Plantevin, V., Bouzouane, A. et Gaboury, S. (2017). The light node communication framework : A new way to communicate inside smart homes. *Sensors*, 17(10), 2397–2416. <http://dx.doi.org/10.3390/s17102397>

Prince, M., Comas-Herrera, A., Knapp, M., Guerchet, M. et Karagiannidou, M. (2016). World Alzheimer Report 2016 Improving healthcare for people living with dementia. Coverage, Quality and costs now and in the future. *Alzheimer's Disease International (ADI)*. <http://dx.doi.org/10.13140/RG.2.2.22580.04483>

Quinlan Ross, J. (1993). C4. 5 : Programs For Machine Learning. [http://dx.doi.org/10.1016/S0019-9958\(62\)90649-6](http://dx.doi.org/10.1016/S0019-9958(62)90649-6)

Rahmani, A. M., Thanigaivelan, N. K., Gia, T. N., Granados, J., Negash, B., Liljeberg, P. et Tenhunen, H. (2015). Smart e-Health Gateway : Bringing intelligence to Internet-of-Things based ubiquitous healthcare systems. Dans *2015 12th Annual IEEE Consumer Communications and Networking Conference, CCNC 2015*, 826–834. IEEE. <http://dx.doi.org/10.1109/CCNC.2015.7158084>

Rashidi, P. et Mihailidis, A. (2013). A survey on ambient-assisted living tools for older adults. *IEEE Journal of Biomedical and Health Informatics*. <http://dx.doi.org/10.1109/JBHI.2012.2234129>

Ravi, N., Dandekar, N., Mysore, P. et Littman, M. M. L. (2005). Activity Recognition from Accelerometer Data. Dans *Proceedings of the 17th Conference on Innovative Applications of Artificial Intelligence*, 1541–1546., Pittsburgh, PA, USA. http://dx.doi.org/10.1007/978-3-642-02481-8_120

Rogers, W. A., Meyer, B., Walker, N. et Fisk, A. D. (1998). Functional Limitations to Daily Living Tasks in the Aged : A Focus Group Analysis. *Human Factors : The Journal of the Human Factors and Ergonomics Society*. <http://dx.doi.org/10.1518/001872098779480613>

Roy, P. C., Bouchard, B., Bouzouane, A. et Giroux, S. (2013). Ambient Activity Recognition in Smart Environments for Cognitive Assistance. *International Journal of Robotics Applications and Technologies (IJRAT)*, 1(1), 29–56. <http://dx.doi.org/10.4018/ijrat.2013010103>

Russell, S. J. et Norvig, P. (2010). *Artificial Intelligence : A Modern Approach* (3rd éd.). Pearson.

Sadri, F. (2011). Ambient intelligence : A Survey. *ACM Computing Surveys*. <http://dx.doi.org/10.1145/1978802.1978815>

Saint-Andre, P. (2011). *Extensible Messaging and Presence Protocol (XMPP) : Core*. Rapport technique

Sanford, J., Young, C., Cremer, S., Popa, D., Bugnariu, N. et Patterson, R. (2015). Grip Pressure and Wrist Joint Angle Measurement during Activities of Daily Life. *Procedia Manufacturing*. <http://dx.doi.org/10.1016/j.promfg.2015.07.321>

Sant'Anna, A. et Wickström, N. (2010). A symbol-based approach to gait analysis from acceleration signals : Identification and detection of gait events and a new measure of gait symmetry. *IEEE Transactions on Information Technology in Biomedicine*. <http://dx.doi.org/10.1109/TITB.2010.2047402>

Schmidt, C. F., Sridharan, N. S. et Goodson, J. L. (1978). The plan recognition problem : An intersection of psychology and artificial intelligence. [http://dx.doi.org/10.1016/0004-3702\(78\)90012-7](http://dx.doi.org/10.1016/0004-3702(78)90012-7)

Sekine, M., Tamura, T., Togawa, T. et Fukui, Y. (2000). Classification of waist-acceleration signals in a continuous walking record. *Medical Engineering & Physics*, 22(4), 285–291. [http://dx.doi.org/10.1016/S1350-4533\(00\)00041-2](http://dx.doi.org/10.1016/S1350-4533(00)00041-2)

Seon-Woo Lee et Mase, K. (2002). Activity and location recognition using wearable sensors. *IEEE Pervasive Computing*, 1(3), 24–32. <http://dx.doi.org/10.1109/MPRV.2002.1037719>

Shelby, Z. (2010). Embedded web services. *IEEE Wireless Communications*, 17(6), 52–57. <http://dx.doi.org/10.1109/MWC.2010.5675778>

Shelby, Z., Hartke, K. et Bormann, C. (2014). The constrained application protocol

(CoAP). <http://dx.doi.org/10.17487/RFC7252>

Stikic, M., Huynh, T., Van Laerhoven, K. et Schiele, B. (2008). ADL recognition based on the combination of RFID and accelerometer sensing. *2008 Second International Conference on Pervasive Computing Technologies for Healthcare*. <http://dx.doi.org/10.1109/PCTHEALTH.2008.4571084>

Sun, W., Choi, M. et Choi, S. (2013). IEEE 802.11 ah : A long range 802.11 WLAN at sub 1 GHz. *Journal of ICT Standardization*. <http://dx.doi.org/10.13052/jicts2245-800X>

Sysel, P. et Rajmic, P. (2012). Goertzel algorithm generalized to non-integer multiples of fundamental frequency. *Eurasip Journal on Advances in Signal Processing*. <http://dx.doi.org/10.1186/1687-6180-2012-56>

Tanenbaum, A. S. et Wetherall, D. J. (2010). *Computer Networks* (5th éd.). Upper Saddle River, NJ, USA : Prentice Hall Press.

Tapia, E. M., Intille, S. S., Haskell, W., Larson, K. W. J., King, A. et Friedman, R. (2007). Real-Time Recognition of Physical Activities and their Intensities Using Wireless Accelerometers and a Heart Monitor. *International Symposium on Wearable Computers*. <http://dx.doi.org/10.1109/ISWC.2007.4373774>

Taplett, N. (2014). Bluetooth Smart Technology from Trend To Standard. Récupéré le 2017-02-10 de <http://bit.ly/217SDJt>

Tavakoli, M., Benussi, C., Alhais Lopes, P., Osorio, L. B. et de Almeida, A. T. (2018). Robust hand gesture recognition with a double channel surface EMG wearable armband and SVM classifier. *Biomedical Signal Processing and Control*, 46, 121–130. <http://dx.doi.org/10.1016/J.BSPC.2018.07.010>

Thullier, F., Plantevin, V., Bouzouane, A., Halle, S. et Gaboury, S. (2017). A position-independent method for soil types recognition using inertial data from a wearable device. Dans *2017 IEEE SmartWorld, Ubiquitous Intelligence & Computing, Advanced & Trusted Computing, Scalable Computing & Communications, Cloud & Big Data Computing, Internet of People and Smart City Innovation (SmartWorld/SCALCOM/UIC/ATC/CBDCom/IOP/SCI)*, 1–10., San Francisco, CA, USA. IEEE. <http://dx.doi.org/10.1109/UIC-ATC.2017.8397511>

Thullier, F., Plantevin, V., Bouzouane, A., Halle, S. et Gaboury, S. (2018). A Com-

parison of Inertial Data Acquisition Methods for a Position-Independent Soil Types Recognition. Dans *2018 IEEE SmartWorld, Ubiquitous Intelligence & Computing, Advanced & Trusted Computing, Scalable Computing & Communications, Cloud & Big Data Computing, Internet of People and Smart City Innovation (SmartWorld/SCALCOM/UIC/ATC/CBDCom/IOP/SCI)*, 1052–1056., Guangzhou, China. IEEE. <http://dx.doi.org/10.1109/SmartWorld.2018.00183>

Tunca, C., Alemdar, H., Ertan, H., Incel, O. D. et Ersoy, C. (2014). Multimodal wireless sensor network-based ambient assisted living in real homes with multiple residents. *Sensors (Switzerland)*. <http://dx.doi.org/10.3390/s140609692>

UNFPA (2007). The State of the World Population 2007 - Unleashing The Potential of Urban Growth. *Linking Population, Poverty and Development*. <http://dx.doi.org/ISBN978-0-89714-807-8>

United Nations. (2015). *World Population Ageing 2015*. <http://dx.doi.org/ST/ESA/SER.A/390>

United Nations (2017a). The Sustainable Development Goals Report. *United Nations Publications*. <http://dx.doi.org/10.18356/3405d09f-en>

United Nations (2017b). *World Population Prospects The 2017 Revision Key Findings and Advance Tables*. Rapport technique

Upadhyay, Y., Borole, A. et Dileepan, D. (2016). MQTT based secured home automation system. Dans *2016 Symposium on Colossal Data Analysis and Networking (CDAN)*, 1–4., Indore, India. IEEE. <http://dx.doi.org/10.1109/CDAN.2016.7570945>

Vacher, M., Istrate, D., Portet, F., Joubert, T., Chevalier, T., Smidtas, S., Meillon, B., Lecouteux, B., Sehili, M., Chahuara, P. et Méniard, S. (2011). The SWEET-HOME project : Audio technology in smart homes to improve well-being and reliance. Dans *Proceedings of the Annual International Conference of the IEEE Engineering in Medicine and Biology Society, EMBS*. <http://dx.doi.org/10.1109/IEMBS.2011.6091309>

Vail, D. et Veloso, M. (2004). Learning from accelerometer data on a legged robot. *IFAC Proceedings Volumes*, 37(8), 822–827. [http://dx.doi.org/10.1016/S1474-6670\(17\)32082-7](http://dx.doi.org/10.1016/S1474-6670(17)32082-7)

Van Den Bossche, A., Gonzalez, N., Val, T., Brulin, D., Vella, F., Vigouroux, N. et Campo, E. (2018). Specifying an MQTT Tree for a Connected Smart Home. Dans M. Mokhtari, B. Abdulrazak, et H. Aloulou (dir.). *Smart Homes and Health Telematics, Designing a Better Future : Urban Assisted Living (ICOST)*, 236–246., Cham. Springer International Publishing. http://dx.doi.org/10.1007/978-3-319-94523-1_21

Van Der Maaten, L. J. P., Postma, E. O. et Van Den Herik, H. J. (2009). Dimensionality Reduction : A Comparative Review. *Journal of Machine Learning Research*. <http://dx.doi.org/10.1080/13506280444000102>

Van Kasteren, T., Noulas, A., Englebienne, G. et Kröse, B. (2008). Accurate activity recognition in a home setting. Dans *Proceedings of the 10th international conference on Ubiquitous computing - UbiComp '08*. <http://dx.doi.org/10.1145/1409635.1409637>

Van Kasteren, T. L. M., Englebienne, G. et Kröse, B. J. A. (2011). Hierarchical activity recognition using automatically clustered actions. Dans *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*. http://dx.doi.org/10.1007/978-3-642-25167-2_9

Vikramaditya Jakkula, D. J. C. (2007). Mining Sensor Data in Smart Environment for Temporal Activity Prediction. *The 13th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*.

Vinoski, S. (2006). Advanced message queuing protocol. *IEEE Internet Computing*, 10(6), 87 – 89. <http://dx.doi.org/10.1109/MIC.2006.116>

Wang, J., Chen, Y., Hao, S., Peng, X. et Hu, L. (2018). Deep learning for sensor-based activity recognition : A Survey. *Pattern Recognition Letters*. <http://dx.doi.org/10.1016/j.patrec.2018.02.010>

Wang, W. Z., Guo, Y. W., Huang, B. Y., Zhao, G. R., Liu, B. Q. et Wang, L. (2011). Analysis of filtering methods for 3D acceleration signals in body sensor network. Dans *Proceedings of 2011 International Symposium on Bioelectronics and Bioinformatics, ISBB 2011*. <http://dx.doi.org/10.1109/ISBB.2011.6107697>

Weiser, M. (1991). The Computer for the 21st Century. *Scientific American*. <http://dx.doi.org/10.1038/scientificamerican0991-94>

Weiss, C., Fechner, N., Stark, M. et Zell, A. (2007). Comparison of different approaches to vibration-based terrain classification. Dans *Proceedings of the 3rd European Conference on Mobile Robots, EMCR 2007*, 1–6., Freiburg, Germany.

Welch, G. et Bishop, G. (2006). An Introduction to the Kalman Filter. *In Practice*. <http://dx.doi.org/10.1.1.117.6808>

Witten, I. H., Frank, E. et Hall, M. a. (2011). *Data Mining : Practical Machine Learning Tools and Techniques, Third Edition*. [http://dx.doi.org/10.1002/1521-3773\(20010316\)40:6<9823::AID-ANIE9823>3.3.CO;2-C](http://dx.doi.org/10.1002/1521-3773(20010316)40:6<9823::AID-ANIE9823>3.3.CO;2-C)

Yang, J. B., Nguyen, M. N., San, P. P., Li, X. L. et Krishnaswamy, S. (2015). Deep convolutional neural networks on multichannel time series for human activity recognition. Dans *IJCAI International Joint Conference on Artificial Intelligence*. <http://dx.doi.org/10.3897/zookeys.77.769>

Yuan Jie Fan, Yue Hong Yin, Li Da Xu, Yan Zeng et Fan Wu (2014). IoT-Based Smart Rehabilitation System. *IEEE Transactions on Industrial Informatics*, 10(2), 1568–1577. <http://dx.doi.org/10.1109/TII.2014.2302583>

Zheng, Y., Peng, Y., Wang, G., Liu, X., Dong, X. et Wang, J. (2016). Development and evaluation of a sensor glove for hand function assessment and preliminary attempts at assessing hand coordination. *Measurement : Journal of the International Measurement Confederation*. <http://dx.doi.org/10.1016/j.measurement.2016.06.059>

Zhenyu, Z., Ke-Jun, L., Ruzhen, L. et Shaofeng, W. (2011). Smart home system based on ipv6 and zigbee technology. *Procedia Engineering*, 15, 1529–1533. <http://dx.doi.org/10.1016/j.proeng.2011.08.284>

Zhihua, S. (2016). Design of smart home system based on ZigBee. Dans *2016 International Conference on Robots & Intelligent System (ICRIS)*, 167–170., ZhangJiaJie, China. IEEE Comput. Soc. <http://dx.doi.org/10.1109/ICRIS.2016.35>

Zhu, X. (2005). Semi-Supervised Learning Literature Survey. *SciencesNew York*, 10, 1–60. <http://dx.doi.org/10.1.1.146.2352>

ANNEXE A

RÉSULTATS DÉTAILLÉS DE L'EXPÉRIMENTATION POUR LA RECONNAISSANCE DES SOLS

A.1 WEARABLE DEVICE : VERSION 1

Tableau A.1 : Résultats détaillés de la reconnaissance des sols avec l'algorithme *Random Forest* configuré avec $B = 150$ arbres et de haut en bas les trois valeurs de $F : f_0, f_1$ et f_2 pour la version 1 du *wearable device*.

Jeu de données	Justesse	F-Mesure	k
soil_type_wear_v1_6	0.82	0.82	0.76
soil_type_position_wear_v1_6	0.86	0.86	0.85
Jeu de données	Justesse	F-Mesure	k
soil_type_wear_v1_6	0.82	0.81	0.75
soil_type_position_wear_v1_6	0.87	0.87	0.86
Jeu de données	Justesse	F-Mesure	k
soil_type_wear_v1_6	0.82	0.82	0.76
soil_type_position_wear_v1_6	0.87	0.87	0.86

Tableau A.2 : Résultats détaillés de la reconnaissance des sols avec l'algorithme *Random Forest* configuré avec $B = 300$ arbres et de haut en bas les trois valeurs de $F : f_0, f_1$ et f_2 pour la version 1 du *wearable device*.

Jeu de données	Justesse	F-Mesure	k
soil_type_wear_v1_6	0.87	0.83	0.77
soil_type_position_wear_v1_6	0.88	0.87	0.87
Jeu de données	Justesse	F-Mesure	k
soil_type_wear_v1_6	0.84	0.84	0.78
soil_type_position_wear_v1_6	0.87	0.87	0.86
Jeu de données	Justesse	F-Mesure	k
soil_type_wear_v1_6	0.82	0.82	0.76
soil_type_position_wear_v1_6	0.87	0.87	0.86

Tableau A.3 : Résultats détaillés de la reconnaissance des sols avec l’algorithme des k plus proches voisins configuré avec $k = 1$ et de haut en bas la distance Euclidienne et la distance de Manhattan pour la version 1 du *wearable device*.

Jeu de données	Justesse	F-Mesure	k
soil_type_wear_v1_6	0.85	0.85	0.80
soil_type_position_wear_v1_6	0.83	0.83	0.82
Jeu de données	Justesse	F-Mesure	k
soil_type_wear_v1_6	0.87	0.87	0.83
soil_type_position_wear_v1_6	0.85	0.85	0.84

A.2 WEARABLE DEVICE : VERSION 2

Tableau A.4 : Résultats détaillés de la reconnaissance des sols avec l’algorithme *Random Forest* configuré avec $B = 150$ arbres et $F = f0$ pour la version 2 du *wearable device*.

Dataset	Justesse	F-Mesure	k
soil_type_wear_v2_6	0.86	0.86	0.82
soil_type_wear_v2_9	0.91	0.91	0.86
soil_type_wear_v2_12	0.89	0.89	0.83
soil_type_position_wear_v2_6	0.91	0.90	0.90
soil_type_position_wear_v2_9	0.93	0.92	0.92
soil_type_position_wear_v2_12	0.92	0.92	0.91

Tableau A.5 : Résultats détaillés de la reconnaissance des sols avec l’algorithme *Random Forest* configuré avec $B = 150$ arbres et $F = f1$ pour la version 2 du *wearable device*.

Dataset	Justesse	F-Mesure	k
soil_type_wear_v2_6	0.86	0.86	0.81
soil_type_wear_v2_9	0.91	0.91	0.87
soil_type_wear_v2_12	0.89	0.89	0.83
soil_type_position_wear_v2_6	0.91	0.91	0.91
soil_type_position_wear_v2_9	0.92	0.92	0.91
soil_type_position_wear_v2_12	0.92	0.92	0.92

Tableau A.6 : Résultats détaillés de la reconnaissance des sols avec l'algorithme *Random Forest* configuré avec $B = 150$ arbres et $F = f2$ pour la version 2 du *wearable device*.

Dataset	Justesse	F-Mesure	k
soil_type_wear_v2_6	0.86	0.86	0.81
soil_type_wear_v2_9	0.90	0.90	0.85
soil_type_wear_v2_12	0.90	0.90	0.85
soil_type_position_wear_v2_6	0.91	0.90	0.90
soil_type_position_wear_v2_9	0.92	0.92	0.91
soil_type_position_wear_v2_12	0.91	0.91	0.91

Tableau A.7 : Résultats détaillés de la reconnaissance des sols avec l'algorithme *Random Forest* configuré avec $B = 300$ arbres et $F = f0$ pour la version 2 du *wearable device*.

Dataset	Justesse	F-Mesure	k
soil_type_wear_v2_6	0.86	0.86	0.82
soil_type_wear_v2_9	0.92	0.92	0.87
soil_type_wear_v2_12	0.90	0.90	0.85
soil_type_position_wear_v2_6	0.92	0.92	0.92
soil_type_position_wear_v2_9	0.93	0.93	0.92
soil_type_position_wear_v2_12	0.92	0.92	0.91

Tableau A.8 : Résultats détaillés de la reconnaissance des sols avec l'algorithme *Random Forest* configuré avec $B = 300$ arbres et $F = f1$ pour la version 2 du *wearable device*.

Dataset	Justesse	F-Mesure	k
soil_type_wear_v2_6	0.87	0.87	0.83
soil_type_wear_v2_9	0.92	0.92	0.88
soil_type_wear_v2_12	0.90	0.90	0.84
soil_type_position_wear_v2_6	0.92	0.92	0.92
soil_type_position_wear_v2_9	0.92	0.92	0.92
soil_type_position_wear_v2_12	0.92	0.92	0.91

Tableau A.9 : Résultats détaillés de la reconnaissance des sols avec l'algorithme *Random Forest* configuré avec $B = 300$ arbres et $F = f2$ pour la version 2 du *wearable device*.

Dataset	Justesse	F-Mesure	k
soil_type_wear_v2_6	0.86	0.86	0.82
soil_type_wear_v2_9	0.92	0.92	0.87
soil_type_wear_v2_12	0.91	0.91	0.86
soil_type_position_wear_v2_6	0.92	0.92	0.92
soil_type_position_wear_v2_9	0.92	0.92	0.92
soil_type_position_wear_v2_12	0.92	0.92	0.92

Tableau A.10 : Résultats détaillés de la reconnaissance des sols avec l'algorithme des k plus proches voisins configuré avec $k = 1$ et la distance Euclidienne pour la version 2 du *wearable device*.

Dataset	Justesse	F-Mesure	k
soil_type_wear_v2_6	0.91	0.91	0.87
soil_type_wear_v2_9	0.90	0.90	0.85
soil_type_wear_v2_12	0.84	0.84	0.76
soil_type_position_wear_v2_6	0.84	0.84	0.83
soil_type_position_wear_v2_9	0.88	0.88	0.88
soil_type_position_wear_v2_12	0.83	0.83	0.82

Tableau A.11 : Résultats détaillés de la reconnaissance des sols avec l'algorithme des k plus proches voisins configuré avec $k = 1$ et la distance de Manhattan pour la version 2 du *wearable device*.

Dataset	Justesse	F-Mesure	k
soil_type_wear_v2_6	0.92	0.92	0.90
soil_type_wear_v2_9	0.93	0.93	0.89
soil_type_wear_v2_12	0.90	0.90	0.85
soil_type_position_wear_v2_6	0.87	0.87	0.86
soil_type_position_wear_v2_9	0.91	0.91	0.91
soil_type_position_wear_v2_12	0.87	0.87	0.86

A.3 TÉLÉPHONE INTELLIGENT

Tableau A.12 : Résultats détaillés de la reconnaissance des sols avec l'algorithme *Random Forest* configuré avec $B = 150$ arbres et $F = f0$ pour le téléphone intelligent.

Dataset	Justesse	F-Mesure	k
soil_type_cell_6	0.92	0.92	0.87
soil_type_cell_9	0.92	0.92	0.88
soil_type_cell_12	0.91	0.91	0.87
soil_type_position_cell_6	0.91	0.91	0.91
soil_type_position_cell_9	0.91	0.91	0.91
soil_type_position_cell_12	0.92	0.92	0.91

Tableau A.13 : Résultats détaillés de la reconnaissance des sols avec l'algorithme *Random Forest* configuré avec $B = 150$ arbres et $F = f1$ pour le téléphone intelligent.

Dataset	Justesse	F-Mesure	k
soil_type_cell_6	0.92	0.92	0.88
soil_type_cell_9	0.92	0.92	0.88
soil_type_cell_12	0.92	0.92	0.88
soil_type_position_cell_6	0.92	0.92	0.91
soil_type_position_cell_9	0.92	0.92	0.92
soil_type_position_cell_12	0.92	0.92	0.91

Tableau A.14 : Résultats détaillés de la reconnaissance des sols avec l'algorithme *Random Forest* configuré avec $B = 150$ arbres et $F = f2$ pour le téléphone intelligent.

Dataset	Justesse	F-Mesure	k
soil_type_cell_6	0.92	0.92	0.89
soil_type_cell_9	0.91	0.91	0.87
soil_type_cell_12	0.92	0.92	0.88
soil_type_position_cell_6	0.92	0.92	0.91
soil_type_position_cell_9	0.92	0.92	0.91
soil_type_position_cell_12	0.92	0.92	0.92

Tableau A.15 : Résultats détaillés de la reconnaissance des sols avec l'algorithme *Random Forest* configuré avec $B = 300$ arbres et $F = f0$ pour le téléphone intelligent.

Dataset	Justesse	F-Mesure	k
soil_type_cell_6	0.92	0.92	0.88
soil_type_cell_9	0.92	0.92	0.88
soil_type_cell_12	0.92	0.92	0.88
soil_type_position_cell_6	0.92	0.92	0.91
soil_type_position_cell_9	0.92	0.92	0.92
soil_type_position_cell_12	0.92	0.92	0.91

Tableau A.16 : Résultats détaillés de la reconnaissance des sols avec l'algorithme *Random Forest* configuré avec $B = 300$ arbres et $F = f1$ pour le téléphone intelligent.

Dataset	Justesse	F-Mesure	k
soil_type_cell_6	0.92	0.92	0.88
soil_type_cell_9	0.92	0.92	0.88
soil_type_cell_12	0.92	0.92	0.87
soil_type_position_cell_6	0.92	0.92	0.91
soil_type_position_cell_9	0.92	0.92	0.92
soil_type_position_cell_12	0.92	0.92	0.91

Tableau A.17 : Résultats détaillés de la reconnaissance des sols avec l'algorithme *Random Forest* configuré avec $B = 300$ arbres et $F = f2$ pour le téléphone intelligent.

Dataset	Justesse	F-Mesure	k
soil_type_cell_6	0.93	0.93	0.89
soil_type_cell_9	0.92	0.92	0.88
soil_type_cell_12	0.92	0.92	0.88
soil_type_position_cell_6	0.92	0.92	0.91
soil_type_position_cell_9	0.92	0.92	0.91
soil_type_position_cell_12	0.92	0.92	0.91

Tableau A.18 : Résultats détaillés de la reconnaissance des sols avec l’algorithme des k plus proches voisins configuré avec $k = 1$ et la distance Euclidienne pour le téléphone intelligent.

Dataset	Justesse	F-Mesure	k
soil_type_cell_6	0.90	0.90	0.85
soil_type_cell_9	0.90	0.90	0.85
soil_type_cell_12	0.90	0.90	0.85
soil_type_position_cell_6	0.89	0.89	0.88
soil_type_position_cell_9	0.88	0.88	0.87
soil_type_position_cell_12	0.89	0.89	0.88

Tableau A.19 : Résultats détaillés de la reconnaissance des sols avec l’algorithme des k plus proches voisins configuré avec $k = 1$ et la distance de Manhattan pour le téléphone intelligent.

Dataset	Justesse	F-Mesure	k
soil_type_cell_6	0.92	0.92	0.87
soil_type_cell_9	0.92	0.92	0.87
soil_type_cell_12	0.92	0.92	0.89
soil_type_position_cell_6	0.90	0.90	0.89
soil_type_position_cell_9	0.89	0.89	0.88
soil_type_position_cell_12	0.91	0.91	0.90